

分类号_____

学号 2003511840025

学校代码 10487

华中科技大学

博士学位论文

机器学习在蛋白质结构和功能预测 中的应用研究

学位申请人：王 燕

学科专业：系统分析与集成

指导教师：许 进 教授

答辩日期：2006.11.13

A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Degree of Doctor of Philosophy in Science

**Prediction of Protein Structure and Function with Machine
Learning Methods**

Candidate : Wang Yan

Major : System Analysis and Integration

Supervisor: Professor Xu Jin

Huazhong University of Science and Technology

Wuhan 430074, P.R.China

November 2006

摘 要

在生物试验数据积累迅速增加的今天,如何将数据变为知识是一项极富挑战性又十分有趣的事情。因此,希望得到新的分析技术的生物学迅速与如日中天的信息技术相结合,催化了生物信息学的诞生。蛋白质序列信息的积累速度远快于蛋白质结构数据的增长速度,因此,人们非常希望能直接能从序列信息出发预测蛋白质结构。仅仅知道蛋白质结构还不够,人们最终想确定的是蛋白质的功能。因此,蛋白质结构与功能预测是生物信息学研究的重点任务之一。本文利用机器学习方法对蛋白质结构和功能预测中的几个分支问题进行了研究,本文主要工作包括:

(1) 提出了一个新的基于支持向量机的预测氢键 α 转角的方法。讨论了位置特异的进化信息和预测的二级结构信息对预测性能的影响。结果显示当使用相同的输入信息和使用相同的评价方法时,本方法表现出比目前最好的预测氢键 α 转角的方法更好的预测性能。当使用位置特异的进化信息和预测的二级结构信息作为输入,并使用相同的数据集和相同的 5-折交叉验证,该方法取得的 MCC 为 0.26,比到目前为止最好的方法取得的 MCC 值要高 0.1。关于氢键 α 转角预测,我们还开发了 AlphaTurn 在线服务。此外,我们还比较了三种处理不平衡数据集的方法,提出用二阶段法来处理不平衡数据集。

(2) 在氢键 α 转角预测的基础上首次对广义 α 转角的预测进行研究。广义 α 转角的定义是第 i 个残基与第 $i+4$ 个残基的 α 碳之间的距离小于 $6.5\text{\AA}$,不一定包括氢键。该方法表现了良好的预测性能,多序列联配信息和预测的二级结构信息都有助于提高预测性能。综合多序列联配和预测的二级结构作为输入信息时,预测的 MCC 值达到 0.415。因为依距离定义的 α 转角在蛋白质中的含量比氢键 α 转角高,所以依距离定义的 α 转角的预测性能优于氢键 α 转角。

(3) 首次开发一个基于支持向量机的从氨基酸序列出发预测 π 转角的可靠方法。使用进化信息 (PSSMs) 加上预测的二级结构信息作为输入时, SVM 分类器达到最终的 MCC 为 0.556。我们也注意到进化信息对 π 转角预测的贡献大于对 β 转角预测的贡献。因此,尽管 π 转角预测训练数据中正负样本数更不平衡,但 π 转角预测所取得的预测性能却高于 β 转角预测。关于 π 转角预测,我们还开发了 PiTurn 在线服务。此外,我们还计算了 640 个非同源蛋白中 1931 个 π 转角的位置特异的氨基

酸出现的频率，这有助于 π 转角的设计。

(4) 综合使用支持向量机和 PSSMs 来预测蛋白质与 RNA 相互作用位点。我们考虑了两种情况，仅仅知道与 RNA 相互作用的蛋白质的序列信息和已知与 RNA 相互作用的蛋白质的结构信息。当仅已知序列信息时，最好的预测性能是使用 PSSMs 和预测的二级结构作为输入信息时得到的，MCC 值是 0.432，是目前从序列出发预测蛋白质与 RNA 相互作用位点最好的预测性能。进化信息对预测性能的提升起至关重要的作用。当已知与 RNA 相互作用的蛋白质的结构信息时，预测性能进一步提升。

(5) 使用了简单的信息离散性度量方法来区分 β -桶形膜蛋白和球形蛋白。当 $l=2$ 时，经过 10-折交叉验证，识别 β -桶形膜蛋白正确率是 91%，识别球形蛋白的正确率是 86%。它还能正确识别跨膜 α 螺旋蛋白，识别正确率为 89%。此外，我们还用简并的氨基酸字符集测试了该方法。当氨基酸字符集减少到 15、12 和 10 时，总正确率下降的很少。这说明识别 β -桶形膜蛋白和球形蛋白所需的最小信息是 10 个字符。当用相同的数据集测试时，信息离散性度量方法比以前的方法取得了更好的 MCC 值。

关键词： α 转角 π 转角 β -桶形膜蛋白 蛋白质与 RNA 相互作用 机器学习 支持向量机 信息离散性度量方法

Abstract

The ever-expanding biological experimental data makes how to turn the data to knowledge a very challenging and interesting problem. The combination of biology and information science brings out bioinformatics. The accumulating rate of the protein sequence information is far quicker than that of the protein structure information. Thus, people hope to be able to predict protein structure from sequence. But it is not enough for only knowing the protein structure. The final aim of protein structure prediction is to know protein function. The predictions of protein structure and protein function are two main points in bioinformatics. We have used machine learning methods to study several problems in protein structure and function prediction. The contribution is as follows.

A novel method based on support vector machine (SVM) has been developed to predict hydrogen-bond α -turns. The contributions of multiple sequence alignment generated by PSI-BLAST and predicted secondary structure on the prediction performance have been discussed. Results have shown that the present method has shown better performance the current best hydrogen-bond α -turns prediction method AlphaPred. An online web server named AlphaTurn based on this method has been developed. In addition, three schemes for handling a highly unbalanced data set have been compared.

We first predict α -turns defined as pentapeptides of which the distance between C_α of between residue i and residue $i+4$. The proposed method performs well. Both multiple sequence alignments information and predicted secondary structure information contribute to the prediction performance. With multiple sequence alignment and predicted secondary structure, the final SVM model yielded a Matthews Correlation Coefficient (MCC) of 0.451 by a seven-fold cross-validation..

A robust method designed for the prediction of π turns was first developed. With multiple sequence alignment and predicted secondary structure, the final SVM model yields an MCC value of 0.556 by a seven-fold cross-validation. We also noticed that multiple sequence alignment contribute more to the π -turns prediction than to the β -turns

prediction. As a result, the accuracy level achieved for π -turns is better than that of the best-predicted tight turns β -turns, although the dataset used in this work is more unbalanced than the datasets used in the β -turn prediction method. The newly computed positional potentials can be applied in modeling and design of π -turns in proteins.

We developed a robust method for the prediction of protein residues that interact with RNA using SVM and position-specific scoring matrices (PSSMs). Two approaches have been considered in the prediction of protein residues at RNA-binding surfaces. One is given the sequence information of a protein chain that is known to interact with RNA; the other is given the structural information. Coupled with PSI-BLAST profiles and predicted secondary structure, the present approach yields an MCC value of 0.432 by a 7-fold cross-validation, which is the best among all previous reported RNA-binding sites prediction methods. The multiple sequence alignment information contributes much to the prediction performance. When given the structural information, further improvement has been obtained.

We applied a new measure of information discrepancy to identifying β -barrel membrane proteins from other globular and membrane proteins. When the subsequence length is 2, our approach can correctly recognize β -barrel membrane proteins with 91% accuracy in the 10-fold cross-validation tests. Meanwhile, the accuracy for picking up globular proteins is up to 86%. Furthermore, the present approach can correctly exclude α -helices membrane proteins with 89% accuracy. Another interesting finding is that the method can still preserve high predicting accuracy when reduced sets of amino acids of 15, 12, and 10 are used. This suggests that the minimum number of letters needed for discriminating between β MPs and GPs is around 10. When evaluated on the same datasets, our method outperforms earlier methods in both overall prediction accuracy and MCC value.

Key Words: α -turns, π turns, protein-RNA interaction, β -barrel membrane protein. Machine learning, Support Vector Machine, information discrepancy

目 录

摘 要	II
ABSTRACT	IV
1 绪 论	1
1.1 引言	1
1.2 蛋白质结构层次	2
1.3 蛋白质结构预测进展	6
1.3.1 蛋白质二级结构预测进展	7
1.4 蛋白质功能预测进展	9
1.5 常用的蛋白质结构和序列数据库	10
1.5.1 蛋白质序列数据库	10
1.5.2 蛋白质结构数据库	11
1.6 本文主要研究内容	11
2 分类器设计及性能评价方法	13
2.1 引言	13
2.2 支持向量机	14
2.2.1 最优分类面	14
2.2.2 核与特征空间	17
2.2.3 软间隔优化	18
2.3 信息离散性度量方法	19
2.4 分类器性能评价	21
2.5 本章小结	21
3 氢键 α 转角预测	23
3.1 引言	23
3.2 试验数据和方法	24
3.2.1 试验数据	24
3.2.2 PSI-BLAST 谱	26
3.2.3 输入特征编码策略	27
3.2.4 预测的可信度	28
3.2.5 预测后过滤	29
3.2.6 预测性能评价参数	29
3.3 结论与讨论	30
3.3.1 α 转角位置特异的氨基酸倾向性研究及类别分析	30
3.3.2 核函数选取与参数优化	33
3.3.3 处理两类样本不均衡	34

3.3.4	预测体系结构	35
3.3.5	PSSMs 和二级结构信息对预测性能的影响	36
3.3.6	与其它预测方法的比较	37
3.3.7	AlphaTurn 网络服务	39
3.4	本章小结	41
4	广义 α 转角预测	42
4.1	引言	42
4.2	材料与方法	42
4.2.1	数据集	42
4.2.2	支持向量机	44
4.2.3	输入特征编码策略	45
4.2.4	预测后过滤	45
4.2.5	预测性能评价参数	45
4.3	结果与讨论	46
4.3.1	核函数选取与参数优化	46
4.3.2	处理两类样本不均衡	46
4.3.3	不同编码策略对预测性能的影响	47
4.4	本章小结	48
5	π 转角预测研究	49
5.1	引言	49
5.2	材料与方法	50
5.2.1	数据集	50
5.2.2	编码策略	51
5.2.3	预测后过滤	52
5.3	预测的可信度	52
5.3.1	预测性能评价参数	53
5.4	结果与讨论	53
5.4.1	π 转角位置特异的氨基酸倾向性研究及类别分析	53
5.4.2	核函数选取与参数优化	55
5.4.3	窗口长度优化	57
5.4.4	处理两类样本不均衡	57
5.4.5	不同编码策略对预测性能的影响	58
5.5	PiTURN 网络服务	60
5.6	本章小结	61
6	蛋白质与 RNA 相互作用位点预测	63
6.1	引言	63
6.2	实验数据	64

6.3	编码	65
6.4	预测性能评价	65
6.5	结果与讨论	65
6.5.1	RNA 结合位点的序列特征	65
6.5.2	预测系统的参数优化	67
6.5.3	窗口长度的优化	67
6.5.4	不同的编码策略对预测性能的影响	68
6.5.5	与其它预测方法的比较	69
6.5.6	网络服务	70
6.6	本章小结	71
7	β -桶形膜蛋白和球形蛋白的识别研究	72
7.1	引言	72
7.2	材料和方法	73
7.2.1	数据集	73
7.2.2	信息离散性度量方法	73
7.2.3	预测正确率的度量	73
7.3	结果与讨论	74
7.3.1	基于普通氨基酸字符集的分析	74
7.3.2	基于简并氨基酸字符集的分析	75
7.3.3	与其它方法的比较	77
7.4	本章小结	78
8	总结与展望	80
8.1	全文总结	80
8.2	研究展望	81
	致 谢	83
	附录 1 发表或录用论文	93
	附录 2 攻读学位期间参与的科研课题	94
	附 表	95

1 绪 论

1.1 引言

随着人类基因组计划的实施,核酸、蛋白质的序列和结构数据呈指数增长。面对巨大而复杂的数据,运用计算机对数据进行管理、分析是很自然的。因此,生物信息学也应运而生。生物信息学广义的概念是指应用信息科学的方法和技术,研究生物体系和生物过程中信息的存贮、信息的内涵和信息的传递,研究和分析生物体细胞、组织、器官的生理、病理、药理过程中的各种生物信息,或者也可以说成是生命科学中的信息科学^[1]。生物信息学狭义的概念是指应用信息科学的理论、方法和技术,管理、分析和利用生物分子数据。通过收集、组织、管理生物分子数据,使研究人员能够迅速地获得和方便地使用相关信息;通过处理、分析、挖掘生物分子数据,得到深层次的生物学知识,加深对生物世界的认识^[1]。

生物信息学的主要研究内容可分为以下三个方面:第一是收集和管理生物分子数据,使得生物学家研究人员能够方便地使用这些数据,并为信息分析和数据挖掘打下基础。生物分子数据来自于生物学实验,应用信息学技术收集和管理这些数据,将各种数据以一定的表示形式存放在计算机中,建立数据库系统,并提供数据查询、搜索和数据通讯工具。第二是进行数据处理和分析。通过数据分析,发现数据之间的关系,认识数据的本质,进而上升为生物学知识。并在此基础上,解释与生物分子信息复制、传递和表达有关的生物过程,解释在生物过程中出现的信息变化与疾病的关系,帮助发现新的药物作用目标,设计新的药物分子,为进一步的研究和应用打下基础。在蛋白质分析方面,着重分析蛋白质序列与蛋白质结构及功能之间的关系,预测蛋白质的结构和功能,研究蛋白质的进化关系。生物信息学的研究第三个方面是开发分析工具和实用软件,解决具体的问题,为具体的生物信息学应用服务,例如,开发生物分子序列比较工具、基因识别工具、生物分子结构预测工具、基因表达数据分析工具等。

蛋白质和核酸是所有生命活动重要的物质基础,也是生物信息学研究的中心。脱氧核糖核酸(DNA)是遗传信息的载体,但是遗传信息的复制、转录和表达则要依靠各种蛋白质才能完成。蛋白质在生物体的生命活动中起着重要的作用。蛋白质的重要功能表现在有以下几个方面。蛋白质可以作为有机体新陈代谢的催化剂-酶、作为

有机体的结构成分、储存氨基酸、作为运输作用肌肉收缩系统的主要成分、激素功能、免疫反应、起接受和传递信息作用、调节和控制细胞的生长、分化和遗传信息的表达。本文的主要研究对象就是千变万化的蛋白质^[2]。

机器学习是信息学科中一门新的，但迅速发展的学科。机器学习的一大优点就是可以灵活构建由大量参数刻画的模型，由机器自动处理数据，使信息提取过程尽可能地实现自动化^[3]。机器学习方法适用于那些拥有大量数据但相应理论很不完善的领域，这正是计算分子生物学使用机器学习方法的原因。机器学习已有较多比较成熟的算法，比如贝叶斯方法、最近邻法、隐马尔可夫模型、神经网络法、支持向量机以及基于信息论的方法等。本文利用机器学习方法对 α 转角预测、 π 转角预测、蛋白质与 RNA 相互作用位点预测和 β -桶形膜蛋白和球形蛋白分类问题进行了研究。

以下将分别介绍蛋白质结构层次、蛋白质结构预测、蛋白质功能预测、常用蛋白质数据库和本文的主要研究内容。

1.2 蛋白质结构层次

所有蛋白质都是由 20 种氨基酸构成的。这 20 种氨基酸其侧链在大小、形状、电荷、形成氢键的能力和化学活性方面都不同。这 20 种氨基酸的不同组合形成各种各样的蛋白质，实现不同的生物功能。多肽链必须按照一定的规律折叠成三维结构，才具有生物活性。蛋白质的结构是分层次的。蛋白质结构层次可分为一、二、三和四级结构。蛋白质的二、三、四级结构一般也统称为蛋白质的高级结构^[3-4]。

蛋白质的一级结构通常是指蛋白质肽链的氨基酸残基的排列顺序，也称为残基或氨基酸的序列。对由多个亚基组成的蛋白质而言，它们的一级结构应该包括各个亚基肽链的一级结构；如果一个亚基由几条肽链通过二硫键相连，则其肽链的序列当然也就是几条肽链的总和。

蛋白质的二级结构是指肽链中局部肽段的构象，它们是完整肽链构象(三级结构)的结构单元，是蛋白质复杂的空间构象的基础，故它们也可称为构象单元。各类二级结构的形成几乎全是由于肽链骨架中的羰基上的氧原子和亚氨基上的氢之间的氢键所维系。其他的作用力，例如范德华力等，也有一定的贡献。某一肽段，或某些肽段间的氢键越多，形成的二级结构就越稳定，即二级结构的形成有一种协同的趋势。蛋白质二级结构可以分为三大类：规则的二级结构、部分规则的二级结构、不规则的二

级结构^[4]。规则的二级结构包括 α 螺旋和 β 折叠。部分规则的二级结构主要包括各种转角和环形。

α 螺旋又是最常见的规则的二级结构。在这些构象单元中，所有与 α 碳原子相连的两个二面角 ϕ 和 ψ 都是恒定的 ϕ 为 -57° ， ψ 为 -47° 。同时，所有的肽键都是反式的，即 ω 可认为是 180° 。在 α 螺旋中起到稳定作用的是肽链骨架中的第 i 个羰基上的氧原子和第 $i+4$ 个亚胺基上的氢之间的氢键，因此，在肽段中近 N 端的前 3 个亚胺基上的氢和其 C 端的最后 3 个羰基上的氧原子都不参与氢键的形成。这也是一些蛋白质肽链的 N 端和 C 端不易形成 α 螺旋的原因。 α 螺旋除了具有特定的 ϕ 和 ψ 角外，还有一些特征参数：每圈螺旋含有 3.6 个残基，每个残基在螺旋轴上的投影，即每圈螺旋沿螺旋轴上升 1.5 埃；每圈螺旋的螺距为 5.4 埃；图 1.1 在每对氢键间包含有 13 个原子。 α 螺旋的特征归纳在图 1.1 中。




图 1.1 蛋白质的 α 螺旋结构

β 折叠是蛋白质中又一种普遍存在的规则构象单元，它可看成是一种特殊的螺旋。 α 螺旋每圈含有 3.6 个残基，而 3_{10} 螺旋每圈仅含有 3 个残基，因此 3_{10} 螺旋可以看成是拉伸了的 α 螺旋。如果 3_{10} 螺旋进一步拉伸，使每圈仅含 2 个残基，就成为了 β 折叠。从已知球状蛋白质的立体结构中统计的结果是，每股 β 折叠的平均长度约 20 Å，相当于 6.5 个残基，通常含有 3~10 个残基。 β 折叠中同一肽段邻近肽键间很难形成氢键，因此单股 β 折叠是不稳定的。只有通过较远距离的肽键之间形成的

氢键，将多股 β 折叠组合成一组 β 折叠，一般称为 β 片层结构。构成 β 片层的几股 β 折叠走向相同的是平行的 β 片层，走向相反的则是反平行的 β 片层。在平行的 β 片层中， ϕ 为 -119° ， ψ 为 $+113^\circ$ ， ω 为 180° ；每个残基在肽链前进的方向上的投影（相当于每圈螺旋沿螺旋轴上升的距离）为 $3.25 \text{ \AA}$ ；每个重复单位（相当于每圈螺旋）中含有 2 个残基。在反平行 β 片层中， ϕ 为 -139° ， ψ 为 $+135^\circ$ ， ω 为 180° ；每个残基在肽链前进的方向上的投影约 $3.3\sim 3.5 \text{ \AA}$ ；每个重复单位也含有 2 个残基。两种类型的 β 片层相比较，反平行的 β 片层比平行的 β 片层更为稳定。在球状蛋白中，最为简单的反平行的 β 片层是由同一肽段经过转角分成的两股 β 折叠间形成的“发夹”结构。




图 1.2 β 折叠

如果蛋白质的肽链中只有规则的二级结构，就不可能有如此多样化的蛋白质的立体结构。因此，这些部分规则的二级结构对球状蛋白质构象的形成是非常重要的。规则的二级结构中，不论是螺旋还是 β 折叠组成的片层结构中，都存在着较多的氢键，致使规则的二级结构都有相当的刚性。如果一段肽段中，不存在氢键或其他的作用，则肽段中的各个残基间有更大的自由度，没有刚性，从而表现出极大的柔性，这类肽段没有规则性。部分规则的二级结构的特点在于，它们介乎前两者之间，即“刚柔兼备”。居于这一类型部分规则的二级结构有转角和环形两类。

蛋白质中的转角定义为帮助多肽链改变方向的结构，并且形成转角的残基数不超过 6 个的肽段。根据包含的残基数，转角可分为 δ 转角、 γ 转角、 β 转角、 α 转

角、 π 转角，它们分别包括 2、3、4、5、6 个残基。

δ 转角是最小的转角，仅仅包含两个氨基酸。转角内氢键由第 i 个残基的羰基 O 与 $i+1$ 个残基的氨基质子组成。另外一个较小的转角是 γ 转角，它包含三个氨基酸。转角内氢键由第 i 个残基的羰基 O 与 $i+2$ 个残基的氨基质子组成。

β 转角是研究的较多转角，它在蛋白质中的含量较高，大约占 25%。由四个氨基酸组成，由第 i 个残基的羰基 O 与 $i+3$ 个残基的氨基质子形成的氢键稳定。然而 Lewis 等发现 25% 的 β 转角没有由第 i 个残基的羰基 O 与 $i+3$ 个残基的氨基质子形成的氢键。因此，现在广泛接受的 β 转角的定义是： β 转角由四个连续的残基组成，第 i 个残基的与 $i+3$ 个残基的 α 碳之间的距离小于 7 Å，并且不属于螺旋结构。

α 转角包含五个氨基酸残基，由第 i 个残基的羰基 O 与 $i+4$ 个残基的氨基质子形成的氢键稳定。最近，Dasgupta^[5]等将 α 转角的定义扩展为第 i 个残基与第 $i+4$ 个残基的 α 碳之间的距离小于 6.5 Å，不一定包括氢键。 π 转角是一段包括 6 个残基的肽段，第 i 个残基的羰基 O 和第 $i+5$ 个残基的氨基质子之间有一个氢键。

因为大多数转角都包含一个转角内氢键，因此将所有转角统一到一个定义中是可能的，这将有助于理解转角的一般特征，以及它们和其它二级结构的区别。Kabsch 和 Sander^[6]将 n -turn 氢键，即第 i 个残基的羰基与 $i+n$ 个残基的氨基质子形成的氢键，表示为 $H\text{-bond}(i, i+n)$ 。为了表示两个或更多连续的氢键，上式可修改为：

$$H\text{-bond}(i, i+n | \xi) (n=2,3,4,5, \xi=1,2,\dots) \quad (1.1)$$

其中 i 是一个滑动索引，用来表示氨基酸在蛋白质链中的位置，叫做连续度，当 $i=1$ ，相应的结构只包含一个氢键，当 $i=2$ ，有两个连续的氢键，即 $H\text{-bond}(i, i+n)$ 和 $H\text{-bond}(i+1, i+1+n)$ ；当 $i=3$ ，有三个连续的氢键，即 $H\text{-bond}(i, i+n)$ ， $H\text{-bond}(i+1, i+1+n)$ 和 $H\text{-bond}(i+2, i+2+n)$ ；依次类推。因此，得出下面公式：

$$H\text{-bond}(i, i+n | \xi) \in \left\{ \begin{array}{ll} \gamma\text{-turn}, & \text{if } n=2, \xi=1 \\ \beta\text{-turn}, & \text{if } n=3, \xi=1 \\ 3_{10}\text{-helix}, & \text{if } n=3, \xi \geq 2 \\ \alpha\text{- or } 5\text{-turn}, & \text{if } n=4, \xi=1 \\ \alpha\text{-helix}, & \text{if } n=4, \xi \geq 2 \\ \pi\text{- or } 6\text{-turn}, & \text{if } n=5, \xi=1 \\ \pi\text{-helix}, & \text{if } n=5, \xi \geq 2 \end{array} \right\} \quad (1.2)$$

注意,该定义并未包含广义 β 转角和 α 转角,即那些不包含 $\text{H-bond}(i, i+3|1)$, 但是第 i 个残基的与 $i+3$ 个残基的 α 碳之间的距离小于 $7 \text{ \AA}$ 的四肽结构,以及那些不包含 $\text{H-bond}(i, i+4|1)$, 但是第 i 个残基的与 $i+4$ 个残基的 α 碳之间的距离小于 $6.5 \text{ \AA}$ 的五肽结构。

Ω 环形的特征有以下两个方面: ①由不超过 16 个残基(最常见的是由 6—8 个残基)组成的肽段,尤其以 8 个残基的小环最多; ②这个肽段改变了蛋白质肽链的走向,构成 Ω 环的首尾两个残基间的距离小于 $10 \text{ \AA}$, 一般介于 $3.7 \text{ \AA}$ — $10 \text{ \AA}$ 之间,多数是 $5 \text{ \AA}$ — $7 \text{ \AA}$, 最常见的距离是 $5 \text{ \AA}$ — $5.5 \text{ \AA}$ 。

在蛋白质中,特别是球状蛋白质中,常常发现两个或几个二级结构单元组合在一起,彼此相互作用,形成有规则、在空间上能辨认的二级结构组合体充当三级结构的构件,称为超二级结构。常见的超二级结构有 $(\alpha \alpha)$, $(\beta \alpha \beta)$, $(\beta \beta \beta)$ 。

在肽链局部的肽段形成二级结构,以及它们之间进一步相互作用成为超二级结构后,仍有一些肽段中的单键在不断地运动旋转,肽链中的各个部分,包括已经相对稳定的超二级结构以及还未键合的部分,继续相互作用,使整个肽链的内能进一步降低,分子变得更为稳定。由二级结构向三级结构过渡的过程中,目前认为有一种称为熔球态的中间状态。在熔球态中,一些二级结构的构象单元已形成一定方式的立体结构,但是和天然的构象还不尽相同,经过适当的调整后,才转变成为具有生物功能的立体结构。至此,蛋白质的结构就过渡到更高的层次—三级结构。

蛋白质的四级结构可以定义为一些特定三级结构通过非共价键连接而形成的大分子体系时的组合方式。作为蛋白质四级结构组分的肽链被定义为亚基,也有人称为亚单位。在亚基间并不存在共价键,亚基间的相互作用那是非共价键。

1.3 蛋白质结构预测进展

蛋白质结构决定蛋白质的功能。因此我们如果想在分子水平全面理解生命,结构知识就显得很关键。不幸的是目前的结构知识仍然相当有限,因为对大多数蛋白质来说实验确定其结构的过程是很缓慢的,而且对大量的蛋白质来说这是不可能的。已知结构组成的数据库目前含有 18000 个以上的蛋白质结构,但序列数据库却含有几十万条序列。因此用计算的方法预测蛋白质结构就非常有意义了。

一般说来,结构预测是指仅依据蛋白序列的信息来预测蛋白质每个原子在三维空间中的相对位置。然而,并非所有的预测方法都是很全面的,有些方法仅预测结构中有限的部分,例如二级结构,而不需要继续预测真正的原子位置。因为本文的工作不涉及三级结构预测,所以下面只分别介绍蛋白质二级结构预测进展。

1.3.1 蛋白质二级结构预测进展

蛋白质二级结构的预测通常被认为是蛋白结构预测的第一步。根据 Rost^[7]的划分,蛋白质二级结构预测可以分为三个阶段。第一阶段是基于单个氨基酸残基统计分析,从有限的数据集中提取各种残基形成特定二级结构的倾向,以此作为二级结构预测的依据。第二阶段预测方法是基于氨基酸片段的统计分析,使用大量的数据作为统计基础,统计的对象不再是单个氨基酸残基,而是氨基酸片段,片段的长度通常为11-21。片段体现了中心残基所处的环境。在预测中心残基的二级结构时,以残基在特定环境中形成特定二级结构的倾向作为预测依据。

Chou-Fasman 算法^[8-10]是第一阶段的代表性方法。首先统计出20种氨基酸出现在 α 螺旋、 β 折叠和无规则卷曲中出现频率的大小,然后计算出每一种氨基酸在这几种构象中的构象参数 Px。构象参数值的大小反映了该种残基出现在某种构象中的倾向性的大小。按照构象参数值的大小可以把氨基酸分为六个组:Ha(强螺旋形成者)、ha(螺旋形成者)、Ia(弱螺旋形成者)、ia(螺旋形成不敏感者)、ba(螺旋中断者)、Ba(强螺旋中断者)。Chou 和 Fasman 根据残基的倾向性因子提出二级结构预测的经验规则,要点是沿蛋白序列寻找二级结构的成核位点和终止位点。这种方法可能能够正确反映蛋白质二级结构的形成过程,但预测成功率并不高,仅有50%左右。

GOR 方法^[11-12]是第二阶段比较有代表性的方法。GOR 方法将蛋白质序列当作一连串的信息值来处理,该方法不仅考虑了被预测位置本身氨基酸残基种类的影响,而且考虑了相邻残基种类对该位置构象的影响。GOR 针对长度为17的残基窗进行二级结构预测。对序列中的每一个残基,GOR 方法将与它N端紧邻的8个残基和C端紧邻的8个残基与它放在一起进行考虑。与 Chou-Fasman 方法一样,GOR 方法也是通过对已知二级结构的蛋白样本集进行分析,计算出中心残基的二级结构分别为螺旋、折叠和转角时每种氨基酸出现在窗口中各个位置的频率,从而产生一个 17×20 的得分矩阵。然后利用矩阵中的值来计算待预测的序列中每个残基形成螺旋、折叠或者转角的概率。GOR 方法的预测成功率大约为65%左右。GOR 方法的优点是物理意义清楚明确,

数学表达严格，而且很容易写出相应的计算机程序，但缺点是表达式复杂。

第一阶段和第二阶段预测方法有共同的缺陷，它们对三态预测的准确率都低于 70%，而对 β 折叠预测的准确率更低，其主要原因是这些方法在进行二级结构预测时只利用局部信息，二没有考虑长程相互作用。蛋白质的二级结构在一定程度上受远程残基的影响，尤其是 β 折叠。因此，20 世纪 80 年代后期，人们意识到利用包含在多序列联配中的进化信息可以显著地提高二级结构预测的质量。Zvelebil 等^[13]最早实现了该想法，将进化信息融入输入信息。但是要使正确率能有突破性提高还需要更多的数据与更先进的算法。多序列联配信息能增加预测正确率的原因有以下两条^[3]：第一，对某序列的特定二级结构有高度偏好的某一残基可能是随机出现的，但如果它是某一保守序列的一部分，而且该保守序列中所有的残基都对那种类型的二级结构有高度偏好，那么这将是更有力的辅助预测的证据。第二，多序列联配可以从更多细节上揭示保守模式。20 世纪 80 年代后期以来，序列和结构数据库中数据的数量急剧增加，使得二级结构预测算法可以利用的进化和结构信息数量也大为增加。这些信息的增加，还有联配算法本身的改善，如 PSI-BLAST 算法的被开发导致二级结构预测的准确率大大提高。最早使用 PSI-BLAST 算法产生的 PSSMs 谱改进蛋白质二级结构预测的是 David Jones^[14]的工作，他们将二级结构预测的正确率提高到大于 75%。

各种机器学习算法，如神经网络^[14-18]，最近邻算法^[19]，支持向量机^[20-22]都在蛋白质二级结构预测中发挥了重要作用。关于蛋白质二级的预测虽然历史较长，研究也很多，但多只对三状态划分的二级结构进行了预测，并已经取得较高的预测精度。然而，在过去的几十年中，却极少有方法预测转角。实际上，无论从结构还是功能的角度看，转角都发挥着至关重要的作用，（1）如果没有转角的帮助，多肽链便无法折叠成球形结构，（2）转角一般位于蛋白质分子的表面，因此与分子识别有关；（3）转角提供了设计新药的模板结构非常有用的信息。对于不规则二级结构的预测开始于 20 世纪 90 年代，而且其中研究较多的是 β 转角预测。 α 转角预测的工作有一些，但预测性能还较低，而且主要是对氢键 α 转角进行预测，因此我们通过使用支持向量机构造分类器，利用 PSI-BLAST 产生的序列谱和有 PSIPRED 预测的二级结构信息作为输入，使用二阶段发处理不平衡数据集，较大提升了氢键 α 转角的预测性能。在此基础上，我们首次进行了广义 α 转角的预测工作，并取得了较好的预测性能。另外，我们还对 π 转角进行了预测。

1.4 蛋白质功能预测进展

确定蛋白质的功能是蛋白质研究的最终目的，因为只有知道某一种蛋白质的功能，人类才能利用它来解决问题。但是蛋白质功能预测远不像蛋白质结构预测那样目标明确，因为蛋白质功能的分类比较模糊，而且蛋白质功能的预测目标也有多种，例如预测蛋白质的亚细胞定位^[23-30]、分泌性蛋白的信号肽剪切位点预测^[31-35]、蛋白质翻译后修饰位点预测^[36-39]、蛋白质功能位点预测^[40-41]、预测蛋白质的类别（是否是酶、膜蛋白）^[42-46]等都属于蛋白质功能预测的范畴。

蛋白质亚细胞定位和预测蛋白质的类别一般都是从全局序列出发，利用全局序列信息，如氨基酸组成等。而预测信号肽剪切位点、蛋白质翻译后修饰位点、功能位点则一般利用的是局部的序列和结构信息。利用序列信息进行预测时，很自然想到相似的序列很可能具有相似的功能。实际上对序列进行同源型分析是预测蛋白质功能一个很重要也是经常使用的方法。但是，该方法显然有缺点，不是所有未知功能的蛋白都能找到同源性足够高的蛋白质。因此，近几年来，人们提出了一些并不直接依靠序列相似性的预测方法。第一种是利用通过 DNA 阵列^[46]和芯片技术得到的基因表达数据。基因在不同时间点或者组织类型中具有不同的表达模式，通过将相同表达模式的基因进行聚类，就可以根据这个类别中最常出现的基因功能，推断该类别其他未知功能的基因可能具有相同的功能。通过这种方法，可以预测序列相似性很小或者完全不相似的基因的功能。

第二种方法则是基于功能域融合模式的^[47-48]，其基本想法是，如果一个生物体中的两个蛋白质在另外一个生物中是作为一个多功能域蛋白质的不同单元存在，就表明即使这两个蛋白质在序列上没有足够的相似性，它们也很有可能具有相同的功能。

第三种方法是利用系统进化谱^[49]。在系统进化谱中，每个蛋白质用包含其同源蛋白质的生物体来表示。如果两个蛋白质具有相同（或非常相似）的系统进化谱，就表明它们通常可以一起观察到。这种现象一个可能的解释就是这两个蛋白质执行相似的功能。随着基因组数据不断增加，系统进化谱有望发挥更大作用。这种方法已经成功应用于酵母基因组，但在我们完成更多的多细胞生物的测序工作以前，这种方法对于人类蛋白质功能预测的作用非常有限。

RNA 负责着将遗传信息从 DNA 传到蛋白质的任务，为蛋白质的合成转运氨基酸，

是核糖体的重要组成部分。这些活动都是通过与蛋白质相互作用实现的。因此正确预测蛋白质与 RNA 的相互作用位点对于理解这些生命过程是至关重要的。本文主要利用局部的序列结构信息以及由 PSI-BLAST 产生的序列谱作为输入来预测蛋白质与 RNA 的相互作用位点,并且考虑了两种情况:已知序列信息和已知结构信息。膜蛋白可分成两种不同的结构类别: α -螺旋膜蛋白和 β -桶形膜蛋白。 β -桶形膜蛋白一般位于革兰氏阴性菌、线粒体和叶绿体的外膜。据估计 β -桶形膜蛋白占整个革兰氏阴性菌基因组编码的蛋白质的 2-3%。膜蛋白在细胞信号传导、选择性运输分子中扮演重要角色。本文主要利用全局序列信息来区分 β -桶形膜蛋白和球形蛋白。

1.5 常用的蛋白质结构和序列数据库

1.5.1 蛋白质序列数据库

(1) SWISS-PROT 数据库

SWISS-PROT 是含有详细注释内容的蛋白质序列数据库。SWISS-PROT 蛋白质序列数据库由大量序列条目组成。SWISS-PROT 涉及已知蛋白质的功能、序列(包括一些蛋白质片段的序列)、结构域(如跨膜区等)的结构、翻译后修饰(如磷酸化与去磷酸化等)及其位点、突变体等,目前已经收录了近 8 万个序列。通过它可以查询所需蛋白质的上述所有内容,从而指导进一步的实验。SWISS-PROT 还与其他一些数据库相链接,包括 PROSITE、SWISS-2DPAGE、SWISS-3D IMAGE、ENZYME、SWISS-MODEL、NCBI 的数据库等,因而可进行更为广泛的查询工作,如可通过关键词、SWISS-PROT 接受号、作者等进行查询。

(2) PIR 数据库

PIR 数据库是蛋白质信息资源数据库,其主要目的是提供按同源性和分类学组织的综合性、非冗余数据库。PIR 通过提供蛋白质序列数据库、衍生的相关数据库及相应的软件而支持有关分子进化、功能基因组学和计算生物学方面的研究,包括:①能够快速查询、比较蛋白质序列并对其进行特征序列的模式匹配;②可给出蛋白质的功能位点,如磷酸化、糖基化位点、与其他蛋白质的共有序列等;③可进行多种方式的序列比较,如对库比较、两两比较和多序列比较等。可通过关键词、特征序列或序列接受号等进行查询。

1.5.2 蛋白质结构数据库

(1) PDB 数据库

蛋白质的基本立体结构数据库为 PDB 1971 年建立于美国布鲁克海文国家实验室。该数据库中收集了通过 X 射线衍射和核磁共振 (NMR) 实验测定的蛋白质结构的精确坐标数据。这种数据即蛋白质中的原子坐标是蛋白质结构的最细微的层次。该数据库的管理者是结构生物信息学合作研究组织 (Research Collaboration for Structural Bioinformatics, RCSB, <http://www.rcsb.org>)。

(2) HSSP 数据库

HSSP 是根据同源性导出的蛋白质二级结构数据库。每一条 PDB 项目都有一个对应的 HSSP 文件。该数据库同时提供了 SWISS-PROT 数据库中所有蛋白质序列的同源性。其网址为: <http://www.sander.embl-heidelberg.de/hssp/>。

(3) 蛋白质结构分类数据库 (SCOP)

蛋白质结构分类数据库是对已知的蛋白质三维结构进行手工分类得到的数据库。将已知结构蛋白质进行有层次地分类。其网址为: <http://scop.mrc-lmb.cam.ac.uk/scop/>。

1.6 本文主要研究内容

(1) 提出了一个新的基于支持向量机的预测氢键 α 转角的方法。讨论了位置特异的进化信息和预测的二级结构信息对预测性能的影响。我们还开发了 AlphaTurn 在线服务。此外,我们还比较了三种处理不平衡数据集的方法,提出用二阶段法来处理不平衡数据集。

(2) 在氢键 α 转角预测的基础上首次对广义 α 转角的预测进行研究。广义 α 转角第 i 个残基与第 $i+4$ 个残基的 α 碳之间的距离小于 $6.5\text{\AA}$, 不一定包括氢键。该方法表现了良好的预测性能。

(3) 首次开发一个基于支持向量机的从氨基酸序列出发预测 π 转角的可靠方法。我们还开发了 PiTurn 在线服务。此外,我们还计算了 640 个非同源蛋白中 1931

个 π 转角的位置特异的氨基酸出现的频率，这有助于设计 π 转角。

(4) 综合使用支持向量机和 PSSMs 来预测蛋白质与 RNA 相互作用位点。我们考虑了两种情况，(1) 仅仅知道与 RNA 相互作用的蛋白质的序列信息。(2) 已知与 RNA 相互作用的蛋白质的结构信息。

(5) 使用了简单的信息离散性度量方法来区分 β -桶形膜蛋白和球形蛋白。此外，我们还用简并的氨基酸字符集测试了该方法。当氨基酸字符集减少到 15、12 和 10 时，总正确率下降的很少。这说明识别 β -桶形膜蛋白和球形蛋白所需的最小信息是 10 个字符。

2 分类器设计及性能评价方法

2.1 引言

生物信息学中的绝大多数预测问题都可归结为两大类问题，即分类和回归。回归问题和分类问题结构相同，不同之处仅在于它们的输出取值范围不同。在分类问题中，输出只允许取两个值（或有限个值），而在回归问题中，输出可取任一实数。

本文所讨论的工作均属于分类问题，涉及分类器的设计。分类器设计的一般步骤如下：

(1) 数据收集。采集到足够并且有代表性的数据是得到好的分类性能的前提。对于生物信息学中涉及分类问题中的数据收集主要注意的是数据的冗余问题，因为大多数数据库都存在数据冗余问题，既偏向某些蛋白质家族，所以在收集数据时，都要进行序列比对分析，去掉相似性很高的序列。

(2) 特征选择。根据特定的问题领域的性质，选择有明显区分意义的特征，是设计过程中非常关键的一步。在选择或设计特征的过程中，很显然，我们希望发现那些容易提取、对不相关变形保持不变、对噪声不敏感，以及对区分不同类别的模式很有效的特征集^[50]。具体到某个分类问题时还与编码方式有关，如本文第三、四和五章讨论的分类都用了局部窗口编码策略，于是便讨论了如何表示定长的窗口序列及其对预测性能的影响。而第六章对 β -桶形膜蛋白与球形蛋白质进行分类的工作所采用的输入信息是全局信息氨基酸组成，而这样便没有考虑序列信息，因此便需要考虑选择一些能包括序列信息的特征。

(3) 模型选择，即选择合适的算法。能用于分类的算法很多，比如贝叶斯方法、最近邻法、隐马尔可夫模型、神经网络法、支持向量机以及基于信息论的方法等。本章主要介绍一下在本文中用到的支持向量机算法和信息离散度算法。

(4) 训练和预测。一般说来, 利用样本数据来确定分类器的过程称为训练分类器。分类器确定好后就可以用来预测。

(5) 评价。多分类器的性能进行评价是设计分类器很重要的一步, 也是改进分类器性能的重要评价标准, 一般采取多个评价标准, 从不同角度对分类器性能进行评价。

本章主要介绍本文中用到的支持向量机、信息离散度方法, 以及分类器性能的评价方法。

2.2 支持向量机

支持向量机是 Vapnik^[55-56]等人提出的, 在解决以往困扰很多机器学习方法的问题, 比如模型选择与过学习问题、非线性和维数灾难问题、局部极小点问题、小样本、非线性及高维模式识别问题中表现出许多特有的优势^[49-54]。已经应用于手写体识别、三维目标识别、人脸识别、文本图像分类等实际问题中, 性能优于已有的学习方法, 表现出良好的学习能力。从有限训练样本得到的决策规则对独立的测试集仍能够得到较小的误差。

2.2.1 最优分类面

支持向量机方法是从线性可分情况下的最优分类面提出的。考虑图 2.1 所示的二维两类线性可分情况, 图中空心圆点和实心圆点分别表示两类训练样本, H 为把两类没有错误地分开的分类线, H_1 和 H_2 分别表示两类样本中距离分类线最近的点且平行于分类线的直线, H_1 和 H_2 之间的距离叫作两类的分类空隙或分类间隔。所谓最优分类线就是要求分类线不仅能将两类无错误地分开, 而且要使两类空隙最大。前者是保证经验风险最小, 而后者是使真实风险最小。推广到高维空间, 最优分类线就成为最优分类面。

假定训练数据 $(x_1, y_1), \dots, (x_l, y_l)$, $x \in \mathbb{R}^n$, $y \in \{+1, -1\}$ 是类别标号。d 维空间中线性判别函数的一般形式为 $g(x) = w \cdot x + b$, 分类面方程为:

$$(w \cdot x) - b = 0 \quad (2.1)$$

我们将判别函数进行归一化, 使两类样本都满足 $|g(x)| \geq 1$, 即使离分类面最近的样本的

$|g(x)|=1$ ，这样分类间隔就等于 $2/\|\mathbf{w}\|$ ，因此使间隔最大等价于使 $\|\mathbf{w}\|$ 最小，而要求分类线对所有样本都正确，就是要求它满足

$$y_i(\langle \mathbf{w} \cdot \mathbf{x}_i \rangle + b) - 1 \geq 0 \quad (2.2)$$

因此，满足上述条件且使 $\|\mathbf{w}\|$ 最小的分类面就是最优分类面。过两类样本中离分类面最近的点且平行于最优分类面的超平面 H_1 和 H_2 上的点就是使式 2.2 中等号成立的那些样本，叫做支持向量，因为它们支撑了最优分类面。如图 2.1 中用圆圈标出的点。




图 2.1 最优分类面示意图^[50]

那么，如何求最优分类面呢？可将求使间隔最大的最优超平面问题转化为下列不等式约束问题：

$$\begin{aligned} & \text{minimize} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\ & \text{subject to} \quad - (y_i(\langle \mathbf{w} \cdot \mathbf{x}_i \rangle + b) - 1) \leq 0 \end{aligned} \quad (2.3)$$

将该优化问题转化为相应的对偶问题，定义 Lagrange 函数：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \langle \mathbf{w} \cdot \mathbf{w} \rangle - \sum_{i=1}^n \alpha_i \{y_i(\langle \mathbf{w} \cdot \mathbf{x}_i \rangle + b) - 1\} \quad (2.4)$$

其中， $\alpha_i \geq 0$ 为 Lagrange 系数。通过对相应的 $\mathbf{w}$ 和 b 求偏导，可找到相应的对偶形式：

$$\begin{aligned}\frac{\partial L(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} &= 0 \\ \frac{\partial L(\mathbf{w}, b, \alpha)}{\partial b} &= 0\end{aligned}\quad (2.5)$$

将得到关系式：

$$\begin{aligned}\mathbf{w} &= \sum_{i=1}^l y_i \alpha_i \mathbf{x}_i \\ \sum_{i=1}^l y_i \alpha_i &= 0\end{aligned}\quad (2.6)$$

代到原始的 Lagrange 函数，得到：

$$L(\mathbf{w}, b, \alpha) = \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i,j=1}^l y_i y_j \alpha_i \alpha_j \langle \mathbf{x}_i \cdot \mathbf{x}_j \rangle \quad (2.7)$$

假定参数 α^* 是下面的二次优化问题的解：

$$\begin{aligned}\text{maximize } w(\alpha) &= \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i,j=1}^l y_i y_j \alpha_i \alpha_j \langle \mathbf{x}_i \cdot \mathbf{x}_j \rangle \\ \text{subject to } &\sum_{i=1}^l y_i \alpha_i = 0 \\ &\alpha_i \geq 0 \quad i = 1, \dots, l\end{aligned}\quad (2.8)$$

则最优解 $\mathbf{w}^* = \sum_{i=1}^l y_i \alpha_i^* \mathbf{x}_i$ 实现了几何间隔为 $1/\|\mathbf{w}^*\|_2$ 的最大间隔超平面。

利用原始约束条件可以找到 b^* ：

$$b^* = -\frac{\max_{y_i=-1}(\langle \mathbf{w}^* \cdot \mathbf{x}_i \rangle) + \min_{y_i=+1}(\langle \mathbf{w}^* \cdot \mathbf{x}_i \rangle)}{2} \quad (2.9)$$

根据 Karush-Kuhn-Tucker 互补条件，最优解 $\alpha^*, (\mathbf{w}^*, b^*)$ 必须满足：

$$\alpha_i^* [y_i(\langle \mathbf{w}^* \cdot \mathbf{x}_i \rangle) - 1] = 0 \quad i = 1, \dots, l \quad (2.10)$$

这就意味着函数间隔不为 1 的向量 $\mathbf{x}_i$ ，其对应的 α_i^* 为零。因此只有函数间隔为 1 的输入点 $\mathbf{x}_i$ 对应的 α_i^* 可能非零。因此最优解 $\mathbf{w}^*$ ，仅仅依靠非零的 α_i^* 的输入点支持，其值

也只依靠这些非零的 α_i^* 的输入向量的加权和。

求解上述问题后得到的最优分类函数是

$$f(x) = \text{sgn}\{(w^* \cdot x) + b^*\} = \text{sgn}\left\{\sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x) + b^*\right\} \quad (2.11)$$

2.2.2 核与特征空间

在实际分类中，分类样本不总是线性可分的。要使用线性分类器进行分类，通常情况下是将原有的输入空间转换为线性可分的特征空间，再进行分类。一种普通的处理方式如下：

$$\mathbf{x} = (x_1, \dots, x_n) \mapsto \Phi(\phi_1(\mathbf{x}), \dots, \phi_N(\mathbf{x})) \quad (2.12)$$

其等价于将输入空间 X 映射到一个新的空间， $F = \{\Phi(\mathbf{x}) | \mathbf{x} \in X\}$ 。

这种处理方式解决了复杂非线性分类问题，提供了线性分类的解决方法。但是，将输入空间映射到特征空间后，特征空间往往变成了一个高维空间，致使分类的计算性能和泛化性能降低，即所谓的“维数灾难”。而且在高维空间，因为可能的冗余特征集，可能引起过拟合问题。因此需要维数约减或主分量分析等方法，减少这些负面影响。

假设上述特征空间的线性分类函数：

$$f(\mathbf{x}) = \sum_{i=1}^N \mathbf{w}_i \phi_i(\mathbf{x}) + b \quad (2.13)$$

这意味着建立非线性学习器分为两个步骤：首先使用一个非线性映射将数据变换到特征空间 F ，然后再在这个特征空间使用线性分类器分类。

线性学习器的一个重要性质可以表达为训练点的线性组合，因此决策规则可以用测试点和训练点的内积来表示：

$$f(\mathbf{x}) = \sum_{i=1}^l \alpha_i y_i \langle \phi_i(\mathbf{x}_i) \cdot \phi_i(\mathbf{x}) \rangle + b \quad (2.14)$$

若定义核函数 K ，对所有 $\mathbf{x}, \mathbf{z} \in X$ ，满足：

$$K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}) \cdot \phi(\mathbf{z}) \rangle \quad (2.15)$$

ϕ 是从输入空间 X 到特征空间 F 的映射。则可直接计算特征空间的内积 $\langle \phi_i(\mathbf{x}_i) \cdot \phi_i(\mathbf{x}) \rangle$ ，这将上述建立非线性分类器的两个步骤合二为一。

若 $K(\mathbf{x}, \mathbf{z})$ 隐式定义的特征空间是线性可分的，假定参数 α^* 和 b^* 是下面二次优化问题的解：

$$\begin{aligned} & \text{maximise} \quad W(\alpha) = \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i,j=1}^l y_i y_j \alpha_i \alpha_j K(x_i, x_j) \\ & \text{subject to} \quad \sum_{i=1}^l y_i \alpha_i = 0 \\ & \quad \quad \quad \alpha_i \geq 0 \quad i=1, \dots, l \end{aligned} \quad (2.16)$$

则决策函数由 $\text{sgn}(f(x))$ 给出，这里 $f(x) = \sum_{i=1}^l y_i \alpha_i^* K(\mathbf{x}_i, \mathbf{x}_j) + b^*$ 等价于核函数 $K(\mathbf{x}, \mathbf{z})$ 隐式定义的特征空间中的最大间隔超平面。

当核函数满足 Mercer 条件，可确保最大间隔优化问题有唯一的解并能有效得到。

常用核函数有：

线性核： $K(x, x') = x^T x'$

多项式核： $K(x, x') = (\lambda x^T x' + \gamma)^d$

高斯核： $K(x, x') = e^{-\frac{\|x-x'\|^2}{2\sigma^2}}$

S 型核： $K(x, x') = \tanh(\lambda x^T x' + \gamma)$

其中， λ, γ, σ 为核参数。

2.2.3 软间隔优化

最大间隔分类器是分析与构造更加复杂支持向量的起点。如果数据存在噪声，即使在特征空间中也无法使用线性分类器进行分类。这时若使用特别强的核，则有可能导致过拟合。最大间隔分类器总是完美的产生一个没有训练误差的一致性假设。当间

隔为负值时，数据是线性不可分的。

引入松弛因子，允许式 2.3 描述的优化问题在一定程度上违反间隔约束：

$$\begin{aligned} \text{subject to } & y_i(\langle \mathbf{w} \cdot \mathbf{x}_i \rangle + b) \geq 1 - \xi_i \quad i = 1, \dots, l \\ & \xi_i \geq 0 \quad i = 1, \dots, l \end{aligned} \quad (2.17)$$

这可通过求解下面的优化问题求解：

$$\begin{aligned} \text{minimise}_{\xi, \mathbf{w}, b} & \langle \mathbf{w} \cdot \mathbf{w} \rangle + C \sum_{i=1}^l \xi_i^2 \\ \text{subject to } & y_i(\langle \mathbf{w} \cdot \mathbf{x}_i \rangle + b) \geq 1 - \xi_i \quad i = 1, \dots, l \end{aligned} \quad (2.18)$$

实践中，参数 C 是一个变化范围大的值，优化性能的评价是通过使用独立的检验集或一种称为交叉验证的技术。参数 C 在一定的范围变化， $\|\mathbf{w}\|_2$ 会有相应的联系变化。

因此，对待特定问题，选择 C 值对应选择 $\|\mathbf{w}\|_2$ 的值，然后在 $\mathbf{w}$ 下最小化 $\|\xi\|_2$ 。

2.3 信息离散性度量方法

信息离散性度量方法是我国的方伟武教授在研究多信息源的差异时提出的 [57][58][59][60]。信息离散性度量方法的核心是引入了全信息集合的概念，它包含了一条序列所有的结构信息。关于全信息集合的概念如下所示。

假设 $\Sigma = \{a_1, a_2, \dots, a_m\}$ 是包含 m 个字符的集合， $\Omega = \{S_1, S_2, \dots, S_s\}$ 是由该字符集的字符形成的序列集。 Θ^l 表示由 Σ 字符集合中的字符形成的长度为 l 的子序列的集合。很容易看出 Θ^l 中的子序列数是 m^l 。对于一个长度为 L_k 的序列 $S_k \in \Omega$ ，假设 $n_{ik}^l (l \leq L_k)$ 表示 S_k 中连续子序列数，显然， $\sum_{i=1}^{m^l} n_{ik}^l = L_k - l + 1 (l \leq L_k)$ ，并且 $P_{il}^l = n_{ik}^l / (L_k - l + 1)$ ，这样，我们得到一个分布：

$$U_k^l := (p_{1k}^l, p_{2k}^l, \dots, p_{m^l k}^l)^T$$

其中， $\sum_{i=1}^{m^l} p_{ik}^l = 1 (l \leq L_k)$ ，T 是转置操作。定义 Γ^l 是所有满足 $\sum_{i=1}^{m^l} p_{ik}^l = 1$ 的分布的集合，即

$$\Gamma^l := \{(p_{1k}^l, p_{2k}^l, \dots, p_{m^l k}^l)^T \mid \sum_{i=1}^{m^l} p_{ik}^l = 1, p_{ik}^l \geq 0\} \quad l=1, 2, 3, \dots \quad (2.19)$$

因此，对每一个序列 S_k ，我们可以得到一个唯一的分布：

$$(U_{s_k}^1, U_{s_k}^2, \dots, U_{s_k}^k), U_{s_k}^l \in \Gamma^l, (l=1, 2, 3, \dots, L_k) \quad (2.20)$$

这个集合包含了 s_k 的所有结构信息，因此它被称为 s_k 的全信息集合。显然，任何不同的序列都有不同的全信息集合，反之亦然。

对于蛋白质，字符集是 20 中氨基酸，即

$$\Sigma = \{A, C, D, E, F, G, H, I, K, L, M, N, P, Q, R, S, T, V, W, Y\}.$$

对于一个长度为 L 的蛋白质，给定子序列的长度为 1，于是这个蛋白质的子序列分布是：

$$U_s^l = (p_1^l, p_2^l, \dots, p_{20^l}^l)^T, \text{ 其中 } \sum_{i=1}^{m^l} p_{ik}^l = 1 (1 \leq L) \quad (2.21)$$

当 $l=1$, $U_s^1 = (p_1^1, p_2^1, \dots, p_{20}^1)^T$ 则是常规的氨基酸组成，当 $l=2$, $U_s^2 = (p_1^2, p_2^2, \dots, p_{20^2}^2)^T$ 包含所有一阶信息，即二肽组成信息。有很多序列有相同的氨基酸组成，因为 $l=1$ 时，没有包含任何序列信息。但是，当 l 等于和大于 2，则亚序列分布集考虑了序列信息。不同的序列有相同的亚序列分布的几率很小，因为邻接的亚序列必须有 $l-1$ 个残基重叠。显然，当增加亚序列的长度，可以唯一确定一个序列。

给定 s 个序列，则它们长度为 1 的亚序列分布是：

$$\begin{aligned} U_{s_1}^l &= (p_{11}^l, p_{21}^l, \dots, p_{m^l 1}^l) \\ U_{s_2}^l &= (p_{12}^l, p_{22}^l, \dots, p_{m^l 2}^l) \\ &\dots \\ U_{s_s}^l &= (p_{1s}^l, p_{2s}^l, \dots, p_{m^l s}^l) \end{aligned} \quad (2.22)$$

信息离散性度量定义为：

$$B_k(U_{s_1}^l, U_{s_2}^l, \dots, U_{s_s}^l) = \sum_{i=1}^{20^l} p_{ik}^l \log \frac{p_{ik}^l}{\sum_{j=1}^s p_{ij}^l / s} \quad (2.23)$$

分别定义 $0 \log 0 = 0$ 和 $0 \log (0/0) = 0$ 。 $B_k(U_{s_1}^l, U_{s_2}^l, \dots, U_{s_s}^l)$ 表示第 k 条序列与组中所有其他序列的差异度量。

2.4 分类器性能评价

当用样本数据确定了分类器,即得到决策函数 $f(x)$ 后,要对该分类器的性能进行评价,就要看对于新的输入(即不是训练样本的输入),根据决策函数推断出它所在的类别 $f(x)$,是否与它真正所属类别一致。这就促使我们用如下方法来评价一个分类器的性能,即把训练样本分成两部分,用其中一部分作为训练集,而余下的部分作为测试集。根据训练集,用选好的分类算法求出决策函数,而用测试集测试所得的决策函数,从而评价分类器的优劣。

k -折交叉验证是评价分类器性能的常用方法。它首先把 s 个样本点随机分成 k 个互不相交的子集,每个折的大小大致相等,共进行 k 次训练和测试,再用相应的参数进行评价。在实际中, k 常有两种取法。第一种是取 $k=s$,每次迭代留下一个样本点作为测试点,称为留一法,这种方法有时计算量很大,并不常用。另一种是取 $k=t$, t 常取 10、7、5 等,分别称为 10-折交叉验证、7-折交叉验证和 5-折交叉验证。分类器性能评价参数有多种,针对不同的问题可以选择不同的参数,将在后面的章节中具体介绍。

2.5 本章小结

本章主要介绍了本文中用来构建分类器的两种算法:支持向量机和信息离散性度量方法。支持向量机在解决以往困扰很多机器学习方法的问题,比如模型选择与过学习问题、非线性和维数灾难问题、局部极小点问题、小样本、非线性及高维模式识别问题中表现出许多特有的优势。信息离散性度量方法的主要优点是实现起来非常简单,计算所需时间很短。

3 氢键 α 转角预测

3.1 引言

蛋白质结构即包括重复的二级结构： α 螺旋和 β 折叠，也包括非重复的二级结构，如转角和随机卷曲。 α 螺旋和 β 折叠是蛋白质结构中两种比较经典的组分，构成复杂蛋白质结构的主体，并且它们在蛋白质中的含量也是划分蛋白质结构类别的基础，所以他们已经得到充分的研究。在过去的几十年中，世界各地的许多研究小组已开发出各种各样的方法来预测 α 螺旋和 β 折叠结构以及它们在蛋白质中的含量，并已经取得较高的预测精度。然而，在过去的几十年中，却极少有方法预测转角。实际上，无论从结构还是功能的角度看，转角都发挥着至关重要的作用，（1）如果没有转角的帮助，多肽链便无法折叠成球形结构，（2）转角一般位于蛋白质分子的表面，因此与分子识别有关；（3）转角提供了设计新药的模板结构非常有用的信息。

α 转角包含五个氨基酸残基，由第 i 个残基的羰基 O 与 $i+4$ 个残基的氨基质子形成的氢键稳定。最近，Dasgupta^[5]等将 α 转角的定义扩展为第 i 个残基与第 $i+4$ 个残基的 α 碳之间的距离小于 $6.5\text{\AA}$ 。 π 转角是一段包括 6 个残基的肽段，第 i 个残基的羰基 O 和第 $i+5$ 个残基的氨基质子之间有一个氢键。

与 β 转角相比，关于 α 转角的研究较少，这主要是由于 α 转角在蛋白质中的含量较低。在已经测得结构的蛋白质数量较少的情况下，研究含量较低的 α 转角显然不合适，但随着越来越多的蛋白质结构的测定，对 α 转角的研究也逐渐开展。

最早较详细的关于 α 转角的研究是 Pavone et al.^[65]的工作，他们系统研究了 193 个蛋白质中 395 个独立的 α 转角。这项研究揭示了 α 转角主要由亲水氨基酸组成，也显示这些结构不仅暴露于溶剂中，而且以钩子形状突出伸向蛋白质外表面，因此这些结构可能会在蛋白质相互作用中发挥作用。

α 转角在蛋白质折叠与分子识别中都扮演了重要作用。在人的溶解酵素蛋白中， α 转角参与一个氢键的聚集，并位于活性位点，显示其与蛋白质功能的关系。铁氧

化还原蛋白的第 35—39 个残基形成 α 转角结构。其上的 cys 位于金属离子结合位点。在 T-细胞表面的糖蛋白中，第 51—55 个残基形成 α 转角结构，并且位于艾滋病病毒 gp120 蛋白与 T-细胞表面的糖蛋白的结合位点区域。综上所述， α 转角尽管在蛋白质中含量较低，却经常包含分子识别的重要信息。因此，开发从氨基酸序列预测 α 转角结构的方法是很有意义的。

预测 α 转角始于 Chou^[67]的工作。他设计了一个基于马尔科夫理论的统计方法来预测 α 转角及 α 转角的类型。Cai^[68]等用支持向量机预测了 α 转角的类型。最近，Kaur H.^[69]用人工神经网络、Weka(Waikato Environment for Knowledge Analysis)、PEBLS(Parallel Exemplar Based Learning)和基于马尔科夫理论的统计方法来预测 α 转角，结果发现使用神经网络方法结合位置特异的进化信息和预测的二级结构信息作为输入取得最好的预测性能。以上方法使用的数据集都是 Pavone et al. 在 1996 年收集的。

本文提出了一个新的基于支持向量机的预测 α 转角的方法。讨论了位置特异的进化信息和预测的二级结构信息对预测性能的影响。结果显示当使用相同的输入信息时，本方法表现出更好的预测性能。当使用位置特异的进化信息和预测的二级结构信息作为输入，并使用相同的数据集和相同的 5—折交叉验证，该方法取得的 MCC 为 0.26，比到目前为止最好的方法取得的 MCC 值要高 0.1。此外，我们还比较了三种处理不平衡数据集的方法。

3.2 试验数据和方法

3.2.1 试验数据

用来预测 α 转角的蛋白质是从 pdbselect^[66](2005 年 10 月版)数据集中选取的。任何两条蛋白质链之间的同源性小于 25%。选取蛋白质的规则如下：蛋白质结构必须是用 X—射线衍射法测定的，测定精度大于 2.0Å，R 系数小于 0.23，并至少包含一个 α 转角。我们使用如下原则确定 α 转角。选择第 I 个残基的羰基与第 $I+4$ 个残基的氨基质子形成的氢键的五肽，氢键的确定使用 Kabsch 和 Sander 的 DSSP^[6]中使用的规则，即 C_iO_i 与 HN_{i+4} 偶极子之间的静电势能小于 -0.5kcal/mol 。去掉中间残基属于螺旋结构（即 DSSP 定义的二级结构中的 G 和 H）的五肽。二级结构使用 DSSP 软件确定。

经过这些规则的过滤后，我们得到 469 个蛋白质，这 469 个蛋白质中共包含 967 个 α 转角。形成 α 转角的残基数占 469 个蛋白质总的残基数的 4.9%。平均来说，每个蛋白质有 2 个 α 转角。469 个蛋白质的 PDB 代码见表 3.1。967 个氢键 α 转角见附表 1。

表 3.1 用于预测氢键 α 转角的蛋白质的 PDB 码

1N55A	1SFDA	1Q7LA	1RG8A	1OBDA	1SWXA	1XDWA	1JIDA	1FLTX	1URSA	1ZDYA	1JG8C
1DS1A	1TT8A	1HD2A	1SU8A	1UUYA	1Y63A	1ICFI	1YWMA	1YY6A	1SI6X	1FL0A	1GPIA
1US0A	1GKMA	1X6ZA	1XODB	1LRIA	1XVYA	1SR4A	1E6IA	1FVKA	1V4PC	1TH7A	1RDQE
1SSXA	1GA6A	1KTHA	1XMTA	1W1HB	1QWDA	1VKYA	1SQ9A	1DSZA	1OQQA	1MK4A	1WDVA
1M40A	1QTWA	1M1QA	1GU2A	1VM9A	1XU1S	1FS9A	1YROD	1MXIA	1SX5A	1XAKA	1USPA
1GWEA	1R2QA	1P1XB	1NWWB	1DJ0A	1O94D	1I24A	1Z6OX	1NRJA	1JOVA	1X8BA	1Z3XA
1KWFA	1FSGA	1R2MA	1E29A	1QWOA	1Z2NX	1OBOA	1WDCA	1NTYA	1B8ZA	1JYOA	1ZXUA
1X8QA	1SX7A	1CC8A	1KYFA	1VHWE	1CSEI	1ES9A	1OTKA	1IGQA	1IT2A	1X9RB	1HRUA
1MC2A	1W23A	1EUWA	1K3XA	2BEMA	2TPSA	1KGDA	1RLJA	1R77B	1MAVA	1XXMC	1G55A
1N4WA	1UWCA	1M2DA	1S3CA	1K92A	1QKSA	1PB7A	1AOCA	1MWPA	1OU8A	1IKOP	1WKCA
1IQZA	1K5NA	1QLWA	2BJIB	1OOYA	1HYOA	1PZ4A	1QG7A	1V54K	1HXRA	1ZB1A	1Y71A
1EB6A	1I40A	1F86A	1FLMA	1TW6B	1O8XA	1RYQA	1USCA	1V54J	1UEBB	1WMXA	1O1XA
1VYYA	1HBNB	1LS1A	1GK9A	1KP6A	1P4CA	1F8EA	1UCDA	1V54L	1VJ2A	1Y96D	1RW1A
1JFBA	1M1NB	1TUKA	1GK9B	1QZNA	1KUFA	1JUBA	1PWBC	1NO5B	1OA8A	1S14B	1VMGA
1SFSA	1M1NA	1N8KA	1WVFA	1O4TA	1KV7A	1EW4A	1G8AA	2BFXD	3HTSB	1Z5ZA	1EAQB
1C5EA	1C9OA	1U07B	1J2RA	1D5TA	1TZPB	1YC5A	1NYCA	1E1HD	1RGXC	1EAYD	1S9UA
1ME4A	1H97A	1VZIA	1QOPB	1TJXA	1S0PA	1HZTA	1V7RA	1PK6A	1UUZA	1P9GA	1YQHA
1M4LA	1UBKS	1ODMA	1X9DA	1RA0A	1U4GA	1HLQC	2TNFA	1QFOA	1LC7A	1I1WA	1Y0UA
1PQ7A	1M15A	1E9GA	1RJUV	1VFYA	1UQ5A	1SMOB	1MNNA	1R75A	1SC3B	1HX0A	1NU0B
1PJXA	1WM3A	1CZPA	1O4YA	1TQWA	4EUGA	1RKUA	1C1KA	1XIWB	1Y02A	1MJUH	1YR0A
1G6XA	1MJUL	1UWKB	1MG4A	1UAIA	1KS8A	1PVMA	1IS3A	1BXYA	1CQ3A	1J98A	1FG7A
1IX9A	1OQVA	1O08A	1OFNA	1QTNB	1M7GD	1ELKA	1D7PM	1FX4A	1T15A	1I8OA	1YB3A
1G66A	1O7QA	1RMWA	2BO9D	1VIMC	1F7LA	1LK9B	1P1MA	1I8AA	1QA7A	1PQHA	1UARA
1MJ5A	1BQCA	1J08A	1SYYA	1EAZA	1X91A	1OQJB	1LMIA	1V83A	1Y7PB	1K55C	1LXJA
7A3HA	1LKKA	1W2LA	1R4PA	1R26A	3EZMA	1EUVA	1SJ1A	1UW1A	1I1WA	1NZ0B	1WGBA
1K5CA	1CXQA	1DG6A	1JKUA	1I71A	1UXAB	1RC9A	1IV3A	1UW4B	1XB9A	1QQFA	1NJHA
1O7JA	1LQTB	1WPNA	1ZK4A	1ZKKB	2ARCB	1B5EA	1MG7A	1LDDA	1JHSA	1Z67A	1RO7A
1PWGA	1KMVA	1E7LA	1L3KA	1XD3C	1M65A	1NC5A	1W4SA	1BYSA	1LHVA	1Y1JX	1QU9A
1JM1A	1XJUB	1GYXA	1H4AX	1Z1SA	1RKIA	1D0DA	3PVIA	1TXJA	1UISA	1QPAA	1IZMA
1K7CA	1T8KA	1EAJA	1FYEA	1T61A	1XG4B	1PYOD	1JATB	1HG2A	1MI8A	1WRRR	
1P6OB	2BHUA	1LLFA	2BMOA	1UV4A	1KQFB	1CXYA	1O26A	2BKQC	1EL6A	1W2WB	
1OJRA	1QL0A	1K0MA	2BMOB	1YBIA	1KQFC	1IBYA	1ID0A	1PY0A	1RW0A	1Y6XA	
1WB4A	1GWMA	1Q92A	1JNIA	1YN9C	1KICB	1F60B	1MK0A	1UUTA	1RYOA	1YG9A	
1NOFA	1KNMA	1OCYA	1RUTX	1DQZA	1X6OA	1J2LA	1UD9D	1JF8A	1F9VA	1K3IA	
1NWZA	1LB3A	1HT6A	1TJYA	1T1UA	2BJFA	1PFVA	1GCQC	1OXDA	1VD6A	1J17A	
1OEWA	1MFGA	1RP0A	1V9YA	1DK8A	1YMKa	2BIIB	1DQIA	1USMA	1PINA	1O3UA	
1VYRA	1KA1A	1XM8A	1V0WA	1P5ZB	1EW2A	1GXYA	1S5UG	1H2WA	1QGVA	1XIYB	
1LUGA	1G61A	1VKBA	1VKKA	1TQJC	1XEDE	1O5FL	1KZQA	1IE9A	1JY2R	1H32A	
1F94A	1R29A	1YFQA	1M1FB	1S95A	1REGY	1JH6A	1H75A	1ES5A	1JY2P	1V54G	
1UG6A	1GXMB	1YS1X	1LTZA	1T92A	1B2VA	1LMB3	1HTWA	1GP0A	1JY2N	1DOWB	

为了方便与其它预测方法进行比较,我们还使用了另一个数据集,即 Pavone 数据集。该数据集有 193 个蛋白质,356 个 α 转角。形成 α 转角的残基数占总的残基数的 3.7%。

3.2.2 PSI-BLAST 谱

PSI-BLAST^[75]利用迭代的 BLAST 搜索方法以增加发现的进化关系的数目,图 3.1 列出了该种方法的原理。最初对查询序列进行 BLAST 搜索。接着把这次查找得到的每一击中项(高于选择的 E 值的选项)作为 BLAST 搜索第二次迭代的查询序列。第二次迭代应该找到比最初查询序列更多的进化关系,重复这个过程直到找不到有意义的相似序列为止。经过多次迭代,应该可以找到比初次查询更多的疏远关系;这个过程是通过利用中间序列的信息来实现的。序列 A 和 C 间的进化关系也许不能被 BLAST 发觉;但如果序列 A 和中间序列 B 的进化关系可以被发现,且 B 和 C 又存在进一步的关系的话,就可以推断序列 A 和 C 是有关系的。

图 3.1 数据库(序列空间)中的每条序列由外圈内的一点表示,查询序列由一个大的黑点表示。点间距离与序列的进化距离成正比,相邻点代表序列密切相关。以查询序列为圆心的虚线圈内的序列是查询序列的同源序列,也是相似性搜索的发现目标。小虚线圈内的十字符号代表一次普通 BLAST 查找得到的查询序列的相似序列(击中项)。该虚线圈上附着的小圆弧代表以第一次 BLAST 搜索得到的击中项作为查询序列进行第二次 BLAST 搜索找到的进一步的同源序列,这次使用的查询序列标记为 x。通过这种方法,第一次和后续 BLAST 搜索得到的击中项可以用来扩展原始查询序列进化关系的覆盖面积。

使用 PSSMs 代替单序列信息进行输入特征向量的编码能提高预测性能最早是由 JONES 等在预测规则二级结构时提出的。我们使用 PSI-BLAST 来产生序列谱。首先从 <ftp://ftp.ncbi.nlm.gov/blast/db/> 下载非冗余的蛋白质序列数据集。该数据集包括所有已知的数据库: GenBank translations, PDB, SWISSPROT, PIR 和 PRF。随后用 PFLIT^[14]软件将所有低复杂度区域、coiled coil 片断,以及跨膜片断过滤。最后使用 PSI-BLAST 对该数据集进行 3 次迭代搜索, E 值取 0.001, 产生 PSSM。




图 3.1 PSI-BLAST 基本原理^[76]

3.2.3 输入特征编码策略

无论采用什么样的预测方法，输入量的编码表示形式十分重要。如果编码表示形式选择得当，能够揭示特定问题的本质，那么问题或多或少可以得到解决，或至少可采用简单的线性方法得以解决。很明显，如果输入的编码表示形式没有增加非线性程度，则问题容易处理得多。

在许多序列分析中，输入常取长度为 W 的窗，这个窗覆盖了一个或几个相关序列片断。一般来说，窗的位置是对称的，以保证上游和下游序列具有相同的长度。但在个别案例中，使用不对称窗要比使用对称窗的效果好。比如在识别信号肽剪切位点和 mRNA 前体中内含子剪接位点时，使用不对称窗就比使用对称窗的效果好得多。本研究中，我们采用了经典的描述蛋白质局部序列信息的移动窗口编码策略，即输入为固定长度的一段序列。当仅使用单个序列的信息作为输入时，对 20 种氨基酸使用正交编码，这种编码表示形式的优点在于不引入任何单体间的代数相关。每一种氨基酸都用 20 维的向量（19 个 0，1 个 1）来表示，例如，Ala = (1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0)，Cys = (0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0)，等等。但是对一条序列两端的残基编码时，会出现所谓的空缺残基，对这样的残基，我们将其表示为 20 个零组成的向量。而当用多序列联配信息作为输入时，我们使用由 PSI-BLAST 产生的 PSSMs 作为输入，并且使用与 PSIPRED 生成 PSSMs 相同的参数设置，PSSMs 的元素通过方程 3.3 进

行归一化处理:

$$f(x) = \frac{1}{1 + \exp(-x)} \quad (3.1)$$

通过 PSIPRED 预测的二级结构信息使用如下编码: 螺旋→(1, 0, 0), 折叠→(0, 1, 0), 无规卷曲→(0, 0, 1)。移动窗口的大小对预测性能有一定影响, 本文使用以前预测氢键 α 转角已经优化了的窗口长度 11。这样输入的信息是 223 维。

3.2.4 预测的可信度

预测可信度(RI)是对用机器学习方法预测的结果进行评价的一个很重要的指标。通过分析预测可信度可以很容易识别预测结果高度可靠的区域。预测可信度采用与 Hua^[20] 相似的定义:

$$RI = \begin{cases} 0 \\ \text{int}(abs(D)/0.2) \\ 9 \end{cases} \quad (3.2)$$




图 3.2 预测可信度与预测敏感度和特异度的关系

D 是样本点到最优超平面的距离, 它是预测可靠性的非常有效的指标。预测可信

度与预测敏感度和特异度的关系见图 3.2。从图 3.2 可以看出，当预测可信度小于 2 时，预测敏感度和预测特异度都受“state-shifting”过滤规则的影响，提高了预测的敏感度，降低了预测的特异度。当预测可信度大于 2 时，可信度越高，预测的特异度越高。而当预测可信度大于 5 时，预测的敏感度很低，这主要与数据集不平衡和支持向量机优化总的正确率有关。

3.2.5 预测后过滤

因为支持向量机优化总的正确率，而非 α 转角残基数远多于 α 转角残基数，所以对非 α 转角残基的预测正确率要远高于对 α 转角残基预测的正确率。因此，我们引入了一个由 Shepherd^[79]提出的被称为“state-shifting”的过滤规则。它将改变预测可信度低于某一门槛值的残基的预测状态。在使用“state-shifting”规则时，我们直接使用 D（样本点到最优超平面的距离）来表示预测可信度，因为 D 能给出比 RI 更加精细的门槛值。例如，NT<0.1 表示将所有 D 的绝对值小于 0.1 的非 α 转角预测转变成 α 转角预测。

因为 α 转角是 5 肽，但是预测是对每个残基进行的，没有考虑残基间的相关性。所以，我们引入了另一个与 Shepherd^[79]提出的被称为“state-flipping”规则相似的过滤规则。首先，将所有孤立的非 α 转角预测转变成 α 转角预测；其次，将所有孤立的 α 转角预测、孤立的连续 2 个 α 转角预测、孤立的连续 3 个 α 转角预测都转变成非 α 转角预测；最后，对于孤立的连续 4 个 α 转角预测，则将相邻的具有较低的预测可信度的非 α 转角预测转变成 α 转角预测。

3.2.6 预测性能评价参数

预测性能是通过 7-折交叉验证来进行评价的。将数据集随机分成大小近似相等的 7 组。SVM 分类器用其中的 6 组进行训练，剩下的一组进行测试。该过程将进行 7 次，每一次使用一组不同的测试集。为了评价预测性能，我们使用四个常用来对转角预测性能进行评价的指标：（1） Q_{total} ，用来表示总的预测正确率；（2） $Q_{\text{predicted}}$ 用来表示预测的灵敏性；（3） Q_{observed} 用来表示预测的选择性；（4）MCC 可同时表示预测的灵敏性和选择性，用它反映预测性能有较好的鲁棒性。

$$Q_{\text{total}} = \frac{p+n}{t} \times 100 \quad (3.3)$$

$$Q_{\text{predicted}} = \frac{p}{p+o} \times 100 \quad (3.4)$$

$$Q_{\text{observed}} = \frac{p}{p+u} \times 100 \quad (3.5)$$

$$\text{MCC} = \frac{pn - ou}{\sqrt{(p+o)(p+u)(n+o)(n+u)}} \quad (3.6)$$

其中 p 是被正确预测的 α 转角残基数, n 是被正确预测的非 α 转角残基数, o 是非 α 转角残基被预测为 α 转角残基数, u 是 α 转角残基被预测为非 α 转角残基数, t 是所有残基总数。

另外, 还有一个参数 S 将该方法与随机预测进行比较:

$$S = \frac{(p+n) - R}{t - R} \times 100 \quad (3.7)$$

其中,

$$R = \frac{(p+o)(p+u) + (n+u)(n+o)}{t} \quad (3.8)$$

R 反映通过随机预测能正确预测的残基总数。S=100%表示一个完美的预测, S=0%表示该预测与随机预测一样。

3.3 结论与讨论

3.3.1 α 转角位置特异的氨基酸倾向性研究及类别分析

本研究使用的数据集远大于 Pavone(1996)的数据集, 所以重新计算一下大的数据集中 α 转角的位置特异的氨基酸倾向性等统计特征是十分有意义的。计算位置特异的氨基酸倾向性的公式如下:

$$P_{i,j} = \frac{n_{i,j}/n_i}{N_j/N_t} \quad (3.9)$$

其中 $n_{i,j}$ 是 20 种氨基酸中特定氨基酸 i 在 α 转角的给定位置 j 出现的次数, n_i 是

469 个蛋白质所含特定的氨基酸 i 的总数； N_j 是 α 转角的个数； N_t 是 469 个蛋白质中总的残基数。

从表 3.1 可以看出， α 转角的第 i 位含量较多的氨基酸依次是 Cys、Asp 和 Asn。Pro 在第 $i+1$ 位的含量最高，其次是 Glu，Lys 和 Met。Glu、Gly 和 ASP 在 α 转角的第 $i+2$ 位出现的频率较高。在 α 转角的第 $i+3$ 位出现频率较高的氨基酸是 Thr、Cys 和 Asn。Gly 在 $i+4$ 位出现的频率很高，其次是 Cys 和 Asn。

Pavone 根据 α 转角中间三个残基肽键的二面角将其分成八种不同的类别。 ϕ 和 ψ 两个限定肽链构象的二面角，见图 3.3。I 和 II 是根据第 $i+2$ 和 $i+3$ 位的 ϕ 角来区分的，如果 ϕ_{i+2} 和 ϕ_{i+3} 同时大于 0 或同时小于 0，则 α 转角属于 I 型，若 ϕ_{i+2} 和 ϕ_{i+3} 一个大于 0，另一个同时小于 0，则 α 转角属于 II 型。R 和 L 是根据 ϕ_{i+3} 的符号来划分的， $\phi_{i+3} > 0$ 属于 L 型， $\phi_{i+3} < 0$ 属于 R 型。U 和 S 则是根据第 $i+1$ 和 $i+3$ 位的 ϕ 角来区分的，如果 ϕ_{i+1} 和 ϕ_{i+3} 同时大于 0 或同时小于 0，则 α 转角属于 S 型，若 ϕ_{i+1} 和 ϕ_{i+3} 一个大于 0，另一个同时小于 0，则 α 转角属于 R 型。综合的规则如表 2 所示。R 和 L 表示链反转的方向，是顺时针还是逆时针。当顺着 C_iO_i 键的方向看 α 转角，U 和 S 分别代表 U 型和螺旋型的转角。8 类 α 转角根据 ϕ 角的分类规则总结见表 3.3。




图 3.3 图示 ϕ 和 ψ 二面角

表 3.2 α 转角位置特异的氨基酸倾向性

	I	I+1	I+2	I+3	I+4
Ala	0.555867	1.032324	0.741156	0.635277	0.807331
Cys	3.404747	0.75661	0.441356	2.017628	1.324068
Asp	2.989758	0.786778	1.591041	0.891682	0.716843
Glu	0.74398	1.454894	1.818617	1.107703	0.545585
Phe	0.614181	0.859854	0.54048	0.737018	1.007257
Gly	0.741564	0.672901	1.757782	0.604237	2.993722
His	1.32444	1.11082	0.939925	1.238992	0.939925
Ile	0.62463	0.511061	0.492133	0.643559	0.889625
Lys	0.553442	1.160442	1.446089	1.624619	1.214001
Leu	0.886462	0.826566	0.479169	0.802608	0.730732
Met	0.404027	1.161579	0.606041	0.808055	1.212082
Asn	2.407925	0.869529	1.560692	1.783648	1.315441
Pro	0.684548	3.246084	1.30285	0.287069	0.132493
Gln	0.648811	0.78398	0.973217	0.838048	1.270588
Arg	0.638855	0.969298	0.991327	1.145534	0.749003
Ser	1.539313	1.009657	1.274485	1.241381	0.910346
Thr	0.970983	1.147526	1.023946	2.189126	0.670861
Val	0.657744	0.745444	0.555429	0.833143	1.008541
Trp	0.971096	0.971096	0.323699	0.971096	0.582658
Tyr	0.8191	0.8191	0.395428	1.158038	1.214527

表 3.3 根据 $\phi_{i+1} \phi_{i+2} \phi_{i+3}$ 的 α 转角分类

名称	ϕ_{i+1}	ϕ_{i+2}	ϕ_{i+3}
I- α_{RS}	-	-	-
I- α_{LS}	+	+	+
II- α_{RS}	-	+	-
II- α_{LS}	+	-	+
I- α_{LU}	-	+	+
I- α_{RU}	+	-	-
II- α_{LU}	-	-	+
II- α_{RU}	+	+	-

3.3.2 核函数选取与参数优化

与神经网络相比,用支持向量机构造分类器的突出优点在于构造简单,只需要选择核函数,和调整极少量的参数。核函数选取与参数优化对支持向量机的分类性能有重要影响。目前,统计学习理论对这些问题给出了一些建议和解释,但还没有给出实际可行方案。因此在实践中,主要通过试验来选取。对于标定好的数据集,根据以往的研究,径向基核和其它核相比有更好的性能^[19,20],因此,我们选择径向基核:

$$k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (9)$$

因此,待优化的参数是 γ 和 C 。因为形成 α 转角的残基数占 469 个蛋白质总的残基数的 4.9%,所以还需要确定另一个参数 j 。参数 j 的主要作用是通过设定不同的惩罚参数 C_+ 和 C_- ($C_+/C_- = N_-/N_+$) 来调节预测的灵敏性和选择性之间的平衡。其中 N_- 是非 α 转角残基数, N_+ 是 α 转角残基数。这里, j 设定为 18。我们用 10-折交叉验证来选择参数,结果如表 3.4 和表 3.5 所示,预测性能在 $\gamma = 0.0625, C=2$ 时最好。

表 3.4 使用相同 C 参数不同 γ 参数时的预测性能比较

γ	Q_{total}	$Q_{\text{predicted}}$	Q_{observed}	MCC
0.0078	83.9	13.4	44.7	0.18
0.0186	83.8	13.5	47.1	0.19
0.0312	92.8	23.7	25.4	0.21
0.0625*	95.4	58.1	11.5	0.24
0.0925	95.5	56.5	9.6	0.22
0.125	95.5	64.5	7.8	0.21

结果是在设置 $j=18$ 和 $C=1$ 时取得的。使用了“state-shifting”规则，所有 $abs(D)<0.4$ 的非转角预测都转换成转角预测。

表 3.5 使用相同 γ 参数不同 C 参数时的预测性能比较

C	Q_{total}	$Q_{\text{predicted}}$	Q_{observed}	MCC
1	95.4	58.1	11.5	0.24
2*	95.5	64.1	11.4	0.25
5	95.8	59.6	10.3	0.24
10	95.5	44.7	10.9	0.22
50	95.3	42.9	10.8	0.21

结果是在设置 $j=18$ 和 $\gamma=0.0625$ 时取得的。使用了“state-shifting”规则，所有 $abs(D)<0.4$ 的非转角预测都转换成转角预测。

3.3.3 处理两类样本不均衡

数据集中 α 转角数与非 α 转角数非常不平衡，数据不平衡将导致对非 α 转角的过预测。而如果使用平衡的 α 转角与非 α 转角训练，又会导致当使用自然发生的 α 转角与非 α 转角的正常比例的数据测试时，对 α 转角的过预测。前者称为不平衡数据集，后者成为平衡数据集。为了避免信息损失，我们选择使用前者（不平衡数据集）。

为了使得使用不平衡数据集也能有好的预测性能，我们测试了三种不同的策略。第一种策略，仅通过参数 j 在训练阶段对 α 转角与非 α 转角使用不同的惩罚参数 C_+ 和 C_- ，来平衡。第二种策略，仅在测试阶段用 state-shifting 过滤规则进行预测后处理。第三种策略，分别在训练阶段和测试阶段使用第一种和第二种策略。第一种策略通过设定 j 等于 18 或 30 实现。state-flipping 原则在所有三种策略中都使用。试验结果见表 3.6。

表 3.6 三种不同处理非平衡数据方法的试验结果^a

	j=1		j=18		j=30	
	SF ^b	SF+SS ^c	SF	SF+SS	SF	SF+SS
$Q_{\text{predicted}}$	85.7±2.5	66.7±1.8	81.5±2.9	60.0±2.6	80.0±2.7	57.6±2.1
Q_{observed}	1.0±0.1	6.7±0.4	4.7±0.6	11.4±0.9	4.3±0.3	11.3±1.0
MCC	0.10±0.01	0.19±0.02	0.19±0.02	0.25±0.02	0.18±0.02	0.24±0.02
S	0.03±0.01	0.11±0.02	0.09±0.02	0.19±0.02	0.08±0.02	0.18±0.02

^a 当 $j=18$ and 30 时的结果是用 “state-shifting” 规则将所有 $abs(D)<0.4$ 的非转角预测都转换成转角预测产生的。当 $j=1$ 的结果是用 “state-shifting” 规则将所有 $abs(D)<0.7$ 的非转角预测都转换成转角预测产生的($\gamma=0.0625$, $C=2$)

^b SF: “state-flipping” 规则.

^c SS: “state-shifting” 规则.

如表 3.6 所示，当 j 从 1 增加到 18 时，MCC 从 0.10 提升致 0.19，这说明在训练阶段对 α 转角与非 α 转角使用不同的惩罚参数 C_+ 和 C_- 对于平衡 α 转角的假阳性和假阴性是有效果的。但是当 j 从 18 增加到 30 时，MCC 没再增加，这说明 j 对性能的提升是有上限的。无论是第一种策略还是第二种策略，state-shifting 过滤规则的应用都极大提升了预测性能。显然，最好的预测性能是使用第二种策略得到的。

3.3.4 预测体系结构

使用 PSSMs 和预测的二级结构作为输入信息预测 α 转角的体系结构如图 3.4 所示。




图 3.4 预测 α 转角的体系结构

3.3.5 PSSMs 和二级结构信息对预测性能的影响

PSSMs 和二级结构信息对预测性能的影响见表 3.7 所示。结果是 10-折交叉验证的平均，表示为平均值加标准偏差。使用 PSSMs 形式的多序列比对信息大大提高了预测性能。当用多序列比对信息代替单序列信息输入时，MCC 从 0.08 提升至 0.24，Qpredicted 从 14.7%提升至 58.1%。当同时包括二级结构信息作为输入时，多序列比对信息的影响是相似的。在两种情况下 PSSMs 都极大减少了假阳性，提高了 Qpredicted。

加上二级结构信息进一步提升了预测性能。当仅使用单序列信息时，MCC 值是 0.08，加上二级结构信息后，MCC 提升至 0.11；当仅使用多序列比对信息作为输入时，

MCC 值是 0.24，加上二级结构信息后，MCC 提升至 0.25。因此，二级结构对预测性能的影响不如多序列比对信息对预测性能的影响。

我们的数据包括一些用来训练 PSIPRED 的蛋白质的同源蛋白质，因此有必要测试一下这对于预测性能有无影响。使用我们的数据集时，PSIPRED 实现的三状态总的预测正确率是 78.8%，MCC 分别是：0.73(螺旋)，0.64(折叠)，0.60(卷曲)。相应的 PSIPRED 用于预测一组与其没有同源性的蛋白质时，得到的总的预测正确率是 76.4%，MCC 分别是：0.70(螺旋)，0.62(折叠)，0.57(卷曲)。因此，我们认为尽管我们的数据包括一些用来训练 PSIPRED 的蛋白质的同源蛋白质，但对最后的预测性能影响很小。

表 3.7 不同编码策略产生的试验结果

Method	$Q_{\text{predicted}}$	Q_{observed}	MCC	S
(1)	14.7±1.3	9.0±0.7	0.08±0.01	0.08±0.01
(2)	16.5±1.4	13.8±1.1	0.11±0.01	0.11±0.01
(3)	58.1±2.5	11.5±1.6	0.24±0.02	0.18±0.02
(4)	60.0±2.6	11.4±0.9	0.25±0.02	0.19±0.02

结果是在设置 $j=18$ 时产生的并且使用了“state-shifting”规则，所有 $\text{abs}(D)<0.4$ 的非转角预测都转换成转角预测。他们分别基于如下编码策略：(1) 单序列信息、(2) 单序列信息加预测的二级结构信息、(3) 多序列比对信息、(4) 多序列比对信息加预测的二级结构信息。

3.3.6 与其它预测方法的比较

为了方便与其它方法我们进行比较，我们也使用了迄今为止预测 α 转角最好的方法 AlphaPred 使用的数据集（即 Pavone 数据集）来测试我们的方法，也使用同样的 5-一折交叉验证。我们的预测结果与 AlphaPred 的预测结果的对比见表 3.8。从表 3.8 可以看出当仅使用单个序列信息作为输入时，我们的方法获得的 MCC 值比 AlphaPred 大 0.08。而当使用多序列比对加二级结构信息作为输入时，我们的方法获得的 MCC 值比 AlphaPred 大 0.1。必须指出的是，MCC 的提升主要源于 $Q_{\text{predicted}}$ 的提升，而神经网络方法取得的 Q_{observed} 则高于用支持向量机方法取得的 Q_{observed} 。

表 3.8 本文提出的方法 AlphaTurn 与 AlphaPred 方法的预测性能比较

	单序列		PSSMs 加预测的二级结构	
	AlphaPred	AlphaTurn	AlphaPred	AlphaTurn
$Q_{\text{predicted}}$	6.5	12.5	9.4	25.5
Q_{observed}	51.1	35.3	55.5	34.7
MCC	0.06	0.14	0.16	0.26

表 3.9 967 个 α 转角的位置特异的二级结构组成。二级结构用 DSSP 程序确定

Position	i	i+1	i+2	i+3	i+4
‘G’结构的 α 转角残基数	33	0	0	0	27
‘H’结构的 α 转角残基数	72	0	0	0	30
‘I’结构的 α 转角残基数	0	2	2	2	2
‘B’结构的 α 转角残基数	35	12	2	0	30
‘E’结构的 α 转角残基数	252	8	0	1	132
‘S’结构的 α 转角残基数	84	5	6	26	146
‘T’结构的 α 转角残基数	83	903	930	917	232
‘C’结构的 α 转角残基数	408	37	27	21	368

我们提出的方法所表现出来的较好的预测性能取决以下三个方面。首先，使用了支持向量机来构建分类器。与传统的神经网络相比，支持向量机具有出色的性能，它运用结构风险最小化原则，在经验风险与模型复杂度之间作适当的折衷，从而获得较好的推广能力。其次，使用二阶段法来处理不平衡数据集。正如前面所讨论的，同时使用参数 j 和 state-shifting 过滤规则比单独使用一种方法要好。最后，我们使用预测的二级结构信息的方式与 AlphaPred 不同。在 AlphaPred 中，预测的二级结构信息是用来过滤 α 转角预测。 α 转角的预测仅保留在预测为无规卷曲的区域。但是在

Pavone 的数据集中， α 转角只有 67% 的残基位于无规卷曲的区域，这主要是因为 Pavone 等没有去掉由 DSSP 确定为 (CGGGC) 和 (CGGGG) 的五肽。我们的数据集中所有 α 转角位置特异的二级结构组成与 Pavone 的数据集所有 α 转角位置特异的二级结构组成分别见表 3.9 和表 3.10。

表 3.10 Pavone 数据集中 α 转角的位置特异的二级结构组成。二级结构用 DSSP 程序确定.

Position	i	i+1	i+2	i+3	i+4
‘G’结构的 α 转角残基数	39	84	87	73	28
‘H’ 结构的 α 转角残基数	20	31	27	30	30
‘I’ 结构的 α 转角残基数	0	0	0	0	0
‘B’ 结构的 α 转角残基数	20	11	3	0	13
‘E’ 结构的 α 转角残基数	71	2	0	2	40
‘S’ 结构的 α 转角残基数	28	1	1	10	50
‘T’ 结构的 α 转角残基数	27	224	236	233	77
‘C’ 结构的 α 转角残基数	151	3	2	8	116

3.3.7 AlphaTurn 网络服务

我们开发了被称为 AlphaTurn 的网络服务来从一级序列预测 α 转角。网址是：<http://bmc.hust.edu.cn/bioinformatics/>。输入单字母编码的氨基酸序列，如 CFGHKLMNVCD AE...。输出标记预测结果（ α 转角或非 α 转角）及相应的可靠度。图 3.5 是网络服务的界面。图 3.6 是蛋白质 1aocA 的预测结果。




图 3.5 AlphaTurn 界面

ALPHATURN PREDICTION RESULT:

```

SEQUENCE:  ADTNAPICLCDEPGULGRTQIUTTEIKDKIEKAUEAUAQESGUSGRGFSI
PREDICT:  -----aaaaa-----
RINDEX:    6744457551010034434356465445445865555553345555742

SEQUENCE:  FSHHPVFRECGKYECRTRPEHSRCYNFPFTHFKSECPUSTRDCEPVFG
PREDICT:  -----aaaaa-----
RINDEX:    3355444454546457533223566665564654533455435443425

SEQUENCE:  YTVAGEFRUIVQAPRAGFRQCWQHKKRFGSNSCGYNGRCTQQRSUURLU
PREDICT:  -----aaaaa-----
RINDEX:    53101156676743564465566664453312201222435443764666

SEQUENCE:  TYNLEKDGFLCESFRTCCGCPCRSF
PREDICT:  -----aaaaa-----
RINDEX:    6532013367454235343533343

```

图 3.6 α -turn/non- α -turn 预测结果示例

该预测是对蛋白质 1aocA(175 残基)进行的。使用的输入信息是 PSSMs 和预测的蛋白质二级结构。预测结果以 50 个残基为一组显示。对于每一组，第一行是氨基酸序列；第二行表示 α 转角/非 α 转角预测 (a= α 转角预测，‘-’=非 α 转角预测)；第三行是预测的可信度。

3.4本章小结

本章提出了基于支持向量机的氢键 α 转角的预测。该支持向量机分类器当使用由 PSI-BLAST 产生的多序列比对信息和预测的二级结构作为输入时产生的 MCC 值是 0.25。多序列比对信息对预测性能的提升作用大于预测的二级结构信息。当使用相同的数据集和相同的测试方法时，该方法能取得比当今最好的氢键 α 转角预测方法更好的预测性能。此外，我们的方法能对其它规则二级结构预测方法起补充作用。

.

4 广义 α 转角预测

4.1 引言

在蛋白质所有二级结构中,关于卷曲结构的分类一直众说纷纭,尽管它们经常位于蛋白质活性位点^[61]。首先被确定的属于卷曲结构的是由四个残基构成的 β 转角。除了 β 转角,还有就是由五个残基构成的 α 转角。和早期 β 转角的定义一样,用来确定 α 转角的规则是第*I*个残基的羰基O和第*I*+4个残基的氨基质子之间有一个氢键,并且不是 α 螺旋的一部分。后来, β 转角的定义扩大到包括不含氢键的转角,但是主要条件变为四个残基两个末端残基 α 碳之间的距离小于7Å。相同的,最近Dasgupta^[5]等也将 α 转角的定义扩展为第*i*个残基与第*i*+4个残基的 α 碳之间的距离小于6.5Å(我们将这种用距离定义的 α 转角称为广义 α 转角)。关于广义 α 转角的预测还未有人做过,很自然的,我们将性能较好的预测氢键 α 转角的工作进一步拓展为预测广义 α 转角。

4.2 材料与方法

4.2.1 数据集

我们使用的基础数据集是2005年10月版的pdbselect^[65]数据库,其中任意两条蛋白质序列同源性小于25%。随后,我们进一步使用下列三条规则选取用来预测依距离定义 α 转角代表蛋白质序列。第一、只选取是用X射线衍射法而不是用核磁共振法确定结构的蛋白质;第二、蛋白质结构测定精度大于2.0埃;第三、至少包含一个依距离定义 α 转角。我们最终得到757个蛋白质,共包含5071个 α 转角、138608个残基。757个蛋白质的PDB代码见表4.1。5071个广义 α 转角见附表2。

我们使用下列规则确定依距离定义的 α 转角:首先选出所有第1个残基与第5个残基 α 碳之间距离小于6.5Å的5肽片断,然后去掉中间三个残基属于 α 螺旋(即DSSP定义的二级结构中的G和H)的5肽。二级结构使用DSSP^[66]软件确定。

表 4.1 用来预测广义 α 转角的蛋白质的 PDB 代码

1N55A	1GA6A	1RTQA	1NWWB	1K92A	1SCJB	1ICFI	1LMB3	1KZQA	1H2WA	1RYOA	1W2WB
1DS1A	1QTWA	1LUQB	1E29A	1HFES	1HJLA	1SR4A	1KVDB	1H75A	1I1JA	1JL1A	1Y6XA
1MF7A	1MFMA	1M1QA	1KYFA	1AY7B	1S3ZB	1VKYA	1JIDA	1HTWA	1IE9A	1F9VA	1Y89A
1R6JA	1KQPA	1P1XB	1K3XA	1OOYA	1K4IA	1FS9A	1DOKA	1FLTXX	1ES5A	1VD6A	1K3IA
1US0A	1R2QA	1NQJB	1S3CA	1TW6B	1Z2NX	1W85J	1YWMA	1YY6A	1GP0A	1PINA	1J17A
1SSXA	1FSGA	1R2MA	2BJIB	1KP6A	1CSEI	1O7IA	1O50A	1FVKA	1XYIA	1V30A	1O3UA
1M40A	1SX7A	1CC8A	1FLMA	1QZNA	1I0VA	1I24A	1E6IA	1DSZA	1URSA	1QGVA	1PBYC
1GWEA	1W23A	1QXYA	1GK9A	1O4TA	2TPSA	1OBOA	1C2AA	1NRJB	1SI6X	1JY2R	1Q8DA
1KWFA	1UWCA	1EUWA	1GK9B	1TL2A	1QKSA	1I0DB	1SQ9A	1MXIA	1V4PC	1JY2N	1XIYB
1IUAA	1K5NA	1M2DA	1WVFA	1CLVI	1HYOA	1ES9A	1DFNA	1NRJA	1C5LL	1ZDYA	1YJ1C
1X8QA	1K5NB	1N62A	1J2RA	1QZ4A	1O8XA	1KGDA	1YROD	1NTYA	1OQQA	1FL0A	1H32A
1MC2A	1I40A	1N62C	1GPPA	1Y55X	1P4CA	1PB7A	1Z6OX	1IGQA	1SX5A	1WMHA	1V54I
1N4WA	1QJ4A	1T2DA	1QOPB	1D5TA	1KUFA	1PZ4A	1LJOA	1NEPA	1OI0B	1WMHB	1V54G
1IQZA	1KNGA	1QLWA	1X9DA	1TJXA	1R6DA	1RYQA	1KLXA	1PCFA	1P4OB	1XPPD	2PSPB
1OK0A	1HDOA	1F86A	1RJUV	1RA0A	1N8VA	1F8EA	1OTKA	1R77B	1SZHA	2BL8C	1QMPD
2BT9C	1HBNB	1P5FA	1O4YA	1VFYA	1KV7A	1JUBA	1RLJA	1XTYA	1EGWA	1HQKA	1JL0B
1EB6A	1M1NB	1LS1A	1MG4A	1TQWA	1TZPB	1N13B	1AOCA	1MWPA	1JOVA	1T0PB	1J8C
1VYYA	1M1NA	1TUKA	1OFNA	1R5YA	1S0PA	1EW4A	1QG7A	1V54H	1TVGA	1TH7A	1LG7A
1JFBA	1C90A	1N8KA	2BO9D	1UAIA	1U4GA	1KJLA	1DANT	1V54K	1B8ZA	1MK4A	1EQ2A
1SFSA	1H97A	1U07B	1W2YB	1QTNB	1UQ5A	1YC5A	1YMTA	1V54J	1RYLA	1OIOA	1GPIA
1ZL0B	1UBKS	1VZIA	1SYYA	1D4OA	4EUGA	1V05A	1USCA	1V54L	1IT2A	1XAKA	1RDQE
1C5EA	1M15A	1ODMA	1R4PA	1RYAA	1YPQA	1HZTA	1V70A	1NO5B	1JHJA	1J22A	1UXOA
2BK9A	1WM3A	1E9GA	1JKUA	1MKKA	1KS8A	1HZ4A	1UCDA	1SMXB	1MAVA	1WZ3A	1ZMAA
1ME4A	1MJUL	1CZPA	1UZ0A	1VIMC	1PKHA	1HLQC	1XEOA	2BFXD	1OU8A	1X8BA	1PMHX
1M4LA	1OQVA	1UWKB	1ZK4A	1JL7A	1M7GD	1GV9A	1TZVA	1E1HD	2BOKL	1JNVB	1WDVA
1PQ7A	1O7QA	1O08A	1XQOA	1EAAZ	1OS6A	1SMOB	1PWBC	1CMBA	1HXRA	1GUXB	1O6AB
1PJXA	1QNRA	1YR4B	1Y93A	1R26A	1GVDA	1RKUA	1G8AA	1PUOB	1UEBB	1JYOA	1USPA
1G6XA	1ST9B	1UCRB	1M9ZA	1KQRA	1O9RA	1PVMA	1NYCA	1PK6A	1VJ2A	1X9RB	1Z3XA
1F9YA	1BQCA	1RMWA	1R0RI	1I71A	1TKEA	1ELKA	1V7RA	1QFOA	1EARA	1XXMC	1UGPA
1IX9A	1W0NA	1JO8A	1L3KA	1ZKKB	1UPQA	1BX4A	2TNFA	1R75A	1OA8A	1NP6B	1SMBA
1G66A	1MUWA	1NXMA	1H4AX	1XD3C	1F7LA	1NN5A	1PFBA	1XIWB	1UB4A	1IKOP	1ZXUA
1J0PA	1MN8B	1LQ9A	1TU9A	1Z1SA	1TP6A	1DP7P	1T7RA	1AGQD	1F32A	1ZB1A	1IZMA
1VBWA	1LKKA	1W2LA	1SENA	1XRKB	1X91A	1GD0A	1MNNA	1BXYA	3HTSB	1WMXA	1UV7A
1MJ5A	1OD3A	1DG6A	1FYEA	1VYIA	3EZMA	1SHUX	1C1KA	1FX4A	1RGXC	1SUMB	1HRUA
7A3HA	1CXQA	1WPNA	2BMOA	1T61A	1LUCA	1LK9B	1IDPA	1OTFA	1YSPA	1Y96D	1G55A
1K5CA	1I27A	1XUBA	2BMOB	1ISUA	1G90A	1OQJB	1IS3A	1I8AA	1UUZA	1S14B	1RHFA
1UFYA	1NH0A	1E7LA	1OOHA	1UV4A	1UXAB	1YXYB	1D7PM	1V83A	1LC7A	1Y50A	1J5UA
1O7JA	1LQTB	1SJWA	1JNIA	1YBIA	1V5IB	1T9IB	1P1MA	1NH2C	1DQEA	1Z5ZA	1WKCA
1PSRA	1KMVA	1GYXA	1QWYA	1YD0A	2ARCB	1EUVA	1ROCA	1AYOA	1SC3B	1GL4B	1KW4A

1PWGA	1RQWA	1OH4A	1RUTX	2BKVB	1DCIA	1RC9A	1LMIA	1FLEI	1Y02A	1EAYD	1Y71A
1JBEA	1XJUB	1EAJA	1TJYA	1YN9C	1M65A	1B5EA	1MTPB	1OAPA	1XAUA	1P9GA	1XE1A
1UOZA	1T8KA	1JO0B	1VMHA	1DQZA	1RKIA	1G8QA	1SJ1A	1UW1A	1CQ3A	1I1WA	1O1XA
1OC7A	1QV1A	1LLFA	1V9YA	1T1UA	1XG4B	1DBWA	1IV3A	1UW4A	1T0FD	1DY5A	1RW1A
1JM1A	1Z2UA	1K0MA	1V0WA	1DK8A	1R5RA	1NC5A	1MG7A	1TU1A	1T15A	1XG0C	1XDNA
1SAUA	2BHUA	1Q92A	1VKKA	1P5ZB	1KQFB	1XTEA	1W4SA	1UW4B	1F5MB	1HX0A	1EAQB
1K7CA	1QL0A	1OCYA	1Q5YA	1B3AA	1KQFC	1D0DA	1EYHA	1LDDA	1QA7A	1VR7A	1WHZA
1P6OB	1GWMA	1HT6A	1M1FB	1TQJC	1KICB	1PYOD	3PVI A	1XIZA	1QOUB	1MJUH	1VR8A
1OJRA	1KNMA	1RP0A	1LTZA	1S95A	1X60A	1DTDB	1FR2A	1H6KZ	1Y7PB	1GMXA	1S9UA
1WB4A	1LB3A	1XM8A	1OBDA	1T92A	1YO3C	1CXYA	1JATB	1BYS A	1STMA	1H4XA	1YQHA
1NOFA	3CHBH	1VKBA	1UUYA	1P0ZA	1KCQA	1IBYA	1O26A	1H8EI	1I1WA	1J98A	1Y0UA
1NWZA	1MFGA	1NKIA	1LRIA	1H2CA	2BJFA	1F60B	1GY7A	1TXJA	1XB9A	1WY3A	1SBXA
1V6PA	1GXUA	1TG0A	1W1HB	1SWXA	1VMBA	1HZ6B	1T1VA	2BSZB	1JHSA	2BF9A	1LR0A
1OEWA	1KA1A	1UNQA	1VM9A	1DOS A	1OSYA	1RH6A	1Y0HB	1HG2A	1LHVA	1I8OA	1UWWA
1VYRA	1QDDA	1C7KA	1UOYA	1UT1A	1QY1A	1N0WB	1ID0A	2BKQC	1UISA	1PQHA	1NU0B
1LUGA	1G61A	1YFQA	1LO7A	1M9XC	1YMKA	1ECSA	1MK0A	1PY0A	1D3BL	1K55C	1YR0A
1F94A	1R29A	1YS1X	1DJ0A	1Y63A	1R0UA	1H03P	1E6BA	1UUTA	1D3BA	1H4GA	1FG7A
1C75A	1GXMB	1RG8A	1QWOA	1XVYA	1EW2A	1EIZA	1UD9D	1MZWB	1DQTA	1QU9A	1YB3A
1UG6A	1Q7LA	1SU8A	1EDMB	1KPTA	1RY9A	1J2LA	1GCQC	1L8JA	1D2ZB	1NZ0B	1UARA
1SFDA	1M0KA	1LU4A	1VL7A	1QWDA	1XEDE	1PFVA	1K94A	1JF8A	1MI8A	1QQFA	1LXJA
1TT8A	1HD2A	1XODB	1NF9A	1YACA	1REGY	2BIIB	1DQIA	1OXDA	1EL6A	1Z67A	1WGBA
1Q6ZA	1UCSA	1XMTA	1HQ1A	1XU1S	1UNNC	1GXYA	1T1JA	1USMA	1RW0A	1Y1JX	1KR4A
1GKMA	1X6ZA	1GU2A	1VHWE	1YVIB	1B2VA	1O5FL	1H6FA	1V8HA	1OH0B	1QPAA	1NJHA
1LNIA	1KTHA	1W6SB	2BEMA	1O94D	1XDWA	1JH6A	1S5UG	1RTTA	1LF7A	1WRR A	1RO7A
1K3SA											

4.2.2 支持向量机

支持向量机是一种较新的由 Vapnik^[55-56]等提出的基于统计学习理论的机器学习方法。近来,支持向量机已被成功用于多种生物分类问题:如蛋白质二级结构预测^[20]、蛋白质亚细胞定位预测^[23]、蛋白质四级结构预测^[72]、酶分类^[42]以及蛋白质残基可溶性预测^[77]。其基本思想是通过核函数将输入样本映射到高维特征空间,然后在此空间中通过求解方程 4.1 来构造最优超平面:

$$\begin{aligned} \min_{\omega, \xi_i} \quad & \frac{1}{2} \omega^T \omega + C \sum_{i=1}^l \xi_i \\ \text{s.t.} \quad & y_i (\omega \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, l \end{aligned} \quad (4.1)$$

其中 x_i 表示输入向量, $y_i = \pm 1$ 分别表示 x_i 属于 α 转角和非 α 转角类, 1 表示训

训练数据集的大小, ω 是权重向量, b 是偏置向量, ξ_i 是松散变量, C 是用来惩罚参数。

本文的支持向量机方法用 Joachims 开发的 SVMlight^[78] 实现。

4.2.3 输入特征编码策略

我们采用了经典的描述蛋白质局部序列信息的移动窗口编码策略来预测广义 α 转角。当仅使用单个序列的信息作为输入时, 每一种氨基酸都用 20 维的向量 (19 个 0, 1 个 1) 来表示, 当对一条序列两端的残基编码时, 会出现所谓的空缺残基, 对这样的残基, 我们将其表示为 20 个零组成的向量。而当用多序列联配信息作为输入时, 我们使用由 PSI-BLAST 产生的 PSSMs 作为输入, 并且使用与 PSIPRED 生成 PSSMs 相同的参数设置, PSSMs 的元素通过方程 3.3 进行归一化处理:

通过 PSIPRED 预测的二级结构信息使用如下编码: 螺旋 $\rightarrow (1, 0, 0)$, 折叠 $\rightarrow (0, 1, 0)$, 无规卷曲 $\rightarrow (0, 0, 1)$ 。移动窗口的大小对预测性能有一定影响, 本文使用以前预测氢键 α 转角已经优化了的窗口长度 11。

4.2.4 预测后过滤

因为支持向量机优化总的正确率, 而非 α 转角残基数远多于 α 转角残基数, 所以对非 α 转角残基的预测正确率要远高于对 α 转角残基预测的正确率。因此, 我们引入了一个由 Shepherd^[79] 提出的被称为 “state-shifting” 的过滤规则。它将改变预测可信度低于某一门槛值的残基的预测状态。在使用 “state-shifting” 规则时, 我们直接使用 D 来表示预测可信度, 因为 D 能给出比 RI 更加精细的门槛值。例如, $NT < 0.1$ 表示将所有 D 的绝对值小于 0.1 的非 α 转角预测转变成 α 转角预测。

因为 α 转角是 5 肽, 但是预测是对每个残基进行的, 没有考虑残基间的相关性。所以, 我们引入了另一个与 Shepherd^[79] 提出的被称为 “state-flipping” 规则相似的过滤规则。首先, 将所有孤立的非 α 转角预测转变成 α 转角预测; 其次, 将所有孤立的 α 转角预测、孤立的连续 2 个 α 转角预测、孤立的连续 3 个 α 转角预测都转变成非 α 转角预测; 最后, 对于孤立的连续 4 个 α 转角预测, 则将相邻的具有较低的预测可信度的非 α 转角预测转变成 α 转角预测。

4.2.5 预测性能评价参数

预测性能是通过 7-折交叉验证来进行评价的。将数据集随机分成大小近似相等的 7 组。SVM 分类器用其中的 6 组进行训练，剩下的一组进行测试。该过程将进行 7 次，每一次使用一组不同的测试集。为了评价预测性能，我们使用四个常用来对转角预测性能进行评价的指标：（1） Q_{total} ，用来表示总的预测正确率；（2） $Q_{predicted}$ 用来表示预测的灵敏性；（3） $Q_{observed}$ 用来表示预测的选择性；（4）MCC 可同时表示预测的灵敏性和选择性，用它反映预测性能有较好的鲁棒性。另外，还有一个参数 S 将该方法与随机预测进行比较。

4.3 结果与讨论

4.3.1 核函数选取与参数优化

核函数选取与参数优化对支持向量机的分类性能有重要影响。根据以往的研究，径向基核和其它核如多项式核相比有更好的性能，因此，我们选择径向基核：

$$k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (4.2)$$

因此，待优化的参数是 γ 和 C。因为非 α 转角残基数与 α 转角残基数之比为：4.4: 1，所以还需要确定另一个参数 j 。参数 j 的主要作用是通过设定不同的惩罚参数 C_+ 和 C_- ($C_+ = j * C_-$) 来调节预测的灵敏性和选择性之间的平衡。 j 一般设为 N_-/N_+ ，其中 N_- 是非 α 转角残基数， N_+ 是 α 转角残基数。这里， j 设定为 4。通过 7-折交叉验证，预测性能在 $\gamma = 0.065$, $C = 5$ 时最好。

4.3.2 处理两类样本不均衡

数据集的不均衡给用机器学习方法进行分类制造了很大的障碍。处理此问题主要有两种策略。第一种策略是采用重采样来平衡数据集，即去掉一定数量的样本数较多的那一类的数据，或增加一定倍数的样本数较少的那一类的数据。但是当使用自然状态的测试数据（正类样本与负类样本不平衡）去检验使用了重采样技术训练的分类器时，就会发现该分类器对原本样本数较多的那一类的预测正确率降低。第二种策略是采用我们在预测以氢键定义的 α 转角时提出的两步法。首先，在训练时，通过参数 j 对样本数不平衡的正类样本和负类样本采用不同的惩罚参数 C_+ 和 C_- 。其次，在决策阶段用“state-shifting”规则对预测结果进行过滤。

使用不同的“state-shifting”规则对预测性能的影响见图 4.1。如图 4.1(a)

所示，当使用 $NT < 0.3$ 的规则对结果过滤时，预测性能最好。图 4.1(b) 显示了“state-shifting”规则对预测的灵敏性和选择性的调节作用。




图 4.1“state-shifting”规则对预测性能的影响 (a) “state-shifting”规则对 MCC 的影响. 结果是用多序列比对信息和预测的二级结构信息作为输入时产生的.(b)“state-shifting”规则对 $Q_{\text{Predicted}}$ and Q_{Observed} 的影响。结果是用多序列比对信息和预测的二级结构信息作为输入时产生的。

4.3.3 不同编码策略对预测性能的影响

我们测试了四种不同的输入对预测性能的影响，即单个序列信息、单个序列信息加上预测的二级结构信息、多序列联配信息、多序列联配信息加上预测的二级结构信息。预测结果见表 4.2。

如表 4.2 所示，当用多序列联配信息代替单个序列信息作为输入时，预测性能得到极大的提高。没有加上预测的二级结构信息时效果更明显，MCC 从 0.249 增加到 0.402， Q_{total} 从 77.1% 增加到 86.7%。PSSMs 对预测性能的提升作用已经在很多种预测中显示：如蛋白质二级结构预测^[30]、蛋白质亚细胞定位预测^[23]、 β 转角预测^[6, 7]。这主要是因为 PSSMs 包含了一个残基出现在一个序列的某一位置是否保守的信息。

二级结构信息进一步提高了预测性能。没有包括多序列联配信息时，二级结构对性能的影响更明显，MCC 从 0.249 增加到 0.299。当使用多序列联配信息加上预测的二级结构信息作为输入时，SVM 分类器达到最终的 MCC 为 0.415，S 为 0.407（比随机预测好得多）。

与氢键 α 转角的预测性能相比，依距离定义 α 转角的预测性能要好很多。氢键

α 转角预测，达到的最好 MCC 是 0.25 (使用的数据集是 469 个蛋白质，967 个氢键 α 转角)^[4]，而依距离定义 α 转角预测，达到的最好 MCC 是 0.415。主要原因是基于 α 碳之间距离定义的 α 转角在蛋白质序列中含量比氢键 α 转角高，氢键 α 转角在蛋白质中含量只有 4.9%，而依距离定义 α 转角的含量则为 18.3%。

表 4.2. 使用不同编码策略的结果

Method	Q_{total}	$Q_{\text{predicted}}$	Q_{observed}	MCC	S
(1)	77.1	30.8	47.2	0.249	0.241
(2)	79.1	34.6	51.2	0.299	0.291
(3)	86.7	55.5	40.8	0.402	0.397
(4)	86.9	56.2	42.0	0.415	0.407

结果是在设置 $j=4$ 时产生的并且使用了“state-shifting”规则，所有 $abs(D)<0.3$ 的非转角预测都转换成转角预测。他们分别基于如下编码策略：（1）单序列信息、（2）单序列信息加预测的二级结构信息、（3）多序列比对信息、（4）多序列比对信息加预测的二级结构信息

4.4 本章小结

本文首次提出了依距离定义 α 转角的预测方法。该方法表现了良好的预测性能，多序列联配信息和预测的二级结构信息都有助于提高预测性能。综合多序列联配和预测的二级结构作为输入信息时，预测的 MCC 值达到 0.415。因为依距离定义的 α 转角在蛋白质中的含量比氢键 α 转角高，所以依距离定义的 α 转角的预测性能优于氢键 α 转角。

5 π 转角预测研究

5.1 引言

随着大规模基因组测序计划的进行, 已知序列的蛋白质和已知结构的蛋白质在数量上的差异逐渐扩大。开发正确的预测蛋白质结构的方法是缩小这个差异的有效办法。蛋白质二级结构预测是蛋白质三级结构很重要的中间步骤, 尤其在蛋白质序列同源性小于 30% 的情况下。蛋白质二级结构可以分为三大类: 规则的二级结构、部分规则的二级结构、不规则的二级结构。规则的二级结构包括 α 螺旋和 β 折叠。部分规则的二级结构主要包括各种转角和环形。根据包含的残基数, 转角可分为 δ 转角、 γ 转角、 β 转角、 α 转角、 π 转角, 它们分别包括 2、3、4、5、6 个残基。转角可以帮助肽链折叠成近乎球状的三维结构。另外, 转角一般位于分子表面, 与分子识别关系密切。鉴于转角在蛋白质结构与功能中发挥的重要作用, 近年来, 已开发出一些方法专门用来预测 α 、 β 、 γ 等转角。但是, 据我们所知, 尽管有关于 π 转角系统分析的研究, 但还没有专门用来预测 π 转角的方法。本文致力于开发专门预测 π 转角的方法。

π 转角是一段包括 6 个残基的肽段, 第 i 个残基的羰基 O 和第 $i+5$ 个残基的氨基质子之间有一个氢键。在 1996 年前, π 转角被描述为第 5 个残基处于 α_L 构型的螺旋结构的终结子。1996 年 Rajashankar 和 Ramakumar^[87] 对 141 个蛋白质中的 486 个 π 转角进行了系统研究, 他们发现 π 转角的第 5 个残基不仅能处于 α_L 构型, 也能处于 α_R 和 β 构型, 并且 π 转角并不仅仅出现在 α 螺旋的末端, 也能出现在 β 折叠的末端。

在本研究中, 我们建了一个基于支持向量机的分类器来识别 π 转角, 并且取得了很高的预测正确率。该方法和多序列比对信息与预测的二级结构信息一起达到的 MCC 值是 0.556, 当用实际的二级结构信息取代预测的二级结构信息时, 实现的 MCC 值是 0.571。另外, 我们还计算了 640 个非同源蛋白中 1931 个 π 转角的位置特异的氨基酸出现的频率。

5.2 材料与方法

5.2.1 数据集

与预测 α 转角使用的基础数据集一样, π 转角预测使用的基础数据集也是 2005 年 10 月版的 pdbselect 数据库, 其中任意两条蛋白质序列同源性小于 25%。随后, 我们进一步使用下列三条规则选取用来预测 π 转角代表蛋白质序列。第一、只选取是用 X 射线衍射法确定结构的蛋白质; 第二、蛋白质结构测定精度大于 2.0 埃; 第三、至少包含一个 π 转角。我们最终得到 640 个蛋白质, 共包含 1931 个 π 转角、124352 个残基。形成 π 转角的残基数占 640 个蛋白质总的残基数的 9.3%。平均来说, 每个蛋白质有 3 个 π 转角。640 个蛋白质的 PDB 代码见表 5.1。1931 个 π 转角见附表 3。

我们使用下列规则确定依距离定义的 π 转角: 首先选出所有第 i 个残基的羰基 O 和第 $i+5$ 个残基的氨基质子之间有一个氢键的 6 肽片断, 然后去掉有连续 π 转角出现的 6 肽。

表 5.1 用来预测 π 转角的蛋白质的 PDB 代码

1N55A	1GA6A	1KTHA	1XMTA	1OOYA	1S3ZB	1REGY	1JH6A	1NRJB	1H2WA	1F9VA	1J17A
1DS1A	1QTWA	1RTQA	1NWWB	1TW6B	1TQGA	1UNNC	1LMB3	1MXIA	1IE9A	1VD6A	1O3UA
1MF7A	1KQPA	1P1XB	1E29A	1KP6A	1K4IA	1B2VA	1KVDB	1NRJA	1ES5A	1PINA	1PBYC
1R6JA	1R2QA	1R2MA	1KYFA	1QZNA	1Z2NX	1XDWA	1JIDA	1NTYA	1GP0A	1QGVA	1XIYB
1US0A	1FSGA	1CC8A	1K3XA	1O4TA	1CSEI	1ICFI	1YWMA	1NEPA	1URSA	1ZDYA	1G2YA
1SSXA	1SX7A	1QXYA	1S3CA	1N1FA	1I0VA	1VKYA	1O50A	1XTYA	1SI6X	1WMHA	1YJ1C
1M40A	1W23A	1M2DA	2BJIB	1QZ4A	2TPSA	1FS9A	1E6IA	1MWPA	1V4PC	1WMHB	1H32A
1GWEA	1UWCA	1N62A	1GK9A	1D5TA	1QKSA	1I24A	1SQ9A	1V54H	1O82A	2BL8C	1V54I
1KWFA	1K5NA	1N62C	1GK9B	1TJXA	1HYOA	1OBOA	1YROD	1SMXB	1C5LL	1HQKA	1V54G
1IUAA	1QJ4A	1T2DA	1WVFA	1RA0A	1O8XA	1I0DB	1Z6OX	2BFXD	1OQQA	1MK4A	2PSPB
1X8QA	1KNGA	1QLWA	1J2RA	1VIFYA	1P4CA	1ES9A	1KLXA	1E1HD	1SX5A	1Z0PA	1QMPD
1N4WA	1HDOA	1F86A	1QOPB	1TQWA	1KUFA	1WCWA	1L3PA	1CMBA	1IRQB	1J22A	1JL0B
1IQZA	1HBNB	1P5FA	1X9DA	1R5YA	1R6DA	1KGDA	1OTKA	1YBZA	1P4OB	1WZ3A	1JG8C
2BT9C	1M1NB	1LS1A	1O4YA	1UAIA	1N8VA	1PB7A	1RLJA	1PUOB	1SZHA	1G8EB	1LG7A
1EB6A	1M1NA	1TUKA	1MG4A	1QTNB	1KV7A	1PZ4A	1AOCA	1VIZA	1JR8A	1X8BA	1EQ2A
1JFBA	1C90A	1N8KA	1OFNA	1D4OA	1TZPB	1RYQA	1X6JA	1QFOA	1EGWA	1J75A	1GPIA
1LWBA	1UBKS	1U07B	2BO9D	1CY5A	1SVFA	1F8EA	1YMTA	1R75A	1JOVA	1JMVb	1RDQE
1SFSA	1M15A	1VZIA	1W2YB	1VIMC	1U4GA	1JUBA	1USCA	2EBOC	1TVGA	1GUXB	1UXOA
1ZL0B	1WM3A	1ODMA	1SYYA	1JL7A	1UQ5A	1N13K	1UCDA	1XIWB	1B8ZA	1JYOA	1ZMAA
2BK9A	1MJUL	1E9GA	1R4PA	1EAZA	4EUGA	1N13B	1XEOA	1AGQD	1RYLA	1X9RB	1PMHX
1ME4A	1OQVA	1CZPA	1JKUA	1R26A	1YPQA	1EW4A	1TZVA	1BXYA	1IT2A	1NP6B	1WDVA
1M4LA	1O7QA	1UWKB	1ZK4A	1I71A	1KS8A	1YC5A	1PWBC	1FX4A	1JHJA	1IKOP	1USPA
1PJXA	1QNRA	1O08A	1XQOA	1ZKKb	1PKHA	1HZ4A	1G8AA	1OTFA	1MAVA	1ZB1A	1Z3XA
1G6XA	1ST9B	1UCRB	1Y93A	1XD3C	1M7GD	1HLQC	1NYCA	1NH2B	1OU8A	1SUMB	1UGPA

1F9YA	1BQCA	1RMWA	1R0RI	1Z1SA	1OS6A	1SMOB	1V7RA	1V83A	1UEBB	1Y96D	1SMBA
1IX9A	1MUWA	1NXMA	1H4AX	1XRKB	1GVDA	1RKUA	1T7RA	1FIPA	1EARA	1S14B	1ZXUA
1G66A	1MN8B	1LQ9A	1TU9A	1VYIA	1O9RA	1PVMA	1MNNA	1B0NB	1OA8A	1Y50A	1IZMA
2PVBA	1CXQA	1WPNA	1SENA	1ISUA	1TKEA	1ELKA	1C1KA	1B0NA	1UB4A	1Z5ZA	1UV7A
1J0PA	1NH0A	1XUBA	1FYEA	1UV4A	1F7LA	1BX4A	1IDPA	1T06A	1F32A	1EAYD	1HRUA
1MJ5A	1LQTB	1E7LA	2BMOA	1YBIA	1TP6A	1NN5A	1G6UA	1R8HC	3HTSB	1I1WA	1G55A
7A3HA	1RQWA	1SJWA	2BMOB	2BKVB	1X91A	1DP7P	1P1MA	1OAPA	1YSPA	1DY5A	1CI4A
1UFYA	1XJUB	1GYXA	1OOHA	1YN9C	1LUC A	1SHUX	1LMIA	1UW1A	1K6KA	1XG0C	1J5UA
1O7JA	1T8KA	1OH4A	1QWYA	1DQZA	1G9OA	1LK9B	1IV3A	1UW4B	1UUZA	1MWQA	1WKCA
1PSRA	1QV1A	1EAJA	1RUTX	1T1UA	1V5IB	1OQJB	1MG7A	1LDDA	1LC7A	1HX0A	1KW4A
1PWGA	1Z2UA	2LISA	1TJYA	1DK8A	1DCIA	1YXYB	1W4SA	1XIZA	1DQEA	1VR7A	1Y71A
1JBEA	2BHUA	1J0OB	1VMHA	1P5ZB	1M65A	1T9IB	3PVIA	1H6KZ	1Y02A	1MJUH	1O1XA
1UOZA	1QL0A	1LLFA	1V0WA	1TQJC	1XG4B	1EUVA	1FR2A	1BYS A	1T0FD	1GMXA	1RW1A
1OC7A	1GWMA	1K0MA	1VKKA	1S95A	1ELWB	1RC9A	1O26A	1H8EI	1T15A	1H4XA	1XDNA
1JM1A	1LB3A	1Q92A	1M1FB	1P0ZA	1R5RA	1B5EA	1T1VA	1OR7F	1F5MB	1WY3A	1VMGA
1SAUA	3CHBH	1OCYA	1LTZA	1H2CA	1KQFB	1G8QA	2CPGA	1TXJA	1QA7A	2BF9A	1Z72B
1K7CA	1GXUA	1HT6A	1OBDA	1SWXA	1KQFC	1DBWA	1ID0A	2BSZB	1QOUB	1I8OA	1WHZA
1P6OB	1KA1A	1RP0A	1UUYA	1DOS A	1X6OA	1NC5A	1MK0A	1HBKA	1Y7PB	1PQHA	1S9UA
1OJRA	1QDDA	1XM8A	1W1HB	1M9XC	1HTRP	1XTEA	1E6BA	1HG2A	1I1WA	1K55C	1YQHA
1WB4A	1G61A	1VKBA	1LO7A	1Y63A	1KCQA	1D0DA	1UD9D	1TAFA	1JHSA	1H4GA	1Y0UA
1NOFA	1R29A	1NKIA	1DJ0A	1XVYA	2BJFA	1CXYA	1K94A	2BKQC	1UI SA	1QU9A	1SBXA
1NWZA	1JHGA	1C7KA	1QWOA	1KPTA	1VMBA	1IBYA	1T1JA	1PY0A	1D2ZB	1NZ0B	1LR0A
1OEWA	1GXMB	1OAIA	1NF9A	1QWDA	1OSYA	1HZ6B	1S5UG	1UUTA	1MI8A	1QQFA	1UWWA
1VYRA	1Q7LA	1YFQA	1HQ1A	1YACA	1QY1A	1RH6A	1KZQA	1MZWB	1EL6A	1Z67A	1YR0A
1C75A	1Q7LD	1YS1X	1VHWE	1XU1S	1YMKA	1ECSA	1H75A	1L8JA	1RW0A	1Y1JX	1FG7A
1UG6A	1M0KA	1RG8A	2BEMA	1YVIB	1EW2A	1EIZA	1HTWA	1JF8A	1OH0B	1QPAA	1YB3A
1Q6ZA	1HD2A	1SU8A	1K92A	1O94D	1RY9A	1PFVA	1YY6A	1OXDA	1LF7A	1W2WB	1UARA
1GKMA	1X6ZA	1LU4A	1HFES	1SCJB	1Q08A	2BIIB	1FVKA	1USMA	1RYOA	1YG9A	1LXJA
1LNIA	1L9LA	1XODB	1AY7B	1HJLA	1XEDE	1O5FL	1DSZA	1RTTA	1JL1A	1K3IA	1WGBA
1KR4A	1NJHA	1RO7A	1K3SA								

5.2.2 编码策略

对于 π 转角预测, 我们测试了 5 种编码策略: 单序列, 单序列加预测的二级结构, 多序列比对信息, 多序列比对信息加预测的二级结构, 多序列比对信息加实际的由 DSSP 确定二级结构信息。我们依然采用经典的描述蛋白质局部序列信息的移动窗口编码策略。当仅使用单个序列的信息作为输入时, 每一种氨基酸都用正交编码, 对于空缺残基, 用 20 个零组成的向量表示。而当用多序列联配信息作为输入时, 我们使用由 PSI-BLAST 产生的 PSSMs 作为输入。二级结构也用正交编码。

5.2.3 预测后过滤

与预测 α 转角一样， π 转角预测也使用两种过滤规则，即 “state-shifting” 规则和 “state-flipping” 规则。

因为 π 转角是连续的 6 肽。我们使用的 “state-flipping” 规则如下。首先，将所有孤立的非 π 转角预测转变成 π 转角预测；其次，将所有孤立的 π 转角预测、孤立的连续 2 个 π 转角预测、孤立的连续 3 个 π 转角预测、孤立的连续 4 个 π 转角预测都转变成非 π 转角预测；最后，对于孤立的连续 5 个 π 转角预测，则将相邻的具有较低的预测可信度的非 π 转角预测转变成 π 转角预测。

5.3 预测的可信度

预测可信度(RI)是对用机器学习方法预测的结果进行评价的一个很重要的指标。通过分析预测可信度可以很容易识别预测结果高度可靠的区域。预测可信度采用公式 3.2 所示的定义。预测可信度与预测敏感度和特异度的关系见图 5.1。




图 5.1 预测可信度与预测敏感度和特异度的关系

如图 5.1 所示，当预测可信度小于 2 时，预测敏感度和预测特异度都受 “state-shifting” 过滤规则的影响，提高了预测的敏感度，降低了预测的特异度。当预测可信度大于 2 时，可信度越高，预测的特异度越高。

5.3.1 预测性能评价参数

预测性能是通过 7-折交叉验证来进行评价的。将数据集随机分成大小近似相等的 7 组。SVM 分类器用其中的 6 组进行训练，剩下的一组进行测试。该过程将进行 7 次，每一次使用一组不同的测试集。为了评价预测性能，我们使用四个常用来对转角预测性能进行评价的指标：(1) Q_{total} ，用来表示总的预测正确率；(2) $Q_{predicted}$ 用来表示预测的灵敏性；(3) $Q_{observed}$ 用来表示预测的选择性；(4) MCC 可同时表示预测的灵敏性和选择性，用它反映预测性能有较好的鲁棒性。另外，还有一个参数 S 将该方法与随机预测进行比较。

因为 π 转角是 6 个残基的片断，因此我们还用来另一个参数 SOV 对上述 5 种评价参数进行补充。不同于以上 5 种从单个残基角度评价预测性能的评价参数，SOV 是用来从片断的角度评价预测性能。它用下式计算：

$$SOV = \frac{1}{N} \sum_s \frac{\min ov(s_1, s_2) + \delta(s_1, s_2)}{\max ov(s_1, s_2)} \times len(s_1) \quad (5.1)$$

其中， s_1 和 s_2 是实际的和预测的 π 转角； $\min ov(s_1, s_2)$ 是 s_1 和 s_2 实际的重叠长度； $\max ov(s_1, s_2)$ 是片断 s_1 和 s_2 都有一个残基在 π 转角中的总长度； $len(s_1)$ 是 s_1 的残基数； N 是 π 转角中总的残基数。 $\delta(s_1, s_2)$ 定义为：

$$\delta(s_1, s_2) = \min((\max ov(s_1, s_2) - \min ov(s_1, s_2)); \min ov(s_1, s_2); \text{int}(len(s_1)/2); \text{int}(len(s_2)/2)) \quad (5.2)$$

5.4 结果与讨论

5.4.1 π 转角位置特异的氨基酸倾向性研究及类别分析

我们的数据集中总共有 1931 个 π 转角，是 Rajashankar and Ramakumar 研究中分析的 π 转角数的 4 倍，因此计算最新的 π 转角位置特异的氨基酸倾向性与总的氨基酸倾向性等统计特征是有必要的。计算位置特异的氨基酸倾向性的公式如方程 3.11。结果如表 5.2 所示。

表 5.2. π 转角位置特异的氨基酸倾向性

Amino acids	Positional						Overall		Difference %
	i	i+1	i+2	i+3	i+4	i+5	Present	Earlier ^a	
Ala	2.02	1.12	1.54	1.29	0.37	1.00	1.22	1.27	-3.43
Cys	2.05	0.92	0.43	0.83	0.73	1.12	1.01	0.91	9.69
Asp	0.87	0.80	1.00	0.60	0.77	0.52	0.76	0.74	2.06
Glu	0.44	1.42	2.10	0.89	0.57	0.68	1.02	1.06	-3.93
Phe	1.22	0.53	0.41	0.91	0.54	1.31	0.82	0.88	-7.42
Gly	0.47	0.39	0.56	0.55	6.34	1.45	1.63	1.51	7.22
His	0.85	1.32	0.60	1.64	0.89	0.79	1.02	1.41	-38.44
Ile	0.96	1.22	0.43	0.57	0.29	1.55	0.84	0.85	-2.36
Lys	0.52	1.67	1.81	1.21	1.07	1.15	1.24	1.28	-3.45
Leu	2.14	1.17	0.73	1.47	0.43	1.50	1.24	1.21	1.92
Met	1.82	0.78	1.26	1.31	0.34	1.19	1.12	1.23	-10.22
Asn	0.79	0.78	1.14	1.54	1.92	0.73	1.15	1.02	11.64
Pro	0.21	0.60	0.31	0.18	0.12	0.07	0.25	0.18	25.75
Gln	0.70	1.28	1.80	1.20	0.74	0.75	1.08	1.15	-6.52
Arg	0.65	1.60	1.43	1.20	0.83	0.84	1.09	1.12	-2.81
Ser	0.97	0.76	1.23	1.11	0.38	0.59	0.84	0.68	19.52
Thr	0.48	0.77	0.67	1.11	0.30	0.70	0.67	0.60	10.06
Val	0.74	0.96	0.48	0.71	0.31	1.35	0.76	0.78	-3.47
Trp	1.73	0.90	0.50	0.53	0.43	0.90	0.83	0.99	-19.03
Tyr	1.04	0.79	0.62	1.17	0.39	1.28	0.88	0.90	-1.59

^a Earlier 指 Rajashankar and Ramakumar 的研究工作^[87]

总的氨基酸倾向性与以前的研究有显著区别的是脯氨酸（增加~26%），丝氨酸

(~20%), 天冬酰胺 (~12%), 下降的有组氨酸 (降低~38%), 氨酸 (~19%)。至于 π 转角位置特异的氨基酸倾向性, 也与以往研究有显著区别。 π 转角的第 I 和第 I+5 位置的残基主要由亲水氨基酸占据。I+1 位置出现频率最高的氨基酸是赖氨酸, 接着是精氨酸和谷氨酸。I+2 位置出现频率最高的氨基酸是谷氨酸, 接着是赖氨酸和谷氨酰胺。I+3 位置出现频率最高的氨基酸则是组氨酸。甘氨酸在 I+5 位置出现频率极高。

π 转角是根据第 I+5 位的残基的二面角来分类的。 π 转角分为四类。如果第 I+5 位的残基的位于 Ramachandran 构想图的 α_R 区域, 则 π 转角属于 π_{α_R} 型; 如果第 I+5 位的残基的位于 Ramachandran 构想图的 α_L 区域, 则 π 转角属于 π_{α_L} 型; 如果第 I+5 位的残基的位于 Ramachandran 构想图的 α_R 区域, 则 π 转角属于 π_{α_R} 型。 π 转角的位置特异的二级结构组成见表 5.3。

表 5.3 π 转角的位置特异的二级结构组成

Position	i	i+1	i+2	i+3	i+4	i+5
No. of -turn residues in 'G' state	35	140	139	127	9	38
No. of -turn residues in 'H' state	1556	1539	1455	621	175	115
No. of -turn residues in 'I' state	0	0	0	0	0	0
No. of -turn residues in 'B' state	27	7	1	1	3	33
No. of -turn residues in 'E' state	156	9	2	0	8	193
No. of -turn residues in 'S' state	20	3	4	15	8	247
No. of -turn residues in 'T' state	50	222	315	1153	1696	150
No. of -turn residues in 'C' state	87	11	15	14	32	1155

5.4.2 核函数选取与参数优化

核函数选取与参数优化对支持向量机的分类性能有重要影响。根据以往的研究, 径向基核和其它核如多项式核相比有更好的性能^[19, 20], 因此, 我们选择径向基核。因此, 待优化的参数是 γ 和 C。因为非 π 转角残基数与 π 转角残基数之比为: 9: 1,

所以还需要确定另一个参数 j 。参数 j 的主要作用是通过设定不同的惩罚参数 C_+ 和 C_- 来调节预测的灵敏性和选择性之间的平衡。 $C_+/C_- = N_-/N_+$ ，其中 N_- 是非 π 转角残基数， N_+ 是 π 转角残基数。这里， j 设定为 9。我们用 7-折交叉验证来选择参数，结果如表 5.3 和表 5.4 所示，预测性能在 $\gamma = 0.0625$, $C=5$ 时最好。

表 5.4 使用相同 C 参数不同 γ 参数时的预测性能比较

γ	Q_{total}	$Q_{\text{predicted}}$	Q_{observed}	MCC
0.0078	78.6	28.7	80.8	0.389
0.0186	82.9	33.6	73.5	0.417
0.0365	92.5	61.8	52.7	0.529
0.0625*	92.9	66.4	51.9	0.550
0.0925	93.0	71.8	46.5	0.542
0.125	93.1	72.8	44.4	0.535

结果是在设置 $j=9$ 和 $C=2$ 时取得的。使用了“state-shifting”规则，所有 $\text{abs}(D)<0.4$ 的非转角预测都转换成转角预测

表 5.5 使用相同 γ 参数不同 C 参数时的预测性能比较($j=9$, $\gamma=0.0625$)

C	Q_{total}	$Q_{\text{predicted}}$	Q_{observed}	MCC
1	92.6	62.9	54.3	0.545
2	92.9	66.4	51.9	0.550
5*	93.1	68.7	50.9	0.556
10	93.0	68.3	50.7	0.552
50	92.6	62.4	52.6	0.533

使用了“state-shifting”规则，所有 $\text{abs}(D)<0.4$ 的非转角预测都转换成转角预测

5.4.3 窗口长度优化

因为我们使用了经典的移动窗口编码策略，所以需要确定窗口长度。一个合适的窗口长度将能取得更好的预测性能。太短的窗口长度会造成信息丢失，但是通过增加窗口长度来提高预测正确率有一个上限，因为太长的窗口长度会降低信噪比。我们测试了 7—13 不同的窗口长度。测试结果见表 5.6。

表 5.6 使用不同窗口长度的预测性能

	l=7	l=9	l=11	l=13
$Q_{\text{predicted}}$	65.5 ± 2.5	65.4 ± 2.8	68.7 ± 2.7	66.1 ± 2.6
Q_{observed}	51.5 ± 1.6	53.1 ± 1.9	50.9 ± 1.9	49.1 ± 1.5
MCC	0.542 ± 0.019	0.551 ± 0.021	0.556 ± 0.021	0.532 ± 0.020

5.4.4 处理两类样本不均衡

数据集的不均衡给用机器学习方法进行分类制造了很大的障碍。处理此问题主要有两种策略。第一种策略是采用重采样来平衡数据集，即去掉一定数量的样本数较多的那一类的数据，或增加一定倍数的样本数较少的那一类的数据。但是当使用自然状态的测试数据（正类样本与负类样本不平衡）去检验使用了重采样技术训练的分类器时，就会发现该分类器对原本样本数较多的那一类的预测正确率降低。第二种策略是采用我们在预测以氢键定义的 α 转角时提出的两步法。首先，在训练时，通过参数 j 对样本数不平衡的正类样本和负类样本采用不同的惩罚参数 C_+ 和 C_- 。其次，在决策阶段用“state-shifting”规则对预测结果进行过滤。

使用不同的“state-shifting”规则对预测性能的影响见图 5.2 和图 5.3。如图 5.2 所示，当使用 $NT < 0.4$ 的规则对结果过滤时，预测性能最好。图 5.3 显示了“state-shifting”规则对预测的灵敏性和选择性的调节作用。随着门限值的增加，预测的特异性下降，预测的灵敏性增加。




图 5.2 ‘state-shifting’规则对 MCC 的影响




图 5.3 ‘state-shifting’规则对预测正确率的影响

5.4.5 不同编码策略对预测性能的影响

我们测试了四种不同的输入对预测性能的影响，即单个序列信息、单个序列信息加上预测的二级结构信息、多序列联配信息、多序列联配信息加上预测的二级结构信息、多序列联配信息加上真实的二级结构信息。预测结果见表 5.7。

如表 5.7 所示，当用多序列联配信息代替单个序列信息作为输入时，预测性能得到极大的提高。没有加上预测的二级结构信息时效果更明显，MCC 从 0.274 增加到 0.532， Q_{total} 从 84.4% 增加到 92.8%。PSSMs 对预测性能的提升作用也表现在其它转角的预测中。这主要是因为 PSSMs 包含了一个残基出现在一个序列的某一位置是否保守

的信息。

预测的二级结构信息进一步提高了预测性能。没有包括多序列联配信息时，二级结构对性能的影响更明显，MCC 从 0.274 增加到 0.341。当使用多序列联配信息加上预测的二级结构信息作为输入时，SVM 分类器达到最终的 MCC 为 0.556，SOV 为 0.518，S 为 0.546。当使用真实的二级结构信息作为输入，达到最终的 MCC 为 0.571。

本方法的优良性能主要源于以下三方面的原因。首先是因为支持向量机有良好的分类性能，其次是因为使用了两步法来处理样本不平衡，最后是因为综合使用了多序列联配信息和预测的二级结构信息。

表 5.7. 不同编码策略产生的试验结果

Method	$Q_{\text{predicted}}$	Q_{observed}	MCC	S
(1)	29.2 ± 0.8	44.2 ± 1.1	0.274 ± 0.012	0.267 ± 0.011
(2)	36.3 ± 1.4	46.7 ± 1.3	0.341 ± 0.014	0.338 ± 0.013
(3)	65.8 ± 2.8	49.3 ± 1.5	0.532 ± 0.020	0.526 ± 0.021
(4)	68.7 ± 2.7	50.9 ± 1.9	0.556 ± 0.021	0.546 ± 0.020
(5)	69.2 ± 2.9	53.1 ± 1.8	0.571 ± 0.022	0.564 ± 0.022

结果基于以下编码策略：


(1) 单序列信息 (2) 单序列信息加预测的二级结构信息 (3) 多序列比对信息; (4) 多序列比对信息加预测的二级结构信息(5) 多序列比对信息加实际的二级结构信息

因为这是首次预测 π 转角，因此没有值可以用来直接与本方法进行比较。但是，考虑到 β 转角预测与 π 转角预测的相似性，以及 β 转角是预测性能最好的转角，所以我们将本方法与 β 转角预测方法进行比较。当使用单序列信息作为输入时，本方法所得到的预测性能不如 β 转角预测方法 BetaTPred2^[64] 和 BetaTurn^[62]。主要原因可能是 π 转角在蛋白质中的含量比 β 转角低较多，即训练数据中正负样本数更不平衡。但是奇怪的是当使用多序列比对信息作为输入时，本方法所得到的预测性能却比 β 转角预测方法 BetaTPred2^[64] 和 BetaTurn^[62] 所获得的预测性能好得多。换句话说，多序列比对信息对 π 转角预测提升性能的作用大于对 β 转角预测提升性能的作用。我们认为主要原因是因为 π 转角和 β 转角不同的二级结构组成导致的， π 转角有

47%的残基位于螺旋结构，而 β 转角大部分残基位于无规卷曲。螺旋结构在进化过程中比无规卷曲更为保守。

5.5 PiTurn 网络服务

我们开发了被称为 PiTurn 的网络服务来从一级序列预测 π 转角。网址是：<http://210.42.106.80/piturn/>。输入单字母编码的氨基酸序列，输出标记预测结果（ π 转角或非 π 转角）及相应的可靠度。图 5.4 是 π 转角在线预测的界面。图 5.5 是蛋白质 1dbwA 的预测结果。



The screenshot shows a web browser window with the title "Pi-Turn V1.0". Below the title, it says "Pi-turn prediction with support vector machine." The form contains three input fields: "Please input your sequence's name: (Optional)" with the value "test", "Please input your Email. (required)" with the value "yanw@mail.hust.edu.cn", and "Please input your sequence: (in plain text and required)" with a long amino acid sequence. There are "Submit" and "Clear" buttons at the bottom.

Pi-Turn V1.0

Pi-turn prediction with support vector machine.

Please input your sequence's name: (Optional)
test (not more than 15 characters)

Please input your Email. (required) [Help](#)
yanw@mail.hust.edu.cn

Please input your sequence: (in plain text and required) [Help](#)
NVYHDGACPEVKPVDNFDWSNYHGKWEVAKYPNSVEKYGRGWA EYTPGKSVKVSNYHVIHGKEYFIEGT

图 5.4 Pi-Turn 网络服务界面

PiTURN PREDICTION RESULT:

```
SEQUENCE:  MQDYTVHIUDDEEPVRKSLAFMLTMNGFAUKMHQSAEAFALAFAPDVRNGV
PREDICT:  -----pppppp-----
RINDEX:    655655987566889999985655553476666666789898466766995

SEQUENCE:  LUTDLRMPDMSGUELLRNGLDLKINIPSIUITGHGDUPMAVEAMKAGAVD
PREDICT:  -----pppppp--
RINDEX:    67786543323567899733322386998997667566779703334234

SEQUENCE:  FIEKPFEDTVIIEAIERASEHLV
PREDICT:  -----
RINDEX:    66765578888997978543335
```

图 5.5 蛋白质 1dbwA 的预测结果

该预测是对蛋白质 1dbwA(123 残基)进行的。使用的输入信息时 PSSMs 和预测的蛋白质二级结构。预测结果以 50 个残基为一组显示。对于每一组，第一行是氨基酸序列；第二行表示 π 转角/非 π 转角预测 s(p= π 转角预测，‘-’=非 π 转角预测)；第三行是预测的可信度。

5.6本章小结

我们开发一个基于支持向量机的从氨基酸序列出发预测 π 转角的可靠方法。这是首次提出关于 π 转角预测的方法。使用进化信息 (PSSMs) 加上预测的二级结构信息作为输入时，SVM 分类器达到最终的 MCC 为 0.556。我们也注意到进化信息 π 转角预测的贡献大于对 β 转角预测的贡献。因此，尽管 π 转角预测训练数据中正负样本数更不平衡，但 π 转角预测所取得的预测性能却高于 β 转角预测。此外，该方法能与其它二级结构预测方法互补，本文计算出的新的 π 转角位置特异的氨基酸倾向性可用于 π 转角的建模与设计。

6 蛋白质与 RNA 相互作用位点预测

6.1 引言

RNA 在细胞内的许多生物过程中扮演重要角色。它肩负着将遗传信息从 DNA 传到蛋白质的任务，为蛋白质的合成转运氨基酸，是核糖体的重要组成部分。这些活动都是通过与蛋白质相互作用实现的。因此，了解 RNA 与蛋白质相互作用的特异性对于深入理解这些生命过程是至关重要的。

关于蛋白质与 RNA 相互作用区域的物理化学性质研究已经有较长的历史。Draper 讨论了两主要的蛋白质与 RNA 相互作用模式^[102-103]。第一种模式称作“螺旋沟绑定”，即蛋白质通过将某种二级结构 α -螺旋、 3_{10} -螺旋、 β 折叠或无规卷曲结构放入一个 RNA 螺旋沟中实现与 RNA 的对接，蛋白质识别特异的 RNA 序列和特定的 RNA 螺旋沟的形状。第二种模式是蛋白质通过 β 折叠形成一个带状结构与单链 RNA 作用。在第二种模式中一些蛋白质识别完全无序的 RNA，还有一些情况下 RNA 通过形成二级结构通过限制对接的方向来促进对接。热力学研究表明对接特异性是由几个因素决定的，如氢键、非极性相互作用、分子表面形状。Jones^[106]等计算分析了 32 个蛋白质和 RNA 相互作用界面的物理化学性质。RNA 与蛋白质结合界面的面积从 $370\text{\AA}^2$ 到 $2422\text{\AA}^2$ 不等，由 3 至 24 个序列片段组成。每 $\text{\AA}^2$ 的界面包括 5 至 26 个分子间氢键，不过范德华力更普遍。另外，带正电荷的氨基酸 Arg，芳香族氨基酸 Phe, Tyr 在 RNA 与蛋白质结合位点扮演重要角色。Kim^[111]等计算分析了蛋白质与 RNA 相互作用中的氢键，揭示了几条有趣的规律。(1) 尽管 β 折叠中的氨基酸倾向于和单链核酸作用，而螺旋结构中的氨基酸并没有什么倾向性，转角中的氨基酸则倾向于和双链核酸作用。(2) 在双链核酸中，骨架氢键比碱基氢键出现的次数多，而在单链核酸中，则相反。(3) 蛋白质和 RNA 的复合体中包含更多的双链 RNA，但是单链 RNA 更容易和蛋白质发生作用。(4) Arg-U, Thr-A, Lys-A, Asn-U 是最常出现的作用模式。

比较而言，关于蛋白质与 RNA 相互作用位点的预测却是近几年才开始的。主要原因是已经测得结构的蛋白质和 RNA 的复合体的数量较少。Jeong (2004)^[107]等用神经网络预测蛋白质与 RNA 相互作用位点，使用的输入单序列加预测的二级结构。2006

年他们通过使用附权的序列谱改进了预测性能^[108]。最近, Terribilini^[115]提出了基于贝叶斯统计的计算方法来预测哪些氨基酸参与蛋白质与 RNA 相互作用。Wang 和 Brown 提出了基于支持向量机的以联合的序列特征作为输入信息的预测方法^[117]。

本研究综合使用支持向量机和 PSSMs 来预测蛋白质与 RNA 相互作用位点,取得了迄今为止, 蛋白质与 RNA 相互作用位点预测最好的预测性能。我们考虑了两种情况, (1) 仅仅知道与 RNA 相互作用的蛋白质的序列信息。(2) 已知与 RNA 相互作用的蛋白质的结构信息。

6.2 实验数据

表 6.1 数据集

链数	类型	PDB IDs
55	rRNA	1DFU:P, 1FEU:A, 1FJG:B, 1FJG:C, 1FJG:D, 1FJG:E, 1FJG:G, 1FJG:I, 1FJG:J, 1FJG:K, 1FJG:L, 1FJG:M, 1FJG:N, 1FJG:P, 1FJG:Q, 1FJG:S, 1FJG:T, 1FJG:V, 1G1X:A, 1G1X:B, 1G1X:C, 1G1X:G, 1HRO:W, 1I6U:A, 1JBR:A, 1JJ2:1, 1JJ2:2, 1JJ2:A, 1JJ2:B, 1JJ2:C, 1JJ2:D, 1JJ2:E, 1JJ2:F, 1JJ2:G, 1JJ2:H, 1JJ2:I, 1JJ2:J, 1JJ2:K, 1JJ2:L, 1JJ2:M, 1JJ2:O, 1JJ2:P, 1JJ2:Q, 1JJ2:R, 1JJ2:S, 1JJ2:T, 1JJ2:U, 1JJ2:V, 1JJ2:W, 1JJ2:X, 1JJ2:Y, 1JJ2:Z, 1MMS:A, 1MZP:A, 1UN6:B
23	mRNA, snRNA, dsRNA, siRNA	1A9N:A, 1AV6:A, 1DI2:A, 1E7K:A, 1E80:A, 1E80:B, 1EC6:A, 1FXL:A, 1GTF:Q, 1JID:A, 1KNZ:A, 1KQ2:A, 1LNG:A, 1M8V:A, 1MFQ:C, 1OOA:A, 1RC7:A, 1RPU:A, 1SI3:A, 1SO3:G, 1URN:A, 1UVJ:A, 2A8V:A
19	tRNA	1ASY:A, 1B23:P, 1COA:A, 1EIY:A, 1EIY:B, 1F7U:A, 1FFY:A, 1GAX:A, 1H3E:A, 1J1U:A, 1J2B:A, 1K8W:A, 1N78:A, 1Q2R:A, 1QF6:A, 1QTQ:A, 1R3E:A, 1SER:A, 2FMT:A
12	viral	1A34:A, 1DDL:A, 1E6T:A, 1F8V:A, 1H2C:A, 1LAJ:A, 1N34:A, 1NB7:A, 1PGL:2, 1RMV:A, 2BBV:C, 2BBV:F

本研究使用的数据是 Terribilin 等提供的数据。该数据由 109 条蛋白质链组成,

其中每两条链之间的相似性小于 30%。这 109 条蛋白质链属于 56 个由 X 射线衍射技术决定的蛋白质和 RNA 的复合体，测定精度大于 3.5 埃，见表 6.1。56 个蛋白质和 RNA 的复合体的 PDB 码见表 1。与 RNA 相互作用的氨基酸是用软件 ENTANGLE 确定。与 RNA 相互作用的氨基酸占 109 条蛋白质链所有氨基酸总数的 14%。

6.3 编码

如上所述，我们考虑了两种情况，(1) 仅仅知道与 RNA 相互作用的蛋白质的序列信息。(2) 已知与 RNA 相互作用的蛋白质的结构信息。在第一种情况下，我们测试了 4 种编码策略：单序列，单序列加预测的二级结构，多序列比对信息，多序列比对信息加预测的二级结构信息。我们依然采用经典的描述蛋白质局部序列信息的移动窗口编码策略。当仅使用单个序列的信息作为输入时，每一种氨基酸都用正交编码，对于空缺残基，用 20 个零组成的向量表示。而当用多序列联配信息作为输入时，我们使用由 PSI-BLAST 产生的 PSSMs 作为输入。二级结构也用正交编码。在第二种情况下，我们使用多序列比对信息加实际的二级结构和残基的水溶性信息作为输入，对于残基的水溶性信息用下式计算：

$$RSA_i = \frac{SA_i}{MSA_i} \quad (6.1)$$

其中 SA_i 表示用 DSSP 算出的残基与溶剂的接触面积， MSA_i 表示在伸展的三肽 Ala-X-Ala 结构种该残基与溶剂的接触面积。

6.4 预测性能评价

预测性能是通过 7-折交叉验证来进行评价的。将数据集随机分成大小近似相等的 7 组。SVM 分类器用其中的 6 组进行训练，剩下的一组进行测试。该过程将进行 7 次，每一次使用一组不同的测试集。除了使用 Q_{total} 、 $Q_{predicted}$ 、 $Q_{observed}$ 、MCC 来评价预测性能外，我们还用了 ROC(receiver operating characteristic) 曲线图来评价预测性能。ROC 曲线具有非门槛依赖性。ROC 曲线下的面积能很好的反映预测性能。对于随机预测该值为 0.5，对于一个完美预测，该值为 1。

6.5 结果与讨论

6.5.1 RNA 结合位点的序列特征

我们计算了这 109 条非同源蛋白质链的 RNA 结合位点的氨基酸倾向性因子。该倾向性因子可以表示不同氨基酸在蛋白质与 RNA 相互作用中的重要性。氨基酸倾向性因子用方程 6.2 计算

RNA 结合位点的氨基酸倾向性因子 AA_j =

$$\frac{\sum_{i=1}^{N_i} ASA_{AAj(i)} / \sum_{i=1}^{N_i} ASA_{(i)}}{\sum_{i=1}^{N_s} ASA_{AAj(s)} / \sum_{i=1}^{N_s} ASA_{(s)}} \quad (6.2)$$

其中 $ASA_{AAj(i)}$ 是 RNA 结合界面的氨基酸 j 的总的溶液接触面积； $ASA_{(i)}$ 是 RNA 结合界面所有氨基酸残基的溶液接触面积的和； $ASA_{AAj(s)}$ 是蛋白质表面的氨基酸 j 的总的溶液接触面积； $ASA_{(s)}$ 是蛋白质表面的所有氨基酸残基的溶液接触面积的和； N_i 是 RNA 结合界面的氨基酸残基总数； N_s 是蛋白质表面的所有氨基酸残基总数。

氨基酸倾向性因子大于 1 表示该氨基酸在 RNA 结合界面出现的几率大于在蛋白质表面出现的几率。图 6.1 给出了 109 条非同源蛋白质链的 RNA 结合位点的 20 种氨基酸倾向性因子。




图 6.1 RNA 结合界面 20 种氨基酸的倾向性因子

从图 6.1 可以看出几个带正电的氨基酸精氨酸、赖氨酸、组氨酸在蛋白质与 RNA 相互作用界面上出现的几率较高, 另外, 色氨酸出现的几率也较高。而带负电的氨基酸天冬氨酸、谷氨酸出现在蛋白质与 RNA 相互作用界面上出现的几率则较低, 另外, 疏水氨基酸丙氨酸、缬氨酸、苯丙氨酸、亮氨酸、异亮氨酸、脯氨酸出现的几率也较低。

6.5.2 预测系统的参数优化

因为我们使用支持向量机来构建分类器, 因此只需要对核与相应的参数进行选择。根据以往的研究, 径向基核相对于多项式核、指数核性能更优异, 因此, 本研究也采用径向基核。因此待定的参数为核参数 γ 和调控参数 C 。优化过的 $\gamma = 0.0625$, $C=5$ 。因为与 RNA 相互作用的氨基酸与不与 RNA 相互作用的氨基酸之比为 1: 6。所以, $j=6$ 。

6.5.3 窗口长度的优化

因为我们使用了经典的移动窗口编码策略, 所以需要确定窗口长度。一个合适的窗口长度将能取得更好的预测性能。太短的窗口长度会造成信息丢失, 但是通过增加窗口长度来提高预测正确率有一个上限, 因为太长的窗口长度会降低信噪比。我们测试了 11—19 不同的窗口长度。测试结果见表 6.2。从表 6.2 可以看出 $L=15$ 时, 预测性能最好, 因此选择窗口长度为 15 个氨基酸。

表 6.2 使用不同窗口长度的预测性能

	L=11	L=13	L=15	L=17	L=19
Total accuracy (%)	86.8	87.0	87.1	87.0	86.8
Accuracy (%)	54.3	55.1	55.9	55.4	54.7
Coverage (%)	44.7	45.2	45.6	45.4	44.8
MCC	0.419	0.425	0.432	0.428	0.421

6.5.4 不同的编码策略对预测性能的影响

已知与 RNA 相互作用的蛋白质的序列信息时的四种输入方式和已知与 RNA 相互作用的蛋白质的结构信息时的一种输入方式对预测性能的影响见表 6.3。如表 6.3 所示, 已知与 RNA 相互作用的蛋白质的序列信息时, 当用多序列联配信息代替单个序列信息作为输入时, 预测性能得到极大的提高。MCC 从 0.268 增加到 0.429, Q_{total} 从 82.1% 增加到 87.0%。PSSMs 对预测性能的提升作用最早是由 Jones 等在预测蛋白质二级结构时提出的。这主要是因为 PSSMs 包含了一个残基出现在一个序列的某一位置是否保守的信息。

预测的二级结构信息对 RNA 结合位点预测的预测性能的提升作用极小。但是当已知与 RNA 相互作用的蛋白质的结构信息时, 我们取得了最好的 MCC 值 0.457, 使用的输入信息为多序列比对信息, 实际的二级结构信息和残基的水溶性信息。

表 6.3 不同编码策略的预测性能

Method	Total accuracy (%)	Accuracy (%)	Coverage (%)	MCC
(1)	82.1	37.2	37.4	0.268
(2)	82.5	38.3	37.9	0.279
(3)	87.0	55.5	45.4	0.429
(4)	87.1	55.9	45.6	0.432
(5)	87.4	58.0	48.2	0.457

结果基于以下编码策略:

(1) 单序列信息; (2) 单序列信息加预测的二级结构信息; (3) 多序列比对信息; (4) 多序列比对信息加预测的二级结构信息; (5) 多序列比对信息加实际的二级结构信息和残基的水溶性信息

我们还用 ROC 曲线下的面积(域值独立的评价)来评价了 SVM 模型的性能。图 6.2 给出了 5 种输入下的 ROC 曲线。相应的 ROC 曲线下的面积分别是: 单序列信息, 0.7188; 单个序列信息加上预测的二级结构信息, 0.7251; 多序列联配信息, 0.8248; 多序列联配信息加上预测的二级结构信息, 0.8251; 多序列联配信息加上真实的二级结构信息和残基可溶性信息, 0.8357。这说明当已知与 RNA 相互作用的蛋白质的序列信息时, 以多序列联配信息加上预测的二级结构信息作为输入时, 预测性能最好; 而显然已知

与 RNA 相互作用的蛋白质的结构信息时的预测性能要优于已知与 RNA 相互作用的蛋白质的序列信息时的预测性能。




图 6.2 SVM 预测的 ROC 曲线

6.5.5 与其它预测方法的比较

Jeong 和 Miyano 比较了三种由 PSI-BLAST 产生的附权的序列轮廓作为输入对预测蛋白质与 RNA 相互作用位点的影响。最好的预测性能是用附权的位置特异性分值矩阵 (PSSM) 作为输入, MCC 为 0.41。而我们的模型当用 PSSMs 作为输入时, MCC 是 0.43, 并且因为我们所用的蛋白质序列之间的相似性小于 30%, 而 Jeong 和 Miyano 使用的蛋白质序列之间的相似性仅小于 70%, 即我们使用了更严格的域值来挑选非同源蛋白质, 所以, 我们的方法的预测性能优于 Jeong 和 Miyano 的方法。Terribilini 等用贝叶斯方法来预测蛋白质与 RNA 相互作用位点, 他们得到的最优 MCC 是 0.35, 用单序列信息作为输入。他们同时报告加入由 HSSP 数据库的序列进化信息并没有改进预测性能。Wang 和 Brown 使用联合的序列信息作为输入, 得到最好的 AUC 是 0.7308, 与我们使用单序列信息加预测的二级结构信息作为输入得到的 AUC 值近似。总之, 当仅知道与 RNA 相互作用的蛋白质的序列信息时, 我们的预测性能时最好的, MCC 达到 0.43, 若知道与 RNA 相互作用的蛋白质的结构信息, MCC 值进一步提高至

0.46。

我们提出的模型所表现出来的良好的预测性能取决以下三个方面。首先，使用了支持向量机来构建分类器。与传统的神经网络相比，支持向量机具有出色的性能，它运用结构风险最小化原则，在经验风险与模型复杂度之间作适当的折衷，从而获得较好的推广能力。其次，使用二阶段法来处理不平衡数据集。正如前面所讨论的，同时使用参数 j 和 state-shifting 过滤规则比单独使用一种方法要好。最后，SVM 与 PSSMs 一起极大提高了预测性能。

6.5.6 网络服务

我们开发了被称为 printr 的网络服务来从一级序列预测蛋白质与 RNA 的相互作用位点。输入可选择是输入序列新还是结构信息。图 3.5 是网络服务的界面。图 3.6 是蛋白质 lurnA 的预测结果，真阳性用红色填充模型表示，假阳性用绿色填充模型表示，假阴性用粉红色填充模型表示，真阴性用黄色球棍模型表示。lurnA 预测的真阳性为 15、假阳性为 2、真阴性为 70、假阴性为 10，MCC 是 0.658。




图 6.3 PRINTR 网络界面



图 6.4 1urnA 的预测结果

6.6本章小结

我们综合使用支持向量机和 PSSMs 来预测蛋白质与 RNA 相互作用位点。当仅已知序列信息时，最好的预测性能是使用 PSSMs 和预测的二级结构作为输入信息时得到的，MCC 值是 0.432，是目前从序列出发预测蛋白质与 RNA 相互作用位点最好的预测性能。进化信息对预测性能的提升起至关重要的作用。当已知与 RNA 相互作用的蛋白质的结构信息时，预测性能还能进一步提升。

7 β -桶形膜蛋白和球形蛋白的识别研究

7.1 引言

膜蛋白可分成两种不同的结构类别： α -螺旋膜蛋白和 β -桶形膜蛋白。 β -桶形膜蛋白一般位于革兰氏阴性菌、线粒体和叶绿体的外膜。据估计 β -桶形膜蛋白占整个革兰氏阴性菌基因组编码的蛋白质的2-3%。在原核细胞中， β -桶形膜蛋白调控非特异的离子和小分子的被动运输，也可选择性的运输麦芽糖和蔗糖分子。在真核细胞中， β -桶形膜蛋白被认为是电压依赖的阴离子通道的组成部分。Schulz^[122]归纳了 β -桶形膜蛋白的主要结构特征：组成 β -桶形膜蛋白的 β -折叠链数是偶数；这些 β -折叠链是反平行的，形成桶状结构； β -折叠链一般由类似 β -转角的结构或较长的无规卷曲结构连接起来等。 β -桶形膜蛋白可以单体和聚合物形式存在。在过去的二十年中， α -螺旋膜蛋白取得了很高的预测准确率，而 β -桶形膜蛋白预测无论从数量上还是质量上都比 α -螺旋膜蛋白差。因此，开发正确的区分 β -桶形膜蛋白和球形蛋白质的方法是有意义的。

与众多预测 α -螺旋膜蛋白的方法相比，预测 β -桶形膜蛋白方法的数量相对较少。Gnanasekaran^[123]等使用结构保守区域的序列比对谱来识别 β -桶形膜蛋白。Wimley^[124]等提出用基于序列谱的HMM方法来预测和识别 β -桶形膜蛋白。Liu^[125]等用一个基于氨基酸组成的线性分类器来预测和识别 β -桶形膜蛋白。Bigelow^[126]等设计了一个新的基于序列谱的HMM方法来预测和识别 β -桶形膜蛋白。Bagos^[128]等提供了一个称为PRED-TMBB的网络服务来预测和识别 β -桶形膜蛋白。最近，Gromiha^[131]等提出了基于氨基酸组成和二肽组成的简单统计方法来识别 β -桶形膜蛋白。

本研究采用信息离散度方法从一级序列出发来区分 β -桶形膜蛋白和球形蛋白质。该方法主要基于比较亚序列的分布，已在第二章详细介绍。我们使用了391个 β -桶形膜蛋白和2321个球形蛋白质序列来进行训练和测试。预测结果显示我们识别 β -桶形膜蛋白的正确率为91%，而识别球形蛋白质的正确率是85%，总的正确率是86%。有趣的是，当我们使用简并的15、12和10种氨基酸编码，仍然能保持较高的预测精度。这表明用来区分 β -桶形膜蛋白和球形蛋白质最少氨基酸数是10种。当

使用相同的数据集时,本方法取得了比以前的方法稍好的预测性能。另外,本方法十分简单容易实现。

7.2 材料和方法

7.2.1 数据集

用于训练和测试的蛋白质由 391 个 β -桶形膜蛋白和 2321 个球形蛋白质组成。391 个 β -桶形膜蛋白收集自 PSORT-B2.0。2321 个球形蛋白质来源于 SCOP 数据库(版本号 1.67)。首先选择序列同源性小于 40% 的数据集,排除多结构域蛋白、膜蛋白和小蛋白后,数据集中有 5909 个蛋白质。这 5909 个蛋白质属于 2321 个蛋白质家族,我们从每一个家族中随机选取一个蛋白质作为代表。结果形成由 550 个全- α , 529 个全- β , 593 个 $\alpha + \beta$ 蛋白质和 649 个 α / β 蛋白质。还有一个由 309 个 α -螺旋膜蛋白组成的数据集用来进一步测试新方法。

为了方便与其它方法的比较,我们还对另一个由 377 个 β -桶形膜蛋白和 674 个球形蛋白组成的数据集进行了测试,该数据集收集自 Gromiha^[130]。

7.2.2 信息离散性度量方法

本文使用信息离散性度量方法来区分 β -桶形膜蛋白和球形蛋白。信息离散性度量方法已成功用于蛋白质结构类型预测^[134]、同源二聚体与非同源二聚体的分类^[135]以及多序列比对^[136]等等。

当使用信息离散性度量来区分 β -桶形膜蛋白和球形蛋白时,我们用方程 7.1 来计算未知蛋白 X 和 β -桶形膜蛋白以及球形蛋白组的差异。 B_X^β 和 B_X^α 分别表示这两个差异。于是未知蛋白 X 将被划归于类 R 当

$$B_X^R = \min\{B_X^\beta, B_X^\alpha\} \quad (7.1)$$

7.2.3 预测正确率的度量

预测正确率用两种方法来检验。一种是重复置换检测,另一种是 k-折交叉验证。前一种是检验算法的一致性,后者是检验一个分类器性能更客观的方法。这里,我们选择 10-折交叉验证。数据集随机分成 10 组,9 组用来训练,一组用来测试,进行

10 次。总正确率 (OA)，每一类的预测正确率 (EA) 和相关系数 (MCC) 用来评价预测性能。它们分别定义为：

$$OA = \frac{\sum_{s=1}^k p(s)}{N} \quad (7.2)$$

$$EA(s) = \frac{p(s)}{N(s)} \quad (7.3)$$

$$MCC(s) = \frac{p(s)n(s) - u(s)o(s)}{\sqrt{(p(s) + u(s))(p(s) + o(s))(n(s) + u(s))(n(s) + o(s))}} \quad (7.4)$$

其中，N 是 β -桶形膜蛋白和球形蛋白的总量，N(s) 分别是 β -桶形膜蛋白和球形蛋白的数量，k 是类别数，p(s), u(s), n(s), o(s) 与前面研究中定义一样。

7.3 结果与讨论

7.3.1 基于普通氨基酸字符集的分析

对该方法的重复置换检验结果见表 7.1。基于长度为 1, 2, 3 的亚序列的总的预测正确率分别是 84%，87% 和 85%。当 1=3 时，对 β -桶形膜蛋白的预测正确率达到一个很高的水平，97%。但是最好的 MCC 值还是在 1=2 时取得的。

表 7.2 给出了不同子序列长度 1 到 3 的 10 折交叉验证的结果。当 1=3 时，我们能鉴别出 391 个 β -桶形膜蛋白中的 360 个 (92%)，但是仅仅鉴别出 2321 个球形蛋白中的 1748 个 (75%)。当 1=2 时，355 个 β -桶形膜蛋白 (91%) 和 1973 个球形蛋白 (85%) 能被正确识别。并且，总的正确率和 MCC 都在 1=2 时最好。

从表 7.1 和表 7.2 我们还可看出当亚序列长度从 1 增加到 2 时，所有预测性能都得到提升。但是当 1 增加到 3 时，情况有所不同。这些趋势说明考虑序列信息能改进预测性能。但这并不意味着考虑的子序列越长，得到的预测性能越好。有两个原因：

(1) 当 1 增加到一定程度时，不同序列之间的差异已达到最大；(2) 当 1 增加到 3 时，数据集中一些三肽出现的频率极低，这对统计预测造成困难。

我们进一步分析了不同结构类别的蛋白质的预测情况。32 个分属全- α ，全- β ， $\alpha + \beta$ 和 α / β 的蛋白质和 8 个 β -桶形膜蛋白的不同子序列的信息离散性度量见表 7.3。当 1=2 时，全- α ，全- β ， $\alpha + \beta$ 和 α / β 的预测正确率分别是：90%、71%、

90%和 87%，表现出除全- β 蛋白外的良好预测性能。当仅用全- β 蛋白来计算时，全- β 蛋白的预测正确率可提高至 85%。

此外，我们也做了将 391 个 β -桶形膜蛋白与 309 个跨膜 α 螺旋蛋白区分的 10 折交叉验证。结果显示能正确识别 309 个跨膜 α 螺旋蛋白中的 241 个 (89%)，而识别 β -桶形膜蛋白的正确率是 99%。

表 7.1 使用信息离散性度量方法不同亚序列长度的重复置换检测结果

	L=1		L=2		L=3	
	EA (%)	MCC	EA (%)	MCC	EA (%)	MCC
β MPs	89.5	0.551	91.8	0.619	96.7	0.612
GPs	82.1	0.551	85.4	0.619	82.4	0.612
OA	83.7	-	86.9	-	85.0	-

L, 亚序列长度; β MPs, β -桶形膜蛋白; GPs, 球形蛋白质; EA, 每一类的预测正确率; OA, 总的预测正确率.

表 7.2 使用信息离散性度量方法不同亚序列长度的 10-折交叉验证检测结果

	L=1		L=2		L=3	
	EA (%)	MCC	EA (%)	MCC	EA(%)	MCC
β MPs	90.3	0.563	90.8	0.608	92.1	0.489
GPs	81.9	0.563	85.0	0.608	75.3	0.489
OA	83.7	-	86.4	-	78.3	-

L, 亚序列长度; β MPs, β -桶形膜蛋白; GPs, 球形蛋白质; EA, 每一类的预测正确率; OA, 总的预测正确率

7.3.2 基于简并氨基酸字符集的分析

大量的试验和理论研究表明全序列复杂性 (20 种氨基酸) 对于蛋白质设计是不必要的^[138-142]。这促使我们考虑用简并氨基酸字符集是否也能正确区分 β -桶形膜蛋白和球形蛋白。有不同的策略来根据氨基酸性质简并氨基酸字符集。我们使用 Li^[143]等提出的简并集。结果见表 7.4。

表 7.3 40 个不同类别蛋白质的信息离散性度量值和相应的预测结果

No	Proteins	L=1			L=2			L=3		
		FDOD (βMps)	FDOD (GPs)	Predicted class	FDOD (βMps)	FDO D (GPs)	Predicted class	FDOD (βMps)	FDOD (GPs)	Predicted class
All-α proteins										
1	1aoy	0.161	0.132	2	1.592	1.527	2	4.388	4.209	2
2	1mkma	0.245	0.213	2	1.719	1.635	2	4.578	4.311	2
3	1jgsa	0.175	0.102	2	1.373	1.227	2	3.946	3.760	2
4	1aru	0.104	0.107	1	0.739	0.723	2	2.905	2.961	1
5	1qbj	0.201	0.173	2	1.718	1.649	2	4.554	4.311	2
6	1hc8a	0.250	0.215	2	1.598	1.521	2	4.327	4.171	2
7	1k6yal	0.250	0.157	2	2.382	2.205	2	5.539	5.129	2
8	1i50j	0.247	0.145	2	1.996	1.776	2	4.549	4.583	1
当 l=1、2、3 时正确预测的 all-α 蛋白质分别是 478,494 and 449										
All-β proteins										
1	1heta1	0.160	0.082	2	1.094	0.925	2	3.427	3.410	2
2	1fc6a3	0.167	0.204	1	1.302	1.355	1	3.831	3.816	2
3	1ib8a1	0.176	0.142	2	1.616	1.535	2	4.408	4.192	2
4	1jb3a	0.163	0.080	2	1.478	1.297	2	4.217	4.001	2
5	1sr3a	0.116	0.082	2	1.406	1.329	2	4.036	3.906	2
6	1gm5a	0.102	0.065	2	1.049	0.963	2	3.694	3.466	2
7	1bfg	0.065	0.051	2	1.301	1.236	2	3.924	3.921	2
8	1hzea	0.167	0.112	2	1.451	1.361	2	4.207	4.119	2
当 l=1、2、3 时正确预测的 all-β 蛋白质分别是 350,377 and 310										
α+β proteins										
1	1h16a	0.034	0.018	2	0.330	0.295	2	2.267	2.202	2
2	1r61a	0.125	0.076	2	1.021	0.936	2	3.530	3.410	2
3	1kid	0.123	0.098	2	0.891	0.824	2	3.274	3.123	2
4	1a4ya	0.259	0.200	2	0.988	0.845	2	2.817	2.746	2
5	1jl5a	0.251	0.229	2	1.071	1.023	2	3.166	3.034	2
6	1h4xa	0.167	0.131	2	1.439	1.331	2	4.153	3.981	2
7	1em8b	0.145	0.121	2	1.494	1.455	2	4.131	4.045	2
8	1hrda2	0.097	0.066	2	0.983	0.922	2	3.499	3.417	2
当 l=1、2、3 时正确预测的 α+β 蛋白质分别是 523,536 and 487										
α/β proteins										
1	1o7na2	0.049	0.054	1	0.676	0.673	2	3.189	3.138	2
2	1mmia1	0.150	0.117	2	1.286	1.232	2	3.845	3.706	2
3	1s68a	0.095	0.059	2	0.921	0.829	2	3.490	3.364	2
4	1nw1a	0.092	0.042	2	0.656	0.545	2	2.969	2.807	2
5	1j7la	0.177	0.103	2	0.988	0.837	2	3.359	3.184	2
6	luxy 2	0.098	0.082	2	1.195	1.141	2	3.725	3.747	1
7	2ahja	0.099	0.076	2	0.942	0.901	2	3.576	3.412	2
8	1ii7a	0.128	0.072	2	0.807	0.693	2	3.060	2.913	2
当 l=1、2、3 时正确预测的 α/β 蛋白质分别是： 551,566 和 502										
β-barrel membrane proteins										
1	129146	0.088	0.158	1	0.608	0.761	1	2.529	2.87	1
2	119821	0.055	0.086	1	0.365	0.433	1	2.102	2.22	1

3	130680	0.046	0.062	1	0.605	0.652	1	2.726	2.83	1
4	123203	0.068	0.096	1	0.459	0.522	1	2.391	2.46	1
5	129111	0.130	0.094	2	0.637	0.566	2	2.553	2.56	1
6	134332	0.032	0.075	1	0.433	0.522	1	2.429	2.60	1
7	129144	0.039	0.046	1	0.568	0.612	1	2.397	2.82	1
8	266697	0.042	0.074	1	0.556	0.657	1	2.452	2.86	1

当 $l=1, 2, 3$ 时正确预测的 β -桶形膜蛋白的数量分别是: 350,359 和 378。

所有球形蛋白质用 PDB 码表示。 β -桶形膜蛋白用 NCBI gi 号表示; 预测类别, 1= β -桶形膜蛋白; 2=球形蛋白质。

从表 7.4 可以看出, 与使用全序列复杂性的氨基酸字符集不同, 使用不同的简并氨基酸字符集的最好预测性能都是在 $l=3$ 时实现的。这主要是因为当使用简并氨基酸字符集时, 某些三肽出现频率极低的概率下降。我们注意到当氨基酸字符集简并至 15、12、10 和 8 时, 总的预测正确率分别下降 2.4%、2.5%、3.9% 和 6.8%, 这说明识别 β -桶形膜蛋白和球形蛋白需要的最小的字符集是 10。有趣的是, 这与 Fang 和 Wang^[144] 的工作得出的结论一致, 他们用三种不同的方法从序列编码蛋白质结构, 发现需要的最少氨基酸也是 10 种。为了得到一般性的结论, 还需要进一步的工作, 如探讨是否 10 种氨基酸也能对蛋白质结构类别进行分类以及预测蛋白质亚细胞结构位置。

表 7.4 使用信息离散性度量方法基于不同字符集的 10-折交叉验证检测结果

Alphabet	Alphabet size	Overall prediction accuracy (%)		
		L=1	L=2	L=3
(C,FYW,ML,IV,G,P,A,T,S,N,H,QE,D,R,K)	15	81.6	83.2	84.0
(C,FYW,ML,IV,G,P,A,TS,NH,QE,D,RK)	12	78.5	80.9	83.9
(C,FYW,ML,IV,G,P,ATS,NH,QED,RK)	10	77.9	80.1	82.5
(CFYW,MLIV,G,P,ATS,NH,QED,RK)	8	74.5	76.1	79.6
(CFYW,MLIV,G,PATS,NHQEDRK)	5	67.9	70.4	73.6

括号中的氨基酸表示精简的氨基酸字符集 L, 亚序列长度。

7.3.3 与其它方法的比较

为了检验本方法, 我们还将与其它预测方法进行了对比。因为 Gromiha 等报告

他们的预测结果与其它早期的预测方法相比，性能相近或更好。因此我们仅与 Gromiha 的结论进行对比。比较结果见表 5。为了进行客观比较，我们用 $l=1$ 的结果与 Gromiha^[130] 比较，用 $l=2$ 的结果与 Gromiha^[131] 比较。我们将 Gromiha^[130] 的方法简称为 AC（即基于氨基酸组成的简单统计方法），将 Gromiha^[131] 简称为 DC（即基于二肽组成的统计方法）。

表 7.5 不同方法区分 β -桶形膜蛋白和球形蛋白的性能比较。

	EA(%)		EA(%)	
	AC	L=1	DC	L=2
β MPs	334/377=88.6	335/377=88.9	357/377=94.7	345/377=91.5
GPs	531/674=78.8	553/674=82.1	534/674=79.2	563/674=83.5
MCC	0.649	0.686	0.710	0.726
OA	865/1051=82.3	888/1051=84.5	891/1051=84.7	908/1051=86.4

L, 亚序列长度; β MPs, β -桶形膜蛋白; GPs, 球形蛋白质; EA, 每一类的预测正确率; OA, 总的预测正确率. AC, Gromiha et al^[130]提出的基于氨基酸组成的简单统计方法; DC, Gromiha et al^[131]提出的基于二肽组成的简单统计方法。

从表 7.5 可以看出，当 $l=1$ 时，信息离散性度量方法得到的总的正确率比 AC 方法高 2.2%，识别 β -桶形膜蛋白的正确率是 82.1%，比 AC 方法高 3.3%。当 $l=2$ 时，虽然信息离散性度量方法识别 β -桶形膜蛋白的正确率比 DC 方法低 3.2%，但信息离散性度量方法识别球形蛋白的正确率比 DC 方法高 4.3%，总的正确率高 1.7%。无论 $l=1$ 或 2，信息离散性度量方法都比相应的用来对照的方法有更好的 MCC 值。

7.4本章小结

在本工作中，我们使用了简单的信息离散性度量方法来区分 β -桶形膜蛋白和球形蛋白。当 $l=2$ 时，总的识别正确率是 86.4%，这表明残基序列在区分 β -桶形膜蛋白和球形蛋白时有重要作用。它还能正确识别跨膜 α 螺旋蛋白，识别正确率为 89%。当用相同的数据集测试时，信息离散性度量方法比以前的方法取得了更好的 MCC 值。此外，我们还用简并的氨基酸字符集测试了该方法。当氨基酸字符集减少到 15、12 和 10 时，总正确率下降的很少。这说明识别 β -桶形膜蛋白和球形蛋白所需的最小

信息是 10 个字符。信息离散性度量方法非常简单，没有引入任何人为参数，并且实现起来非常简单。

8 总结与展望

8.1 全文总结

据权威机构统计,目前生物分子数据量每 15 个月翻一翻,这些生物分子数据蕴涵着大量信息。如何充分利用这些数据,通过数据分析、处理,揭示这些数据的内在规律,从而为人类服务是生物信息学的重要任务。对核酸、蛋白质数据的处理是其中中心课题。本文主要在蛋白质结构与功能预测方面做了一些工作。若干重要结论总结如下:

(1) 提出了一个新的基于支持向量机的预测氢键 α 转角的方法。结果显示当使用相同的输入信息和使用相同的评价方法时,本方法表现出比目前最好的预测预测氢键 α 转角的方法更好的预测性能。当使用位置特异的进化信息和预测的二级结构信息作为输入,并使用相同的数据集和相同的 5-折交叉验证,该方法取得的 MCC 为 0.26,比到目前为止最好的方法取得的 MCC 值要高 0.1。此外,我们通过比较三种处理不平衡数据集的方法,得出用二阶段法来处理不平衡数据集效果最好。

(2) 对广义 α 转角的预测进行研究。该方法表现了良好的预测性能,多序列联配信息和预测的二级结构信息都有助于提高预测性能。综合多序列联配和预测的二级结构作为输入信息时,预测的 MCC 值达到 0.415。因为依距离定义的 α 转角在蛋白质中的含量比氢键 α 转角高,所以依距离定义的 α 转角的预测性能优于氢键 α 转角。

(3) 开发一个基于支持向量机的从氨基酸序列出发预测 π 转角的可靠方法。使用进化信息(PSSMs)加上预测的二级结构信息作为输入时,SVM 分类器达到最终的 MCC 为 0.556。我们也注意到进化信息对 π 转角预测的贡献大于对 β 转角预测的贡献。因此,尽管 π 转角预测训练数据中正负样本数更不平衡,但 π 转角预测所取得的预测性能却高于 β 转角预测。

(4) 综合使用支持向量机和 PSSMs 来预测蛋白质与 RNA 相互作用位点。我们考虑了两种情况,(1) 仅仅知道与 RNA 相互作用的蛋白质的序列信息。(2) 已知与 RNA

相互作用的蛋白质的结构信息。当仅已知序列信息时，最好的预测性能是使用 PSSMs 和预测的二级结构作为输入信息时得到的，MCC 值是 0.432，是目前从序列出发预测蛋白质与 RNA 相互作用位点最好的预测性能。进化信息对预测性能的提升起至关重要的作用。当已知与 RNA 相互作用的蛋白质的结构信息时，预测性能进一步提升。

(5) 使用了简单的信息离散性度量方法来区分 β -桶形膜蛋白和球形蛋白。当 $l=2$ 时，总的识别正确率是 86.4%，这表明残基序列在区分 β -桶形膜蛋白和球形蛋白时有重要作用。它还能正确识别跨膜 α 螺旋蛋白，识别正确率为 89%。当用相同的数据集测试时，信息离散性度量方法比以前的方法取得了更好的 MCC 值。此外，我们还用简并的氨基酸字符集测试了该方法。当氨基酸字符集减少到 15、12 和 10 时，总正确率下降的很少。这说明识别 β -桶形膜蛋白和球形蛋白所需的最小信息是 10 个字符。

8.2 研究展望

本文使用机器学习方法对蛋白质结构与功能预测中的几个问题进行了研究，如氢键 α 转角预测、广义 α 转角预测、 π 转角预测、蛋白质与 RNA 相互作用位点预测以及 β -桶形膜蛋白和球形蛋白的分类。在各项研究中都取得了较好的预测性能，在后期的研究工作中还需开展以下几方面工作：

到目前为止，规则二级结构预测和各种转角预测都是分开进行的，但它们显然同时存在于同一条蛋白质中，因此，将它们整合在一起进行预测是有价值的。选择合适的多分类方法进行预测是保证该预测能有效的前提。

在我们对氢键 α 转角、广义 α 转角、 π 转角、蛋白质与 RNA 相互作用位点进行预测时，都发现由 PSI-BLAST 产生的多序列比对的进化信息对预测性能有较强的提升作用。Cuff J. A. 和 Barton G. J.^[81] 在预测蛋白质规则二级结构时发现结合由 PSI-BLAST 生成的 PSSM 谱和 HMMER 谱产生的预测性能要优于单独使用由 PSI-BLAST 生成的 PSSM 谱。因此，另一个可能提升预测性能的途径是综合不同的序列比对谱。

任何单独的预测方法都有局限性。King^[80] 等比较了单独使用 PHD、DSC、NNSP 和 Predator 方法预测二级结构和综合这几种方法进行预测，发现综合这几种方法进行预测时的预测性能要优于单独使用这些方法时的预测性能，所以，还有一个可行的研究方向是综合不同的方法进行预测。

致 谢

本论文是在导师许进教授的精心指导下完成的。许老师既是我博士阶段的导师，也是我硕士阶段的导师。五年来，他在学术上的指导，思想上的启发，使我受益匪浅。课题在开始阶段进行的并不顺利，许老师的宽容与鼓励使我有勇气继续做下来。许老师开阔的思维和勇于创新的精神，深刻教育和感染了我，使我逐渐完成了从学习型向研究型的转变。在此，向我的导师表示衷心的感谢。

作者得到了控制系的费奇教授、寥晓听教授、岳超源教授、王红卫教授、王永冀教授以及生命科学院的徐涛教授、刘曼西教授、瞿安连教授、周艳红教授、原芸教授、张春光教授在学业上的教诲，使作者奠定了完成本博士论文的知识基础。在此向他们表示衷心的感谢。感谢环境学院赵开宏教授的指导和关心。

感谢实验室的潘林强教授的指导和关心。感谢同课题组的史小红博士、刘向荣博士。感谢同实验室的张征博士、史小龙博士、方刚博士、张社民博士、强小利博士、王延峰博士、王子诚博士、周康博士、罗亮博士等同学，还有已经毕业的殷致翔博士、张凤月博士、王淑栋博士、刘文斌博士、刘西奎博士、李崇明博士、赵虎博士、张连珍硕士、董永硕士等同学。

感谢我的朋友张礼知博士、魏建宾博士、李鹏博士、王泽敏博士的支持和帮助。

感谢我伟大、聪明、坚强的母亲，单纯而可爱的妹妹。

感谢我的爱人薛志东博士，在一起共同生活、学习的日子非常幸福、快乐。

感谢所有给予我直接和间接帮助和指导的每一个人。

参考文献

- [1] 生物信息学引论. <http://www.lmbe.seu.edu.cn/chenyuan/xsun/bioinformatics/Web/ChapterOne/1.1.html>
- [2] 沈同,王镜岩,赵邦悌等. 生物化学(上册).第1版,北京:高等教育出版社.1990. 77-78.
- [3] Pierre B. Soren B. 生物信息学—机器学习方法. 第1版,张东晖等译,中国:中信出版社.2003. 69-70.
- [4] 阎隆飞,孙之荣主编. 蛋白质分子结构. 北京:清华大学出版社.1999. 32-39.
- [5] Dasgupta B, Pai L, Basu G, et al. Expanded turn conformations: characterization and sequence-structure correspondence in α -turns with implications in helix folding. *Proteins*, 2004, 55(2):305-315.
- [6] Kabsch W, Sander C. Dictionary of protein secondary structure: pattern recognition of hydrogen-bonded and geometrical features. *Biopolymers* 1983, 22(12):2577-2637.
- [7] Rost B. Review: protein secondary structure prediction continues to rise. *J. Struct. Biol.*, 2001,134(2-3):204-218.
- [8] Chou PY, Fasman GD. Conformational Parameters for Amino Acids in Helical, Sheet and Random Coil Regions From Proteins. *Biochem*, 1974, 13(2):211-222..
- [9] Chou PY, Fasman GD. Prediction of Protein Conformation. *Biochem.*, 1974,13(2): 222-245.
- [10] Chou PY, Fasman GD. Prediction of the secondary structure of proteins from their amino acid sequence. *Advances in Enzymology*, 1978, 47: 45-147.
- [11] Garnier J, Osguthorpe DJ, Robson B. Analysis of the Accuracy and Implications of Simple Methods for Predicting the Secondary Structure of Globular Proteins. *J. Mol. Biol.*, 1978, 120(1):97-120.
- [12] Garnier J, Gibrat JF, Robson B. GOR method for predicting protein secondary structure from amino acid sequence. *Methods Enzymol.*, 1996,266:540-553.
- [13] Zvelebil M.J. Barton G.J. Taylor W.R. et al. Prediction of protein secondary structure and active sites using alignment of homologous sequence. *J. Mol. Biol.*, 195(5): 584-599.
- [14] Jones DT. Protein secondary structure prediction based on position-specific scoring matrices. *J. Mol. Biol.*, 1999,292(2):195-202.
- [15] Qian N, Sejnowski TJ. Predicting the Secondary Structure of Globular Proteins Using Neural Network Models. *J. Mol. Biol.*, 1988, 202(4):865-84.
- [16] Howard L. Karplus M. protein secondary structure prediction with a neural network. *PNAS*, 1989, 86(1):152-156.
- [17] Kneller DG. Cohen FE, Langridge R. Improvemnets in protein secondary structure prediction by and enhanced neural network. *J. Mol. Biol.*, 1990, 214(2):171-182.

- [18] Rost B. PHD: predicting one-dimensional protein structure by profile-based neural networks. *Methods Enzymol.*,1996,266: 525-539.
- [19] Yi TM. Lander ES. Protein Secondary Structure Prediction Using Nearest-neighbor Methods. *J. Mol. Biol.*, 1993, 232(4): 1117-1129.
- [20] Hua SJ. Sun Z. A novel method of protein secondary structure prediction with high segment overlap measure: support vector machine approach. *J. Mol. Biol.*, 2001, 308(2):397-407.
- [21] Ward JJ McGuffin LJ Buxton BF et al. Secondary structure prediction with support vector machine. *Bioinformatics*, 2003, 19(13):1650-1655.
- [22] Hu HJ, Pan Y, Harrison P et al. Improved protein secondary structure prediction using support vector machine with a new encoding scheme and an advanced tertiary classifier. *IEEE Trans Nanobioscience.*, 2004, 3(4):265-271.
- [23] Hua S J, Sun Z R. Support vector machine approach for protein subcellular location prediction. *Bioinformatics*, 2001,17(8):721-728
- [24] Xie D, Li A, Wang M. et al. LOCSVMPSI: a web server for subcellular localization of eukaryotic proteins using SVM and profile of PSI-BLAST. *Nucleic Acids Res*, 2005, 33(Web server issue):W105-W110.
- [25] Matsuda, S. Vert, J.P., Saigo, H. et al. A novel representation of protein sequences for prediction of subcellular location using support vector machines *Protein Sci.*, 2005, 14(11): 2804-2813.
- [26] Chittibabu G, Shankar S. TARGET: a new method for predicting protein subcellular localization in eukaryotes *Bioinformatics*, 2005,21(21): 3963-3969.
- [27] Bulashevskaya A., Eils R. Predicting protein subcellular locations using hierarchical ensemble of Bayesian classifiers based on Markov chains. *BMC Bioinformatics.*, 2006,7:298.
- [28] Xiao X, Shao S, Ding Y et al. Using complexity measure factor to predict protein subcellular location. *Amino Acids.*, 2005, 28(1):57-61.
- [29] Pan YX, Li DW, Duan Y et al. Predicting protein subcellular location using digital signal processing. *Acta Biochim Biophys Sin (Shanghai)*. 2005, 37(2):88-96.
- [30] 王娴, 李骛, 王明会, 等. 基于支持向量机方法的蛋白质氨基酸残基可溶性预测. *生物物理学报*, 2005, 21(1):60-64.
- [31] Nielsen H, Engelbrecht J, Brunak S, et al. Identification of prokaryotic and eukaryotic signal peptides and prediction of their cleavage sites. *Protein Eng.*, 1997, 10(1):1-6.
- [32] Chou KC. Prediction of protein signal sequences and their cleavage sites. *Proteins*. 2001, 2(1):136-139.
- [33] Liu H, Yang J, Ling JG, et al. Prediction of protein signal sequences and their cleavage sites by statistical rulers. *Biochem Biophys Res Commun.*, 2005, 338(2):1005-1011.
- [34] Liu L, Li J, Tian X, et al. Information theory in prediction of cleavage sites of signal peptides. *Protein Pept Lett.*, 2005, 12(4):339-342.

- [35] Cai YD, Lin SL, Chou KC. Support vector machines for prediction of protein signal sequences and their cleavage sites. *Peptides*, 2003, 24(1):159-161.
- [36] Huang HD, Lee TY, Tzeng SW et al. Incorporating hidden Markov models for identifying protein kinase-specific phosphorylation sites. *J Comput Chem.*, 2005, 26(10):1032-1041.
- [37] Zhou FF, Xue Y, Chen GL et al. GPS: a novel group-based phosphorylation predicting and scoring method.. *Biochem Biophys Res Commun.*, 2004, 325(4):1443-1448.
- [38] Blom N, Sicheritz-Ponten T, Gupta R, et al. Prediction of post-translational glycosylation and phosphorylation of proteins from the amino acid sequence. *Proteomics*, 2004, 4(6):1633-1649.
- [39] Koenig M, Grabe N. Highly specific prediction of phosphorylation sites in proteins. *Bioinformatics*, 2004,20(18):3620-3627.
- [40] Muramatsu T, Suwa M. Statistical analysis and prediction of functional residues effective for GPCR-G-protein coupling selectivity. *Protein Eng Des Sel.*, 2006, 19(6):277-83.
- [41] Burgoyne NJ, Jackson RM. Predicting protein interaction sites: binding hot-spots in protein-protein and protein-ligand interfaces. *Bioinformatics*, 2006, 22(11):1335-42.
- [42] Cai C Z, Han L Y, Ji Z L, et al. Enzyme family classification by support vector machine. *Proteins*, 2004, 55(1):66-76.
- [43] Liu H, Yang J, Wang M, et al. Using fourier spectrum analysis and pseudo amino acid composition for prediction of membrane protein types. *Protein J.*, 2005, 24(6):385-389.
- [44] Liu H, Wang M, Chou KC. Low-frequency Fourier spectrum for predicting membrane protein types. *Biochem Biophys Res Commun.*, 2005, 336(3):737-739.
- [45] Chou KC, Cai YD. Prediction of membrane protein types by incorporating amphipathic effects. *J Chem Inf Model*, 2005, 45(2):407-413.
- [46] Perou CM, Jeffrey, SS, Rijn MVD. Distinctive gene expression patterns in human mammary epithelial cells and breast cancers. *Proc. Natl. Acad. Sci. USA.*, 1999, 96(16):9212-9217.
- [47] Enright AJ, Iliopoulos I. Kyrpides NC. et al. Protein interaction maps for complete genomes based on gene fusion events. *Nature*, 1999, 402(6757):86-90.
- [48] Marcotte EM., Pellegrini M, Ng HL. Detecting protein function and protein-protein interactios from genome-wide prediction of protein function. *Science*, 1999,285(5428):751-753.
- [49] Pellegrini M, Marcotte EM, Thompson MJ. Assigning protein functions by comparative genome analysis: protein phylogenetic profiles. *Proc. Natl. Acad. Sci. USA.*, 1999,96(8):4285-4288..
- [50] Duda RO, Hart PE, Stork DG. 模式分类. 第1版, 李宏东 姚天翔等译, 2003. 北京: 机械工业出版社. 2003.

- [51] 张学工.关于统计学习理论与支持向量机.自动化学报,2000,26(1):32-41
- [52] Nello Crsitianini, John Shawe-Taylor.支持向量机导论. 第 1 版, 李国正等译. 北京: 电子工业出版社,2004
- [53] Trevor Hastie, Robert Tibshirani, Jerome Friedman.统计学习基础——数据挖掘、推理与预测. 范明等译.北京:电子工业出版社,2003
- [54] 邓乃扬,田英杰.数据挖掘中的新方法——支持向量机.北京:科学出版社,2004
- [55] Vapnik V. The nature of statistical learning theory. New York: Springer-Verlag; 1995.
- [56] Vapnik V. Statistical learning theory. New York: Wiley;1998
- [57] Fang W. The disagreement degree of multi-person judgments in additive structure. Math. Social Sci. 1994,28(2):85-111.
- [58] Fang W. On a global optimization problem in the study of information discrepancy. J. Global Optim. 1997,11:387-408.
- [59] Fang W. The characterization of a measure of information discrepancy. Inf. Sci. 2000,125(1-4): 207-232.
- [60] Fang W, Roberts FS, Ma Z. A measure of discrepancy of multiple sequences. Inf. Sci. 2004,67(2):173-182.
- [61] Chou KC. Prediction of tight turns and their types in proteins. Analytical Biochem 2000,286(1):1-16.
- [62] Zhang QD, Yoon S, Welsh WJ. Improved method for prediction β -turn using support vector machine. Bioinformatics, 2005,21(10):2370-2374.
- [63] Fuchs PFJ, Alix AJP. High accuracy prediction of β -turns and their types using propensities and multiple alignments. Proteins, 2005,59(4):828-839.
- [64] Kaur H, Raghava GPS. Prediction of β -turns in proteins from multiple sequence alignment using neural network. Protein Sci, 2003,12(3):627-634.
- [65] Pavone V, Gaeta G, Lombardi A, Nastri F, Maglio, O, Isernia C, Saviano M. Discovering protein secondary structure: classification and description of isolated α -turns. Biopolymers, 1996,38(8):705-721.
- [66] Hobohm U, Scharf M, Schneider R. Selection of representative protein data sets. Protein Sci, 1993,1(3):409-417.
- [67] Chou KC. Prediction and classification of α -turn types. Biopolymers, 1997, 42(7):837-853.
- [68] Cai YD, Feng KY, Li YX, et al. Support vector machine for predicting α -turn types. Peptide, 2003,24:629-630.
- [69] Kaur H, Raghava GPS. Prediction of α -turns in proteins using PSI-BLAST Profiles and secondary structure information. Proteins, 2004,55(1):83-90.
- [70] Kaur H, Raghava GPS. A neural network based method for prediction of γ -turns in proteins from multiple sequence alignment. Protein Sci., 2003,12(5):923-929.
- [71] Guo J, Chen H, Sun ZR, et al. A novel method for protein secondary structure prediction using dual-layer SVM and profiles. Proteins, 2004,54(4):738-743.
- [72] Zhang SW, Pan Q, Zhang HC, Zhang YL, Wang HY. Classification of protein

- quaternary structure with support vector machine. *Bioinformatics*, 2003,19(18):2390-2396.
- [73] Ben-Hur A, Noble WS. Kernel methods for predicting protein-protein interactions. *Bioinformatics*, 2005,21:i38-i46.
- [74] Cai YD, Chou KC. Predicting subcellular localization of proteins in a hybridization space. *Bioinformatics*, 2004,20(7):1151-1156.
- [75] Altschul SF, Madden TL, Alejandro AS, Zhang J, Zhang Z, Miller W, Lipman, DJ. Gapped blast and psi-blast: a new generation of protein databases and search programs. *Nucleic Acids Res*, 1997,25(17):3389-3402.
- [76] Westhead DR, Parish JH, Twyman RM. 生物信息学. 第1版 王明怡等译. 北京: 科学出版社. 2004.
- [77] Zheng, Y, Burrage K, Mattick J S. Prediction of protein solvent accessibility using support vector machines. *Proteins*, 2002, 48(3):566-570
- [78] Joachims, T. Making large-scale SVM learning practical. In: Schölkopf B, Burges C, Smola A, editors. *Advances in kernel methods-support vector learning*. Cambridge, MA: MIT Press.1999.
- [79] Shepherd AJ, Gorse D, Thornton JM. Prediction of the location and type of β -turn types in proteins using neural networks. *Protein Sci.*, 1999,8(5):1045-1055.
- [80] King RD, Ouali M, Strong AT, Aly A, Elmaghraby A, Kantardzic M, Page D. Is it better to combine predictions? *Protein Eng.*, 2000,13(1):15-19.
- [81] Cuff JA, Barton GJ. Application of multiple sequence alignment profiles to improve protein secondary structure prediction. *Proteins*, 2000,40(3):402-511.
- [82] Wang Y, Xue Z D, Xu J. Better prediction of the location of α -turns in proteins with support vector machine. *Proteins*, 2006, 65(1):49-54.
- [83] Shepherd A J, Gorse D, Thornton J M. Prediction of the location and type of β -turn types in proteins using neural networks. *Protein Sci*, 1999, 8(5):1045-1055
- [84] Pavone V, Gaeta G, Lombardi A, et al. Discovering protein secondary structure: classification and description of isolated α -turns. *Biopolymers*, 1996, 38(6):705-721.
- [85] Venkatachalam CM. Stereochemical criteria for polypeptides and proteins. V. Conformation of a system of three linked peptide units. *Biopolymers*, 1968, 6(10):1425-1436
- [86] Lewis PN, Momany FA, Scheraga HA. Chain reversals in proteins. *Biochim Biophys Acta*, 1973, 302(3):211-229.
- [87] Rajashankar, K.R. and Ramakumar, S. π -Turns in proteins and peptides classification, conformation, occurrence, hydration and sequence. *Protein Sci.*, 1996, 5(5):932-946
- [88] Guo J, Chen H, Sun Z R, et al. A novel method for protein secondary structure prediction using dual-layer SVM and profiles. *Proteins*, 2004, 54(4):738-743
- [89] Gao Q B, Wang Z Z, Yan C. Prediction of protein subcellular location using a combined feature of sequence. *FEBS Lett*, 2005, 579(16):3444-3448.
- [90] Krogh A, Larsson D, von Heijine G, et al. Predicting transmembrane topology with a

- hidden markov model: application to whole genomes. *J. Mol. Biol.*, 2001,305 (3) :182-192.
- [91] van Geest M, Lolkema JS. Membrane topology and insertion of membrane proteins: search for topogenic signals *Microbiol. Mol. Biol. Rev.*, 2000, 64(1):13-33.
- [92] Tusnady GE, Simon I. Principles governing amino acid composition of integral membrane proteins: application to topology prediction. *J. Mol. Boil.*, 1998, 283(3):489-506.
- [93] Rost B, Casadio R, Fariselli P, Sander C. Transmembrane helices predicted at 95% accuracy. *Protein Sci.* 1995, 4(3):521-533.
- [94] Jones DT, Taylor WR, Thornton JM. A model recognition approach to the prediction of all-helical membrane protein structure and topology. *Biochemistry*, 1994, 33(10):3038-3049.
- [95] Ahmad S. et al. Real value prediction of solvent accessibility from amino acid sequence. *Proteins*, 2003, 50(4): 629-635.
- [96] Ahmad S. et al. Analysis and prediction of DNA-binding proteins and their binding residues based on composition, sequence and structural information. *Bioinformatics*, 2004, 20(4): 477-486.
- [97] Ahmad, S. and Sarai A. PSSM-based prediction of DNA binding sites in proteins. *BMC Bioinformatics*, 2006, 6, 33.
- [98] Allers,J. and Shamoo,Y. Structure-based analysis of protein-RNA interactions using the program ENTANGLE. *J. Mol. Biol.*, 2001, 311(1), 75-86.
- [99] Berman HM, Westbrook J. Feng Z. et al. The Protein Data Bank. *Nucleic Acids Res.*, 2000, 28(2):235-242.
- [100] Bradford, J.R. and Westhead D.R. Improved prediction of protein-protein binding sites using a support vector machines approach. *Bioinformatics*, 2005, 21(8): 1487-1494.
- [101] Chen,H and Zhou,H.X. Prediction of interface residues in protein-protein complexes by a consensus neural network method: test against NMR data. *Proteins*, 2005, 61(1): 21-35.
- [102] Draper,D.E. Protein-RNA recognition. *Annu. Rev. Biochem.*, 1994, 64, 593-620.
- [103] Draper,D.E. Themes in RNA-protein recognition. *J.Mol.Biol.*, 1999, 293(2),255-270.
- [104] Fariselli,P. Pazos F. Valencia A. et al. Prediction of protein-protein interaction sites in heterocomplexes with neural networks. *Eur. J. Biochem.*, 2002, 269(5): 1356-1361.
- [105] Jones S. and Thornton J.M. Prediction of protein-protein interaction sites using patch analysis. *J. Mol. Biol.*, 1997, 272(1):133-143.
- [106] Jones S., Daley DT, Luscombe NM. et al. Protein-RNA interaction: a structural analysis. *Nucleic Acids Research*, 2001, 29(4):943-954.
- [107] Jeong E. Chung IF, Miyano S. et al. A neural network method for identification of RNA-interacting residues in proteins. *Genome Inform. Ser. Workshop Genome Inform.*, 2004, 15, 105-116.

- [108] Jeong E. and Miyano S. A weighted profile based method for Protein-RNA interacting residues prediction. *Trans. Comput. Syst. Biol.* 2006, IV:123-139..
- [109] Kuznetsov IB, Guo Z, Li R. et al. Using evolutionary and structural information to predict DNA-binding sites on DNA-binding proteins. *Proteins*, 2006, 64(1):19-27.
- [110] Kim, H. and Park, H. Prediction of protein relative solvent accessibility with support vector machines and long-range interaction 3D local descriptor. *Proteins*, 2004, 54(3):557-582.
- [111] Kim,H. Jeong E, Lee SW. et al. Computational analysis of hydrogen bonds in protein-RNA complexes for interaction patterns. *FEBS Lett.*, 2004, 552(2-3): 231-239.
- [112] Koike,A. and Takagi,T. Prediction of protein-protein interaction sites using support vector machines. *Protein Eng.*, 2004, 17(2):165-173.
- [113] Morik, K. Brockhausen, and T. Joachims. Combining statistical learning with a knowledge-based approach – A case study in intensive care monitoring. *Proc. 16th Int'l Conf. On Machine learning (ICML-99).* (1999)
- [114] Ofra Y. and Rost, B. Predicted protein-protein interaction sites from local sequence information. *FEBS Lett*, 2003, 544(1-3): 236-239.
- [115] Terribilini M.. Prediction of RNA binding sites in proteins from amino acid sequence. *RNA*, 2006, 12(1):1-13.
- [116] Treger,M. and Westhof E. Statistical analysis of atomic contacts at RNA-protein interfaces. *J. Mol. Recognit.*, 2001, 14(1): 199-214.
- [117] Wang L.J. and Brown S.J. BindN: a web-based tool for efficient prediction of DNA and RNA binding sites in amino acid sequences. *Nucleic Acids Res.*, 2006, Web Server Issue, W243-W248.
- [118] Ward, JJ, MuGuffin LJ, Buxton BF. et al. Secondary structure prediction with support vector machine. *Bioinformatics*, 2003, 19(13),1650-1655.
- [119] Zheng, Y. (2002) Prediction of protein solvent accessibility using support vector machines. *Proteins*,48(5):566-570.
- [120] Zhou,H.X. and Shan,Y. Prediction of protein interaction sites from sequence profiles and residue neighbor list. *Proteins*, 2001, 44(3):336-343.
- [121] Claros MG, von Heijine G. Toppred II : an improved software for membrane protein structure prediction. *Comput. Appl. Biosci.* 1994, 10(6):685-686.
- [122] Schulz G.E. β -barrel membrane proteins. *Curr. Opin. Struct, Biol.* 2000, 10(4):443-447.
- [123] Gnanasekaran TV, Peri S, Arockiasamy A, et al. Profiles from structure based sequence alignment of porins can identify beta stranded integral membrane proteins. *Bioinformatics*, 2000,16(9):839-842.
- [124] Wimley WC. Toward genomic identification of beta-barrel membrane proteins: composition and architecture of known structures. *Protein Sci.*, 2002, 11(2):301-312.
- [125] Liu Q, Zhu Y, Wang B et al.. Identification of beta-barrel membrane proteins based

- on amino acid composition properties and predicted secondary structure. *Comput. Biol. Chem.*, 2003, 27(2):355-361.
- [126] Bigelow HR, Petrey DS, Liu J, et al. Predicting transmembrane beta-barrels in proteomes. *Nucleic Acid Res.*, 2004, 32(8):2566-2577.
 - [127] Natt NK, Haur H, Raghava GP. Prediction of transmembrane regions of beta-barrel proteins using ANN- and SVM-based methods. *Proteins*, 2004, 56(1):11-18.
 - [128] Bagos PG, Liakopoulos TD, Spyropoulos IC, et al. A Hidden Markov Model method, capable of predicting and discriminating beta-barrel outer membrane protein. *BMC Bioinformatics*, 2004; 5:29.
 - [129] Bagos PG, Liakopoulos TD, Spyropoulos IC, et al. PRED_TMBB: a web server for predicting the topology of beta-barrel outer membrane proteins. *Nucleic Acids Res.* 2004, 32:W400-W404.
 - [130] Gromiha MM, Suwa M. A simple statistical method for discriminating outer membrane proteins with better accuracy. *Bioinformatics*, 2005, 21(7):961-968.
 - [131] Gromiha MM, Ahmad S, Suwa M. Application of residue distribution along the sequence for discriminating outer membrane proteins. *Comput. Biol. Chem.*, 2005, 29(2):135-142.
 - [132] Gardy JL, Laird MR, Chen F, et al. PSORTB V2.0: expanded prediction of bacterial subcellular location and insights gained from comparative proteome analysis *Bioinformatics*, 2005, 21(5):617-623.
 - [133] Murzin AG, Brenner SE, Hubbard T, et al. SCOP: a structural classification of proteins database for the investigation of sequences and structures. *J.Mol.Biol.*, 1995, 247(4):536-540.
 - [134] Jin L, Fang W, Tang H. Prediction of protein structural classes by a new measure of discrepancy. *Comput. Biol. Chem.*, 2003, 27(3):373-380.
 - [135] Song J, Tang H. Accurate classification of homodimeric vs other homooligomeric proteins using a new measure of information discrepancy. *J. Chem. Inf. Sci.*, 2004, 44(4):1324-1327.
 - [136] Zhang M, Fang W, Zhang J, et al. MSAID: multiple sequence alignment based on a measure of sequence alignment. *Comput. Biol. Chem.*, 2005, 29(2):175-181.
 - [137] Ron, K. A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings IJCAI-95*, Montreal, Morgan Kaufmann, San Francisco, CA.1995, 1137-1143.
 - [138] Kamtekar S, Schiffer JM, Xiong H, et al. Protein design by binary patterning of polar and nonpolar amino acids. *Science* 2003, 262(5140):1680-1685.
 - [139] Regan L, Degrado WF. Characterization of a helical protein designed from first principles. *Science*, 1988, 241(4868):976-978.
 - [140] Plaxco KW, Riddle DS, Grantcharova V, et al. Simplified proteins: minimalist solutions to the “protein folding problem”. *Curr. Opin. Struct. Biol.*, 1998, 8(1):80-85.

- [141] Clarke ND. Sequence “minimization”: explore the sequence landscape with simplified sequences. *Curr. Opin. Biotech.*, 1995, 6(4):467-472.
- [142] Beasley JR, Hecht MH. Protein design: the choice of *de novo* sequences. *J. Biol. Chem.*, 1997, 272(4):2031-2034.
- [143] Li T, Fan K, Wang J, et al. Reduction of protein sequence complexity by residue grouping. *Protein Eng.*, 2003, 16(5):323-330.
- [144] Fan K, Wang W. What is the minimum number of letters required to fold a protein? *J. Mol. Biol.*, 2003, 328(4):921-926.

附录 1 发表或录用论文

- [1] Yan Wang, Zhidong Xue, Jin Xu. Better Prediction of the Location of α -turns in Proteins with Support Vector Machine. PROTEINS: Structure, Function, and Bioinformatics, 2006, 65(1):49-54. (SCI 源刊, IF:4.5(2005))
- [2] Yan Wang; ZhiDong Xue; XiaoHong Shi, Jin Xu. Prediction of pi-turns in proteins using PSI-BLAST profiles and secondary structure information. Biochemical and Biophysical Research Communications. 2006, 347(3):574-580. (SCI 源刊, IF:3.0 (2005))
- [3] Yan Wang, Zhidong Xue, Jin Xu. Improved Prediction of RNA binding site using SVM and profiles. Bioinformatics, (in revising)
- [4] 王燕, 薛志东, 史小红, 许进. 广义 α 转角预测研究. 华中科技大学学报. (已接收)
- [5] XiaoHong Shi, Liang Luo, Yan Wang, Jin Xu. A finding maximum clique algorithm for predicting loop of protein structure. Applied mathematics and computation. (accepted). (SCI 源刊)
- [6] 史晓红, 王燕, 刘文斌, 殷志祥. 现代优化算法在蛋白质结构预测中的应用. 数学的实践与认识. 2006, 36 (10):86-92.

附录 2 攻读学位期间参与的科研课题

- [1] 作为完成人之一参加了国家自然科学基金“综合型智能化蛋白质结构预测研究”，基金号:60274026。
- [2] 作为完成人之一参加了国家自然科学基金“DNA计算在图论与组合优化中的应用”，基金号:60103021。
- [3] 作为完成人之一参加了国家自然科学基金“基于分子信标的 DNA 计算模型的研究和探索”，基金号:30570431。

附表

附表 1 967 个氢键 α 转角

NAANA	GKHNG	SPAVN	CPPRY	IKEDT	TDGGE	FTGIS	NMTAT	VHNVG	AMPEG	VKNFA
DRELL	GPEHW	NSEAD	YEQVA	FEQYG	NCSNS	CTKLS	NNPEG	GMESK	GNILG	DITEV
DNFRT	DHTTA	GVGSG	MDGVL	DRGSG	NPAEG	EMSTI	WPHYT	SPYLC	THSAG	DPDLG
SLLED	NKISN	VYGDK	NFFFE	LQPYL	DKKNM	FIETC	CNYFR	GLKEV	VRSNF	DERFG
INNAS	RPGAI	GVQSG	MFKYC	QPNYS	VLEEG	AGSSE	QHDKV	YFGVL	DLATG	DWNTK
GRTTG	TGEPA	RDDVA	ACHNQ	LSNYR	GAVMK	GKYHI	VRRWM	FGVLK	DMLKF	EVTGG
DLNSG	LADRV	ASKLL	SASDC	LEHAL	DADNN	NNKTN	LNQSH	GVLKD	TMDDM	DYKKR
HLTDG	DFPSQ	HKDST	RPELI	IFARN	TTEYY	NLVAY	DLKKK	DTVGQ	PPPGS	LVNHV
VGSEG	VAGVL	PSSDA	DTKYS	CRHRG	IDGKG	DEAHQ	KYGVG	DQDTC	NNGTG	NPKKK
VSKYT	EQQGK	EKGHS	AVEGE	CGYHG	SDETL	HEPVF	DSTRQ	CPDVF	GPEAK	VKGKG
LPDSG	IPEEL	TVGSN	NHDTG	IFPNN	ATVSG	IYYYD	SKKDY	DPRWR	NPSTG	LKGNK
SQKDY	AYGIN	ANKGT	GSTQA	NTQED	NINNV	PDLGI	TVEEL	MMDSG	YSEKG	VLNEW
EHGSY	FAAEG	DQLKR	IDGKV	RRENQ	KAGEL	DVSTC	DAKTG	TLANS	FGQTR	LADNK
VKKYN	NGGVN	REGNI	NHHTQ	SPENS	SISSG	NKEDN	NEETG	SAKTK	PSGVL	KRLDG
NASFI	SANQE	DYNSV	CLKDN	CAGCG	DKSTM	WRPYF	DKETG	NIDLT	NKKLV	SKVMF
DPKTQ	ECNNR	GALDY	DEDTG	CSSCQ	VNGNI	NTEKV	CPEDH	NYPDS	GFQTD	LDSDI
YGCNC	NNRGY	SGSES	TGDTM	CSACG	DSNKA	DIFTG	NTKRG	NPTTG	DQNTL	AAGMH
DSKKD	SWPAS	SPRTY	DCPSM	CSTCR	DTVAR	NKSNK	RACDM	ILDKG	QNTLK	DHCRV
SLDKT	DYPTG	LAATN	DIQAK	PTALI	NEEKA	VRGST	LTPYV	SGRYS	IEDWN	DVDGY
DAATD	HLMQI	DLNTN	YGDDK	IPGIG	RPELF	CLEKG	TKSYG	YQRKG	RKSKG	LPGQG
VLGKA	SLGEG	DPFEA	SPRHK	NKDNI	SASMG	FSNIV	PKNIH	NTLNN	NEAFT	GSSQW
DKETC	SAKTS	AEGKV	NLQTR	LRPAH	YPQQF	FFPQH	EDDKV	NSKIN	FTDKV	DDVAI
APDIY	PPHCK	DATKK	YAGVL	LEGDV	DPMVQ	AGTYA	DEDHV	LLKLV	SFIRN	KTWL
APGVY	CKPYI	GPKNK	IPLVD	VDGQS	RLFSS	DSTLD	DAATC	SKDTG	NSLNQ	LVEFI
LANKL	ILKGS	TAADG	NQLLG	NIASV	EYTRT	SEEDT	DPEKG	NTATN	IVGFG	YVENG
RSMVE	IGIGH	DPNTK	CSNGG	DNTNA	VNILK	SSKYA	CPKCK	CNIHG	FPKFS	QTPIG
DEEVF	WDAYK	AESGG	STETG	NTNAD	EHNAS	YAGRA	CEVCG	DPLKM	DDDLA	PVRRR
VPNV	NTIYG	DAVHK	EENHY	TCPPL	LEYVL	FPENG	SVVSG	SLDTA	SASAT	HPEEG
DTSSR	MSSDI	HDGNL	QNLKS	NRGYS	KPNNT	SFKQK	DIVNK	KKEAF	ARENG	DEINN
RYEDV	AQKNL	AVHDM	DDSSG	VDSS	YPDHF	STANQ	LKPVL	NVDRV	CQRCG	NIDSV
TEDSY	HRSVG	CESCH	RLRDK	DKDRQ	INGKV	RDVEL	DPERC	PTYTL	CADCE	NPAVE
WGEEG	NAQTD	NFPHG	RNNGK	DMKAR	TTEQG	IEDYC	EFKEN	GQGIL	DLETY	LCFVI
STNTF	DDTSK	VEKTV	NIVTG	DANDF	NPAKF	IKENG	SQEFF	KFPLD	DTRTG	GAGNC
HPQLV	SPETT	DARHY	APRVN	LPGRA	ETHII	LYPRV	QGYNE	DSRKG	GLKDA	YKGKI
DYGQD	GKETL	VLDLI	KRFTD	TVEFG	NPAKL	YGSIG	SSADA	DPEKG	VFGQG	YLGPK
GTSAL	KETLQ	SLEKQ	ALPTG	LSNDV	WKGRW	NQSLG	DKTEG	VNGKY	NEKFI	NDGKC
SVGAL	DLPED	RVGKE	TESTR	LEDRS	GENSN	SVSQG	DEGRL	CFVCQ	REEKV	NTNWF
DLKTG	DKESG	VYPDG	YSELH	DEKTN	KSSST	HRKTQ	DEESE	NKVTR	DCGNN	YFGNG
DMRLG	HSKLS	HLKGG	RPDIY	TPDSS	NPDRG	WARYY	YEAVS	PETRG	EPAEV	RGNRG
ETPTK	SPLRN	FPRWA	NLQAQ	SYDKQ	DHLLR	WTCKS	PISKA	LQGIE	EVMQT	DVISG
EHENN	SMYDA	DAVRG	NQLYG	SSEKL	GYNQK	YGDEI	ITKNI	PPGIV	NNPTG	YPGSS
NAKAG	RYPQS	TEEEF	SPRFR	SMLTA	RPSVF	DDKSA	NKEEV	WADKF	LTKFY	FKNKA
LEPHF	NGKEG	QVLES	DQAF	VPTSG	DPILL	TFAES	ERDAF	TSDNK	IPGLR	DTSSS
DPYCC	HIVTR	DPTYG	CERCG	TEGPH	NPGTN	HGISK	EDETK	YEDDG	HPTMG	TSSTW
WRNIM	IKNEI	FLGTS	CPGCQ	DPVKN	TIDNA	CMNCH	ELSTL	NESTG	YACSC	TPWSQ

CAGLG	PEEVL	QEAYG	LYLEN	SEEHG	MPNWG	LKGVD	ETFG	NVQNG	CKSCG	DHNAV
VLQDN	GMQAT	PANMF	SCLED	CRAHL	LRDAG	DAVFG	DVTKT	PVGRV	CLDCK	VGTDG
GYIDD	TTGVN	CEVCG	RKGKG	NDGTG	DGSTY	SWKKI	KKGWR	PVHLK	SSSSS	QPNKQ
TWGNQ	DRTMK	CNIHG	LCLPI	HARFS	WEDKY	GNDVV	CLDRS	GPGEN	DTKCV	NEKQC
KGTTN	TMKEM	IRAYN	LDGNR	TVDLG	DGETL	DVSQA	KLGR	GSRVK	DVVNG	CMTCH
SARYI	NNEKG	IPGKK	AVQES	NPATF	TYDEQ	LNIGE	ALKDY	KLEEL	IGQMC	NVTNG
ANEEG	TIENV	DETKH	GKSKA	HIKTG	VKETG	DQIGY	NAVIG	PDENY	SAGNV	EGDNE
MGAGS	HETIM	ENFFA	DQTTQ	GFPQA	DTKEG	DEDNQ	TMLSD	TIKDG	DLDRV	GIDKF
ALTRT	FNQTN	KPDDT	DPEMC	TPTRW	HPTFG	SHHDM	KDVVN	NTEIN	NPPFV	EFERV
DRATG	DDRFG	SAFHD	TWQIF	KPERL	DPEGH	HPDRF	KKLMD	QNHSG	ATPLF	AANLI
IFTPL	SMRQI	HPETK	QEGIL	SENGI	HPDNA	ENGKN	LMDRH	DKRFR	KPSVQ	CEGQV
VSWAQ	TPAQL	NEAEG	SYETA	DRKKG	DDKTL	TAEFA	VKPLL	FRGRA	QQGTK	KDRNR
YYGKY	YRMSN	EEDLY	KPVS	CFFCY	PIQNL	QEPFV	WCGHA	DTEAR	NPKDD	DFDSV
CVHLG	DSKDS	DPQVA	NIGTG	AHGTG	DLSVI	MEKHN	SSAKM	CNEST	SFPEG	QANNND
YAKGA	NPFIG	YGGIG	NTHSG	DARAG	LSVIK	DLKNV	EPGVL	VAHLV	GAVMQ	EPFVT
CPCHG	DFENS	GQMTA	GARAD	DPAVL	GPALS	CRHCH	ECRTV	HPDLM	SDKEM	HRSYC
DSSTG	QAWWY	GGMGG	SEPSK	DLEKG	NWLHL	CPVCG	APRAG	DEVTK	LASTG	FHGGQ
DSTMA	PHNWY	DPLNG	SLDAY	MIKAS	YVPLG	TVYNS	TPNCA	SLDKN	NEQTM	DSRTA
NNKDG	GYGEQ	PLNGY	CGSCK	SKEAM	SWKGT	DPVAM	LKNNN	NSWRD	VPGPH	DEKGT
NVQLD	EEDYV	GGGVG	QTDWR	DPQNT	FHESK	NALTD	SGREV	LRELV	IDVMN	VEGKG
LTNEA	APNWG	LDGVI	DDSKN	LGLLE	DADSG	GRPKE	KPGLA	EGKKG	VMNRQ	SWHKG
LTYVL	GGGVE	NEQLK	SPDRF	GSESQ	KANLE	VFTFF	SESTF	CVKCK	GPAAF	TRPYN
WPFHG	DQNGQ	DPAEV	VTPPG	VPIAG	DEKYS	DPEAE	DPQTK	LVLQY	CTFSE	NPENG
NENTI	DTASS	IDDTV	DPALG	HLDTT	DKDKC	QEPLH	LFPNG	IANGS	ESETF	VLISR
SNDVK	VVGEH	PATNM	IPGRG	VAPWI	QHGKT	CDRSG	NPNRS	YSPEG	SYRRD	LISRG
TAQNF	DDQSG	LEKDG	EIIQK	CMICS	VSTLW	CVRCE	YRALV	VDNVT	LAPNN	FFDTG
CLDYV	QPELA	FKGLY	NIASQ	CRSCG	FKGVN	KLESS	LEPYE	DVFTN	RSAGW	EPTSG
DFSKG	PELAN	DHEAS	HPQYG	DVVQD	NQKIG	CDDCN	NHQLQ	FREIA	DGTDF	NDAFG
GVGWI	LANKV	AANEV	IMEGI	SDQNV	TYGSD	NDDEV	DTAHQ	DFTKV	GKDKS	DPSTG
NFFKD	DLEKY	SLLFK	EQNNL	HHDDI	YGRSV	DKTKY	LKGKV	GVMRT	LKNLE	SPSSK
AKASL	SKARG	CLICQ	NTATN	KPSIY	DVTNA	RDGEM	AISSY	SSDHV	DDNSG	DSGVA
SSSVG	LTGLV	EIAPQ	MKEIE	GSGVE	LIPII	LEGVL	DKRKL	LQDKN	NPGDG	SPHSG
SAGIG	SFVED	QMEAL	TPDQI	GEDIL	GPGQA	TTRDI	ESHTG	CTPHY	DQETK	LSSRF
IIEPGD	VEDLG	LKGRV	SVEET	DTLTK	DKQRH	LSRYL	NDDDD	VQPEL	STRLV	PTSTK
SPSSN	DPVLH	GGFEI	QRTKT	LNLGL	SPLSA	CPKCG	DVIKY	LGEGW	APLKA	TSTKM
AEGYT	NSTTK	LPIMG	DPNTK	TAPWF	FRNVD	LPKNN	NPKVQ	LVTTL	NHITN	INGEI
LADRF	DTSLC	DLTKR	SWLER	TQNSF	DATTF	RPSTG	SYEQG	LLKVI	SPTFG	TTSKG
VESAG	GMSKY	CGKEF	AGESD	LGSIA	ATTFL	LRLDK	YEQGY	LKVIA	VWDTG	RYPNE
RLKNA	ARNTG	NSKEL	SETAV	GSIAA	TTFLQ	RLDKG	DLSGI	VKPGG	LPGGK	LEAYP
SWLHS	NSFRM	SKELA	DALTG	PGRLI	SHETA	SEEEI	LGGNG	ENFLE	QAHLE	HPGEL
NPRVN	DHAAN	KELAG	SGVGG	ELLAQ	AAFKT	EIQTL	EPGKD	KLERL	TSGVY	QRITG
DAELA	APGVA	TRNNV	GYGSY	LLAQP	QWREN	IQTLS	NNPTG	LERLG	NPKTG	WLAAY
NRSKG	HKESG	AATSL	PLEAY	SKKEY	WRENG	TDAGK	TRGKA	PWDDV	PTGLV	

附表 2 5071 个广义 α 转角

VNAAN	SPEFY	DYPFK	DTKRR	VDGRV	ANCSN	YPSGT	VEKLG	VGEKI	DPPEH	ADGGL
NAANA	DYQMT	INSNG	LYGTE	IKEDT	NCSNS	IQRGA	INGGV	DSKTE	WTKDH	VDGGG
GSEDG	QSSSQ	NSNGS	YGTEV	EQYGK	CSNSS	QRGAV	TFENG	TYPTG	TKDHP	ESDKE
AHHLs	CSGGE	LRSQW	CPPRY	DRGSG	NPAEG	LPADQ	FENGs	YPTGE	IANGS	SDKEM
ADHER	RDHRG	RVNGT	PPRYP	TVNGH	DKKNM	QGDQG	QEPLH	WAPGE	VVSDF	ILQDG
DADDP	DHRGY	VNGTE	KFLDG	LQPYL	NSIA	GDQGG	ATKQG	IFTNG	VEPVG	LQDGR
DRELL	IDSLL	LGGGI	FLDGN	QPYLS	VGyAA	TSQNE	TKQGG	FTNGK	DMGGE	FDKHM
LEPGD	DSLDD	VLDGV	YEQVA	QPNYS	ENSRG	IDTSR	LKGDE	IDDDG	LSFYT	DKHNM
DNFRT	IGTPA	LDGVP	DMDGV	LSNYR	NSRGE	DTSRP	KGDEW	DDDGS	RLDDR	ETNTG
KKSKT	GTPAQ	LPDGV	MDGVL	HSRAA	NRPAQ	FRNVD	CDRSG	KWEGE	YSPEG	TNTGE
YSEEF	FSSET	DGVHG	DGVLA	SRAAL	DNFSG	RNVVG	QRGND	WEGEE	DERGN	AEDNM
RELFN	SYGDG	FTPEG	GVLAD	RAALD	NFSGT	LNWDS	RGNDV	NPNRS	VDNVT	EDNMN
ASKPP	YGDGS	SSAWG	NFFFE	KGFGF	DEQHD	NWDSK	NENNR	PNRSK	RQAGL	TYRDG
KDSTG	SVGGL	SAWGM	PLPGA	SPDGG	IKPHQ	KTPKG	ENNRR	VGWEG	DVFTN	YRDGR
DSTGH	VSPTQ	VKGEE	TACHN	LDPGS	VLEEG	TPKGL	KLDNN	YRALV	FREIA	ASSHG
FKNGK	AKASL	DPVLH	ACHNQ	DPSGK	AGADN	DMWGT	LDNNW	LKRGG	REIAF	SSHGV
KNGKI	GYHAP	HDGDV	LQPPR	TLP GK	GADNG	GDGGR	VEPDH	SEYFE	MGESL	QTNDQ
EINGQ	TKQGF	VTGAG	HSWAD	LPEGN	SGASD	FGSNP	EPDHF	LEPYE	YKGEE	TNDQM
LNNGA	AVSGG	HTEGR	SASDC	VSNQG	GYGNK	PPAPA	AVNDA	EPYEK	IVLGG	FNESR
LDESG	SSSVG	LGAGE	ASDCP	LEAGH	GAYMK	PDQND	VNDAH	NHQLQ	ELDGR	NESRV
DESGN	GVGSA	CAVGC	TRYGG	TIFAR	LDENT	DQNDN	CVRCE	GDDTS	LDGRT	YSRNT
CHPYL	VGSAR	VRHAY	GSSSN	IFARN	DENTI	VGPCS	KLESS	DTAHQ	FGGLT	SGAGC
HPYLT	ISTGS	RHAYT	SSSNP	KMGVD	KSELE	GPCSY	LESSD	DDTQH	TPHEP	LPPDQ
SPLGS	SAGIG	NSTTK	NDQFG	MGVDE	VTTSR	CPLNY	CDDCN	GTFTI	EADDH	GKLNE
SLLD	GATTP	ITKDT	DQFGK	RQNDG	TTSRT	LPNDI	VFFGE	YIDGK	ADDHF	DGPGA
SINNA	KVGAV	GVSDW	PRLGV	QNDGS	DADNN	GRVFL	GPKTP	GFQYD	AIGGD	LASTG
INNAs	VGAVT	SPAVN	GYVGE	CRHRG	ADNNS	AFDKP	HMGNR	IPEGS	IGGDW	NEQTM
TRGAT	IEPGD	PAVNH	GAFGN	CGYHG	ARSGK	GLSAS	MGNRV	LANGM	AAPDR	KTRLG
GTVNA	ISAQA	FDQNT	FNWES	YGSNG	NNTDR	IRFGL	KWGDE	LKDND	APDRR	TRLGR
RIGGA	RDENG	YYGGA	QSGGW	GSNGE	TLFGT	RFGLN	WGDES	AISSQ	LKGNR	ATANH
VFPNG	DENG N	NSEAD	SNEGY	SFHGF	LFGTQ	FGLNK	SVPGS	PEGAE	IHHTE	LTIDG
FPGND	SPSSN	GVGSG	SKYGN	PPEGA	TTQNG	VATTG	FNAKG	VKKGV	QQLLG	TIDGW
ANGSS	TDQYG	TDAGE	KDSRG	SKYGS	KHNGK	DPKGL	NAKGQ	EQTNK	RGADG	LSLKE
NGSSF	TFQNV	RVYGD	DSRGI	IFPNN	HNGKI	FTGIS	KKAWP	FAPDL	GVMRT	PRKSD
AAVGA	FQNV D	VYGDK	DTKYS	LTGSA	ETPNV	TGISA	PQLGE	APDLV	VMRTM	RKSDI
GRTTG	NGPNE	LNSDG	TGGDG	IDENT	YHGDG	GISAP	TDP SG	PVDGL	SYMDS	VPGPH
NYAEG	TDLAG	NSDGS	GGDGK	IGPAG	TTVTG	AKNGD	DPSGI	GLKNQ	YMDSL	VANDI
YAE GA	AE GYT	GVQSG	AVEGE	DECYP	TVTGR	HGKGC	NDDEV	LNEDG	LDPPS	IDVMN
MGRGD	EGYTD	TANGT	VEGEL	NTQED	MTPHW	GK GCK	DDEV M	NEDGT	NSQFH	VMN RQ
ITSAG	YGKHN	DRDDV	IDPQG	TQEDK	TTEYY	YGPKR	LPPGW	DKRKL	SSDHV	LAKVF
TSAGQ	GKHNG	RDDVA	DPQ GK	NNPKI	TTEYY	NHLNP	DKTKY	KRKLK	LQDKN	KDGV T
VQSNG	NGPEH	AGKRE	DNHDT	DKSAP	NPDAE	KG PQF	KTKYP	ESHTG	DSHSR	LPPGS
QSNGN	DTHTA	TFKNG	NHDTG	RRENQ	IDGKG	TLPDG	KGPHL	HIDEE	KGAEG	LVFGL
DLNSG	NNGHA	FKNGA	HDTGS	IEGGG	FSRGD	LPDGS	VQSDG	IDEEW	GAEGA	STYGI
HLTDG	NGHAF	KTPRA	GSTQA	VNKKG	QYLSK	RVNGE	QSDGT	DLLVG	ANPGD	TLDNQ
RWEPE	KGGPL	KDPEL	ITATS	NKKGE	YLSKT	VNGEL	HAGNA	LLVGR	IPCGA	SLSPY
GERGS	TVDKK	GGVGG	HEGDA	ADGQF	DIDGV	VDACD	PSADQ	NDDDD	CTPHY	LSPYD
GPDGK	TTPPL	NPFRP	EGDAY	VTKNV	IDGVP	ITAKD	SADQI	HTAKR	VGDSY	YDSL N
TTPHA	NGEGE	EGPAS	IDGKV	TKNVN	FESGS	VIDNG	GPVFG	YGVDS	LPPEs	CNREG
TRQNG	CGVSG	ASKLL	HGNDY	HSPEN	HVDGH	IDNGF	PVFGS	KKPSQ	KGSEY	GPAAF
RQNGA	GVS GC	QANGY	GNDYA	SPENS	TSDET	FHEEY	VFGSA	KPSQ Q	GSEYF	LAKDA
VGSEG	CSAEE	QGVGF	DLNAF	MDRDG	SDETL	HEEYV	SFDNN	LKNGS	VKKGG	PHGEK
RRPHA	NKISN	NDGDG	GGGAW	DRDGK	NLYFQ	LSGHC	FDNNP	DVIKY	VDSGY	HGEKF
VSKYT	DTWNV	CPPLA	LGGQL	SYGTY	FHPEG	APRGR	NNGQI	VIKYN	VQPEL	CTFSE
SKYTK	HGGDL	HKDST	GGQLF	IDSNG	ATVSG	IGRQL	YYQKT	IKYNW	TLFGE	ESETF
GELGS	GGDLT	KDSTT	VRKPA	DSNGD	TRDGQ	GRQLS	TGGLA	NPKVQ	RDPHY	SYRRD
YTEEG	GASAP	TKNDN	QDTYV	VDAQG	VEDDF	KDQNG	IRDGE	SSKQV	SLGGH	YRRDK
TEEGN	QGQGM	KNDNS	VKGNR	DAQGH	EDDFA	DQNGK	RDGEM	SKQVL	GPDTN	YADDA
LPDSG	QEDGR	TNDQF	DGPFG	FYN CY	VRDDV	CTKLS	TERPS	KQVLG	PDNTN	SHNGC
VNAQG	IRDGS	NDQFP	VVPGM	ATAGD	EQPWG	TKLSP	QVGRI	VSEDE	AVNGS	VWNGQ
NAQGE	LPEGR	IVDGV	NAIDG	QYHGG	QPWGR	HTKEY	VGR II	KIDGV	LGEGW	WNGQP
IPYEE	EERGG	VDGVV	AIDGT	YHGGG	RDPAG	TKEYA	DLEGV	IDGVW	LPNNV	WDEHG
SQKDY	LADRV	VRGLG	CLKDN	SNYGG	DPAGN	SRADA	LEGVL	FKLGM	DVNGH	DEHGR
QKDY P	EHAPG	SPSSD	DEDTG	NYGGG	SRSSG	FAEDF	EGVLV	ESTDS	VNGHK	PQGT A
QIESA	TGTL P	PSSDA	LKDGD	VKAGD	NRYS T	VTPHG	GVLVP	SYGAD	LVTTL	QGTAM
TVPGI	ATAMG	DAMED	MFAGH	STGNS	CPPGT	TPHGV	ATTRD	YGADQ	AMPEG	KLDGI
VGAHV	TAMGW	NGRTL	FAGHE	MSGGI	QGNER	SGVDG	TTRDI	VHNVG	FKDDG	LDGIC

EGQMW	DFPSQ	CPEGT	PGHTK	CAGCG	NINNV	GVDGA	TRDIP	FDTHT	FEGDT	ARGAR
LRADD	IAKMK	AYRSY	TGDTM	YAMDS	MPMSM	SDAAG	PLEGA	QLSNG	EGDTL	DYQSF
GGEAR	VKVG	YRSYC	MFSLS	CSSCQ	CPTGW	RDDEG	RERFQ	LSNGE	DGNIL	ERAGQ
AGGYK	FVAGV	WSSGS	FSLSC	TKSGM	HGRGT	DDEGR	IDDS	GMESK	GNILG	IPSDG
FNGNG	GVLGE	WGIGA	VYGT	CSACG	LKAGE	EMSTI	DDSDR	TNMFA	NILGH	YLAPN
NGNGL	MKKEQ	SSVNP	YGT	RAQGN	KAGEL	IQGSV	KDDNG	NMFAT	NIEDG	LAPNN
IDANN	CTFHP	TGFQK	LKRQ	CSTCR	AKNGK	ERTNG	DDNGN	QGRSN	IEDGS	GSKED
DANNN	EQQK	YFSGI	AGEHN	LVPD	ASPTA	RTNGG	VDDPG	KSLLT	ERKRL	SKEDP
SHDGG	IPEEL	TTEEI	DCPSM	YINGS	KEGSS	NVDGS	DDPGR	SLTTS	VEWGR	RSAGW
SSGAI	SADGE	TEEIT	CPSMY	PTALI	EGSSW	VDGSL	LSRYL	FQNGK	EWGRV	SAGWN
SGAIN	RDAGL	NIGGS	PSMYQ	TWDS	GLTEE	FIETC	CPKCG	QNGKV	THSAG	DGTDF
EHGSY	RLSGK	ANKYG	RWDQ	MNVGD	YYNGK	IETCR	YNEKG	WVHQI	PKAGE	GTDFP
GGSSV	FLPAS	TNDKG	WDQGA	IPGIG	YNGKY	AGSSE	NEKGE	KDFSS	RDAEG	CQLCP
GSSVT	IGVEA	NDKGA	ELGSL	FNKDN	STSSN	KTRAQ	ILPKN	IENG	DAEGK	VKHST
VKKYN	EALLT	TIAEL	LDPDG	NKDNI	FDKDG	TRAQ	ITGDN	ENG	YFEGE	CLDNT
CTASG	PRPLV	TVGSN	DPDGH	IENGK	DKDGN	NIDGT	TGDN	ARHGI	FEGEK	RSMSG
TASGT	SMAPQ	VGSNA	PYAGM	ENGKL	SFWSG	IDGTL	QGRDD	DSNGD	KD	FGKDK
YKYDA	LKPGT	VTNKG	FEKDG	LGTWQ	DKSTM	QPEEL	ATESE	SNGDD	DTDGD	DLLFK
YTIQ	APENA	TNKG	EDA	INEND	RPNNG	DNEHI	TESEV	HSPYL	VPPGM	LGNPG
TIQGS	CAAGG	TANKG	QDSNG	NENDE	PNNNG	NEHIK	LVSDK	SPYLC	YALGF	RYRGR
SMTRY	ANYSI	ANKGT	DSNGD	LRPAH	YQNGY	TQGGA	RTGCT	LNIGL	EYNY	KTADK
APANA	AYGIN	ANSKG	GEYIK	EKKDG	QNGY	KGPNG	GVDRA	GLKEV	YNYSM	TADKK
GEDGW	YGINT	NSKGA	KNDGT	KKDGS	LDKSG	GPNGY	GTRGN	YFGVL	RPPEQ	LKNLE
EGDWK	RYKGQ	VVSRE	ERPRP	SAEGK	DKSGK	EVNGE	TRGNS	AASNN	FDAQG	DDNSG
TASGK	YKGQW	VSREQ	LQWTT	LEGDV	GNDQW	ALNAV	AFGGS	KAQNP	DAQNP	FDQQD
DPKTQ	LAAKE	DQLKR	QWTTV	EGDVW	NDQWK	TIAQD	GWNS	MVAGK	DYHGH	GQTGS
ESLGK	FAAEG	LREGN	DGHGR	GDVWE	VNGNI	KCGSQ	WNNST	YFDGE	YHGHK	NPGDG
VDKNG	AAEGD	REGNI	GPCSE	SAADP	ANDNG	CGSQI	FSSQA	AKFTD	KKGKR	IYNEN
DKNGN	NGGVN	MTGRM	PGPSC	SKTAF	WSSGW	AGKYH	LDGLV	SYDGR	KGKRY	DQETK
ADDSS	GGVNS	TGRML	SWDGS	KTAFS	CKADT	NNKTN	GVLDF	YDGRE	NTGLQ	SNAGA
DDSSA	PTSAN	QQNNG	DIQAK	VDGQS	QVAGN	NKTNP	MTWTM	DTVGQ	DSLEG	NAGAH
YGCNC	SANQE	QNNNG	DNTDL	NIASV	DSNKA	FNKNG	CSEHG	TVGVQ	SDDGT	LTGDS
DSKKD	RSEVA	DYNSV	TVQGE	ASGNA	SYKNP	NKNGV	AFLDG	AIRGS	FSEDG	STRLV
WKNKA	NRESV	QYSTG	YVDDK	LGVGI	DTVAR	RSGNS	ISEGS	RTADG	SEDEG	GHRGA
PGPDG	QSYGY	YSTGA	SWDGL	DNTNA	PILDL	SGNSN	SEGGP	TADGI	SASGS	APLKA
GPDGN	ARTRG	KRAPF	TNSSR	NTNAD	VDVTN	NLVAY	CNTCY	IPQGE	KVDGA	PLKAK
CGMLN	TRDHY	RAPFD	MNNSQ	TCPLP	NEEKA	LVAYP	TGPDC	NNGME	SDGTE	PTRDG
GMLNP	ASGNT	KQNGV	SIDGR	CPPLP	NLRDT	YLGGK	GPDCS	RRRGA	FPDEP	TRDGV
APLGS	EGVYE	QNGVL	DDQGD	NRGYS	TANGT	NMPGM	WKQHK	DQDTC	LSDDG	DTPLG
NYDQM	ECNNR	GALDY	SPRHK	RGYSQ	KNKGV	MPGMK	VSPWH	CPDVF	SDDGR	TPLGP
YDQMS	NNRGY	ARAYE	GSDGI	KWADG	NKGVP	LQGD	FFNPV	MNDEG	NEGTV	SFPLG
RGVGG	SWPAS	SGSES	NLQTR	WADGH	TGGTP	QGDLI	FNVPV	NDEGK	NRHSP	FPGLG
EVIYG	TTSAG	SPRTY	CSDNI	VDSST	LSSDD	GDLID	NMTAT	YLCGL	DFTDP	LPPGW
VYIGN	TSAGA	LAATN	SDNIL	DKDRQ	IGRNG	NGYLD	MTATP	AHSDG	VSNFH	HNITN
NNHGK	LDSNG	AATNP	HGLTG	VHDDG	GRNGH	KNQGR	AHAPF	SAYGL	LHDVK	KHSQS
QSLDK	DSNGK	DLNTN	KYAGV	HDDGR	HIGFN	NQGRE	NNPEG	DPRWR	HDVKN	SSWRQ
LDKTY	YNYGQ	SDRDG	YAGVL	INHDD	NEPGT	CRPGD	WPHYT	SEGLA	DLATG	SWRQE
QTKDG	NYGQL	DRDGS	DGPNG	TAGHE	HCTHG	FPPGE	PHYTP	MMDSG	GQKKD	LRTGE
TKDGG	GYGGY	VQPKP	PHRGS	TAGFA	SASMG	SIFAN	CNYFR	LDSSG	TSFLS	FTDSG
KD	GTGWD	VAPGY	SSSSN	DMKAR	DGLRA	IFANT	TCGES	DSSGK	PSKDG	TDSGI
DTDGK	DYPTG	PATNP	TVGGN	MKARG	YPOQF	PDEAH	FVCPG	SREEV	SKDGT	VYGT
NHMWN	AAGGL	KDSEG	SVGGV	KARGG	PQQFP	DEAHQ	KFNDQ	IIAES	DMLKF	YGT
NSDSS	HLMQI	DSEGY	IPLVD	DANDF	SESWW	EGRYS	RLGGI	KTDLH	KYTIG	LRKKG
DAATD	GQGSN	GAQDM	VNRGS	LPGRA	GPSSD	YESIQ	LGGIM	VQGGG	DDR	GKPLH
DLFGT	HSLGE	AQDMK	NDGVV	REP	DPMVQ	AQKHV	QHDKV	QQGGI	ADQEC	FEYLP
VLGKA	EGNIG	GHQGM	LYGQV	YTVEF	PMVQI	CTQDA	HDKVC	LKKDS	TDKWD	STKFG
LKAT	GDGPV	NPTDA	WNHLD	TVEFG	PSDLG	ADVGT	ALPGE	VTLAN	DGGGS	TKFGK
GKATD	KESNG	SERSP	NQLLG	NTPAG	GAPGG	VVDGV	PFITA	TLANS	TMDDM	VKNFA
TDDYG	GGPKD	PFGGE	QLLGV	TPAGM	PTDWA	NVDGE	RHDGL	EDSAG	TKAGH	KNFAV
DDYGR	RHVGD	IGSEG	RGANA	YCLDS	DWAKG	HEPVF	NDLGV	DSAGE	PPPGS	DITEV
VGVPN	ADKDG	GSEGA	CSNGG	WGAGD	WAKGQ	EPVFA	SYKFK	FLEKE	NNGTG	ITEVP
DKETC	DKDGV	SEGAG	ILPDG	RGKVR	RLFSS	IYYD	YKFKH	SAKTK	SFDGI	NKMYE
APDIY	SGDHS	FEGEP	LPDGT	GKVRD	GHTQD	YYYDN	DRGSV	VDRDG	VTKTG	FFRNK
YDE	DLGKG	KAKGV	ESVGE	VDAGT	ACCNQ	IGPSK	RGSVS	DRD	TKTGS	ARKGR
DE	PHGTG	AEGKV	STETG	SAYDV	VINFR	EIGGV	LKLKQ	FQNGK	AGPEA	DPDLG
VTLDD	TKYGD	VQDGI	MDTDG	LSNDV	GGCSL	IGGVY	NRDNI	VDNAG	GPEAK	DWNTK
FDGDP	KYGDG	EPDGT	DTDGL	IAPGK	GCSLN	AGSLG	LAPRR	DNAGQ	TRGGK	EVTGG
QSWRY	YGDGG	LTCSL	LEENH	LED	CSLNG	QVGAK	LNQSH	NIDLT	RGGKT	PTDNM
VYEDD	LDEKP	VPLGT	EEENH	TVHGL	GRDGT	VDDEA	DLKKK	IDLT	NPSTG	DYK
YEDDT	ASMFD	DATKK	SKKHA	LKESQ	HSPFD	DDEAN	SKHTI	YRGIA	YSEKG	LSPKE
VAPGQ	CLDDT	AGPKN	LKKNG	TKADE	QAMTD	LSAKS	VIEGI	PKEGD	SICGE	SPKEE
DGYIG	LDDTT	GPKNK	KKNGS	DEKTN	AMTDH	SAKSW	IEGIK	CGPNY	CPPGV	HPDAD
IGSHG	SAKTS	TAADG	QNLKS	LTPDS	MTD	EQNGK	KYGVG	NYPDS	FGQTR	LVNHV

WGTVP	VPPHC	IPKGC	NLKST	TPDSS	VVPNG	QYANG	DPPNA	YPDSP	YVDQV	KMRGV
ANNGK	PPHCK	DPNTK	VGICG	PDSSR	PQPEA	YANGI	FIGKT	NPTTG	VDQVL	MRGVL
NNGKI	CKPYI	GSEAP	GICGA	SYDKQ	QPEAI	NKEDN	CGDCP	ILDKG	AGPTN	SSPEK
WDGKG	ILKGS	IGSHT	TSMGC	SSEKL	KQEGC	VSVGQ	CPSDC	SGRYS	DKQTC	SPEKI
LVGSA	LKGSR	TNEQS	SKLNA	EKLGG	LEYTR	QTFGT	CDNGL	YRNES	KYKGE	PPNGS
STGTT	YQNDN	GADDD	NANDP	FTPRD	EYTRT	VGKYN	DNGLC	TFETS	RAGKA	FDAFP
WDGNG	QNDNS	ADDDA	GSCVD	IRGST	GNIAA	WRPYF	VDKTG	FETSQ	DDNGK	NPKKK
CEPNV	KAVGP	CGYAC	TTLTG	SMLTG	QSTNG	RPYFA	DKTGV	SPYGD	DNGKT	TNDEC
PGVYQ	VGCCY	YNQLG	TLSGA	VPTSG	VTNRN	NTEKV	IPGET	LIDEE	KGFQF	NDECV
LVDNV	DFNEM	NQLGS	YRADG	LDSNS	TRKNR	TEKVR	ASSKG	PDGNS	KVNGT	TYKGV
GTSDK	KDTEG	GADGA	RADGT	RKGLF	GRFVP	DADCF	SSKGE	DGNSY	NKKLV	VKGKG
SVNGK	DTEGY	ATDGS	DDSSG	KGLFA	EHNAS	HNNMN	IRDKK	VNGNH	KKLVP	YYRGD
ILANK	TIGIG	KNNYR	RLRDK	TEGPH	HNASP	AVDVR	ISKKD	NGNHY	DNNGT	FDNEQ
LANKL	IGIGH	NNYRN	VTPTF	DPVNK	LNPT	FLPST	SKKDY	ESADG	NNGTL	IDEEG
ASGPE	WDAYK	GGAEA	RIGDK	WSQEL	LEYVL	KQPNE	SSTLT	SADGG	MTPST	DEEGD
KLFDG	NAGPS	AESGG	ETEDH	KNFKT	VNQSF	CINGR	CPSGS	QTDEH	TLPNG	KFDAE
LFDGS	ELLNF	MDAVH	TEDHE	HTPNR	LKPNN	SKTHA	MPDMS	TDEHL	LPNGK	FDAEF
MDPPE	NFNDT	DAVHK	MRNNG	TPNRT	KPNNT	DIFTG	YTVEE	LRPGQ	LNSGE	TDHAG
RSMVE	FNDTQ	HDGNL	RNNGK	DPSGN	YSGPK	APSTH	TVEEL	ESMLG	GFQTD	DAHGD
CANGP	LTKGT	AVHDM	NNGKV	YQSHP	LEDGK	ANEDP	ELPPA	SMLGG	TSKGY	KEKNS
QVKPG	KLLGE	MNVGQ	KTPSG	IWVGE	LKETE	MDDEG	IDDNG	NTLNN	ITETM	EKNSI
VKPGN	NTIYG	CESCH	TPSGK	ETSDG	PSETN	DDEGE	DDNGN	NSKIN	TETMG	ADYGD
MIGDK	MSSDI	ESCHD	HTNNP	TSDGT	SETNP	SAMGT	RTSEG	SKING	DQNTL	GTKHG
IGDKL	AQKNL	KTPVG	NIVTG	SEEHG	YDPHF	KNVDM	TSEGG	KINGY	TIYNK	SGMGW
VRANE	QKNLG	TPVGN	APRVN	CPHQE	RGNHE	YIGQV	HKDGY	NLLKG	YVSTN	GMGWA
DEEVF	SDSLY	NFPHG	PRVNT	YEGGV	INGKV	GRRVV	DAKTG	LLKGD	KKDDP	YCNGS
EEVFE	LYNTP	VEKTV	KAAGN	CRAHL	SKRGV	LGNNI	NEETG	VDGDV	SGTGK	CNGSQ
LGFGF	SNGFY	FGADW	PKPGF	NDGTG	KAEGY	CGSNS	LPKKH	DGDVV	VKGNK	LKGKN
VPNVS	SLMNV	ADARH	GSKYD	GINPD	QGSGL	RSGRA	DKETG	GKHAT	KGNKG	YDQHM
AEVCP	HRSVG	DARHY	SSNGL	VKGDD	PTTEQ	SEEGT	WYQIV	KHATG	YDLFP	DQHMN
RYRYL	IYNAV	ARHYR	ALPTG	KGDDI	TTEQG	EEGTE	TSEDG	HATGD	IEDWN	IQSDG
YRYLA	AYADL	LLGDD	LTEGK	CGSGY	QDPWG	ETKDG	SEDGA	LLKLV	RKSKG	QSDGS
GTLGG	NAQTD	VDGNK	TEGKI	CGCDR	DPWGS	TKDGL	REKKK	LKLV	GEADC	VLNEW
APAGS	DDTSK	DGNKV	LTEST	CKGGK	LGPDG	NKSNK	EKKKR	IKPEG	RPLFE	EWWGG
LEGNR	SPETT	PTGLF	TESTR	KGGKW	GPDGV	IFDDY	SVGRS	KPEGI	VSHDG	SEHNS
APAMT	SVDPY	TGLFS	ESTRT	CGSSS	GDASG	FDDYP	VGRSE	IDKAH	SHDGT	SQSDP
DTSSR	TYFGM	VLDLI	DEAGG	GTSGN	DASQG	MNEKG	IFGDN	DKAHI	GDCGG	KQRCG
ADQTS	YVDDT	LEPDV	GAEPR	TSNGG	KGSLG	NEKGL	NGKGG	SGALN	NEAFT	TVNGI
IDDDG	VGPDG	SLEKQ	AEPRR	CDPAG	QDATG	FPVYV	CPEDH	GNEEK	FTDKV	NYDGP
DDDDG	AYDGG	SVNEE	KSYDG	DPAGI	DATGK	PISEN	CLKGT	FSKDT	LKPNS	DGPGQ
TEDSY	LNEDL	EVAHG	SYDGE	RRKSF	SGPKV	DITGK	NTKRG	SKDTG	ISAEG	HAMDN
EDSYP	GKETL	LKNGY	YSELH	TTPGG	QKTYS	QTKEK	RACDM	KDTGS	SAEGK	ISGGF
SGEGI	KETLQ	VGLSL	RPDYI	TPGGD	KATNP	TKEKL	GHPPT	FADQK	YTSFI	SLDGQ
SAAVP	ETLGR	TSDKS	PDIYP	NDGER	LPADK	KLGDQ	QPDQV	NTATN	TSFIR	LDGQS
WTTQW	ISDHE	TKDGP	FVCKN	DGERL	PADKQ	LGDQS	CRGAA	SKNGR	SFIRN	LTEEV
QWGEE	QRDGE	RVGKE	ENQLL	TDAGV	DCLSG	RTVEE	PYSTG	KNNGR	FIRNN	PYNGS
WGEEG	AGDRT	VGKEF	FRQNL	LPGDI	NPAKF	TVEEK	YSTGQ	RKRDH	SGNTT	LADNK
GEEGY	VPSGE	GKEFP	RQNLG	HARFS	PAKFR	CLEKG	HSPDD	DHLQQ	RNDKY	CADGT
EEGYI	LKNGE	ATSGS	VDGGA	ARFSA	DENHP	NTYEN	SPDDC	REGEL	GSKDV	ISEDV
RSTNT	KNGER	LAPGD	RYGGT	PAVLS	SKISP	TYENN	AIHGK	EGELV	LPIGM	ATGGA
STNTF	FSKDW	IDSXY	TKTTQ	LSKGV	GNPKG	EIKKF	LTPYV	GKEIP	VCYFY	FDGDK
HPQLV	SKDWS	RPPGH	NLQAA	RHGPY	NPKGE	IKKFN	TKSYG	NTTEH	YDENS	FDGKL
RSYEG	NHVTL	VYPDG	TRGKA	HGPYV	TEKCQ	RGTPS	KSYGE	TTEHH	YNRKG	SGEFG
SYEGR	LPED	KHLKG	FSNDL	FVHHM	LTDA	VVNGS	NVEGV	ESVNG	NRKGE	GEFGS
DYGQD	LPEDI	HLKGG	NQLYG	QPESW	FEQKG	VTPSG	VKKGD	SVNGP	PDEWE	KRLDG
WDAGF	DKESG	TINGH	VDTGE	GPLFL	ISDNN	TPSGG	IKAGE	NGPNT	QGSFG	AEDDH
GKAGA	LSLDG	INGHP	QTADK	TVDLG	SDNNR	QYNKG	PKNIH	CNIHG	GSGFM	EDDHM
YGFLL	SLDGD	DLDDG	TADKT	DELSV	TDNGV	TGNSE	KNIHL	DLPGW	VAEDF	ISKVM
ASAGD	TDEAG	LDGMS	LRPEQ	ESETF	QNLQG	IEDNG	WDEET	ITKSG	AEDFT	SKVMF
SRNGG	DEAGE	AAPDG	SPRFR	TSDAS	NLQGG	LEKSL	IGFGI	TKSGR	MEPGF	DVNMS
RNGGP	PHSKL	APDGT	QAFLA	YGAGN	FSPEV	VRDEE	EDDKV	FHNSR	SFYYS	LSEHP
LNANT	SKLSK	EEGTD	TRGAL	NPATF	THNPP	TYDGF	DEDHV	HNSRW	FAKEP	MRDRH
YSGNN	HTICH	EGTDV	RGALF	PATFP	GTPGT	DYDNF	FANGS	TDAGG	SLLDN	IKEEE
SGGNI	DLAAS	TGPEG	CERCG	VPFGA	TETHI	EKDGE	KDGRE	DAGGV	FNSSN	FDDNN
GGNIG	ASGVD	GPEGA	TLSSR	LINDR	NPAKL	KDGET	DGREY	ARLDD	NSSNK	DDNNQ
YGTSA	LPPGE	QGAYF	LSSRP	VDKLG	PAKLS	GREPD	FHESA	MRGTS	ASTDM	LDSDI
ITNQM	GESCG	IEPGE	CPGCQ	DKLGR	GENSN	EEHGI	HTASG	RGTSL	LTPEL	AKDDI
SCQGD	HCPSY	RKIGD	LYLEN	CESNP	FKHQD	LSNAN	TASGK	VNAEN	QHNDI	KDDIW
VDSSN	TKDGG	MSGGK	YLENP	CLNGG	WCPGE	LIGDY	ERLGF	NAENT	HNDIP	HCRV
DSSNT	TKEGY	SGGKC	VTPLG	DDINS	CGTGN	FSNIV	RDAGW	DPLKM	KHAVG	HCRVG
SVGAL	DEIFL	SDGRG	TPLGT	DINSY	GTGNS	HCEFS	DAGWM	LTPTE	HAVGT	CRVVG
VGALR	GDHKL	DGRGP	TKEDG	CPFGF	CRVCG	NDYPS	QRGDL	TPTEN	SLOGA	AAGDY
MEIPV	QADNV	KSDKE	KEDGE	EGKNC	KSSST	FFPQH	QGWGG	CPKTA	KPQNA	AGDYY

FDKNG	ADNVQ	SDKEW	VDEAG	GKNCE	TPPRG	FPQHP	VDPDG	LTEPP	CYPWF	AAADA
DKNGD	VGREG	VTNPV	DEAGK	ISEQG	RDDGG	RPMNH	DPDGT	YSPNR	ISVHK	VGQGS
EVNGK	GREGT	HGNKM	VKSSP	SEQGI	NPDRG	EDDGN	IRNGQ	CPAGT	SVHKV	AYPST
VNGKP	YDDRQ	TVGGI	SSPAD	IDDAK	FTGAP	VKQNK	ILFGA	TTSSC	FSDLN	FDVDG
DLKTG	DDRGN	LGANG	VVNKK	DDAKN	SFFGP	EHDLG	CNTGY	CTSKA	SDLNI	SSTGA
EVNGY	SPLRN	TTPDG	SCLED	VIGFG	FFGPF	HDLGK	ISGSS	SLDTA	FTDKC	FTDGV
DRDAN	GGPAC	TPDGR	RKGKG	PGPDD	LDREY	VSEGE	YGYRQ	LDTAG	NSLNQ	AWSGT
DMRLG	SMYDA	DQSGR	FCNGQ	YAHVG	DREYR	SEGEV	CNKGF	IKGDD	DKSFN	VDKPG
VQTDG	RYPQS	GRGRS	LCLPI	DDKVL	DKNDA	RSGAV	VNNDE	VVNNV	MSETG	ASQQR
QTDGT	YPQSV	MPTPN	LDVTG	TPHIN	ETGPN	SGAVK	IGGKG	LSAEG	RIHHL	SQQRW
KDSEG	NGKEG	FPRWA	DVTGG	AQMGD	TGPNG	KMSFG	LAPGG	SAEGP	LEFGE	TPDEE
DSEGR	ELTDY	NSHMM	QGEDG	TYKGR	VTEVC	MSFGE	QGEFG	AEGPT	IDLCL	IDRHV
FDYEG	LTDYK	QDRNN	GEDGP	YKGRR	TEVCV	LDEEK	KPDSS	CGKDG	DEKHP	LPGQG
DYEGN	FFSHS	DAVRG	LDGNR	HIKTG	EVCVA	DEEKG	DAATC	TLTGT	SKEPV	POIGD
EVAPA	FNGNH	KAADD	AGRNG	VESPA	VTDAS	MHVGH	LRPGA	SSDKG	AFDHF	VDSKT
SMQEK	HIVTR	AADDT	GRNGP	ESPAS	DHLLR	YNVDK	DGLCC	IKKEA	IVGFG	IKKEN
FTTDG	SKGFA	TSESG	RDEYG	GFPQA	ICGQH	NVDKH	CDQCR	GSPEK	EVVPK	PNLWG
TTDQG	QVDKI	SESGE	DEYGM	FPQAG	QDPGF	LSAAA	DQCRF	NVDRV	IDKRW	YSSSQ
HMNDG	PEEVL	TTEEE	VOESN	PADGH	HRRND	TRVQH	ARGDF	VDRVP	SAFDP	GSSQW
MNDGR	EEVLD	TEEEF	IGKSK	ADGHI	IGSQA	AGTYA	DPEKG	IAGDL	EDDGF	EYSSA
KGPAK	EVLDT	NDSGP	GKSKA	HIASA	YQGDE	FRMGT	CPKCK	AGDLS	DDGFL	INEDY
FDEDN	GNSYG	LSPYS	AQDAK	IASAD	GGYNQ	DPEYP	CEVCG	GDLGA	EIYPG	DDVAI
DEDDN	GMQAT	SPYSY	YAPAY	QTPTR	GYNQK	EPGDM	SVVSG	PTYTL	FKFS	KTWLV
FGPDG	MQATD	GLAGK	HGAGY	TKPNW	SQKGG	DSTLD	WKKDS	NIAGK	CKPGF	LVEFI
EHENN	SKGVV	QCSRQ	TPFAY	TTGGL	ARRMG	SEEDT	TVNGA	QGQIL	NNFHN	DFIYH
NAKAG	KGVVW	CSRQV	HNGVI	SNMLG	ELNGK	KARDR	VNGAK	YYDDA	NFHNL	SGMGE
NLASP	GVVWG	AICAG	NGVIS	NMLGA	LNGKP	ARDRK	SKSRG	YDDAR	TDNHK	TIGDT
PLGPQ	TTGVN	ICAGP	SAEKP	PIMGV	ANRHQ	LKDGA	KSRGT	KFPLD	DNHKK	TYNGL
NTERL	TGVNA	KDGLI	LHNGK	FEQGH	QASGL	KDGAR	DIVNK	DGKRI	LPEIS	TLRGW
TERLT	GVNAF	DGLIL	HNGKW	ALNGK	HDGER	RGPQA	IVNKV	GKRII	DDDLA	YVENG
TVPHY	NIGGD	QVLES	VKNQK	GRHGL	MADGV	CLEPY	VNKVV	DSRKG	VKDGQ	RVYGL
VFPDG	WSGDG	GLQGS	RTVHG	NRIIE	ADGVA	LEPYT	LKPVL	TVNGH	KDQGI	CYHDE
FPDGE	IGGLR	AGGLE	TVHGN	RIIEA	PSREN	LDSHS	KPVLP	FVRNL	LSASA	YHDEL
YAYDA	EDLGM	DPTYG	DQTTQ	RRGND	DRPGT	LDSMP	SGFLT	RFQKS	SASAT	TDLDV
LEPHF	TMKEM	PKAHE	DVNGN	AASGV	ELNNI	LVNEQ	WGAAG	NYRDD	TNDFI	QTPIG
EPHFD	EMHSW	IGEGV	RQSGH	PYPYE	CIGNT	VNEQV	PSKRA	FFHKE	RFKGV	VRRRP
LITKL	NNEKG	VRPGD	LTQSD	LPEYY	IGNTL	SINEL	NPANG	FKHEN	FKGVS	LHADQ
LKGDK	VEGGS	DLSMP	LNDDG	GFGLC	NNQHL	RSDEY	PANGA	IDDDK	ARENG	HADQS
KGDKL	QGNRG	TMQDG	VPMPF	GVDNF	SANRF	SVEGN	QQNGE	DGKQY	CDQFC	HPEEG
TANQD	GNRGP	MQDGT	TTQDG	YNKDG	DPILL	GARGG	GKPLR	GKQYT	HENSV	RRDQG
RETTA	RTIEN	TCRKG	TQDGP	NKDGK	PILLN	SSEGY	PENQQ	LPEGV	ENSVV	RRDQV
GGFDQ	TIENV	CRGKP	NNFFG	EFNGQ	ILLNL	VSSKY	SLDKG	VNGKY	CARGY	FENGE
RPAGF	AFEPY	FLGTS	NFFGV	ADQAG	NPGTN	SSKYA	DKGKS	CFVCQ	LADNG	ENGKE
DPYCC	HETIM	VKVAK	VAPGQ	DQAGN	TCSGN	YAGRA	RLFEG	YHYGV	ADNGK	GCKRN
PYCCN	KVANH	SNGGV	IAPDG	VDIGS	CGSNC	FPENG	MDERM	HYGVS	VSAEG	DEINN
PVNGK	VANHT	QEAYG	APDGT	ISPNM	VGSNS	PENGT	DERMM	CHRDK	SAEGR	EYNGK
VNGKE	AAKPN	VTPDG	VDKHY	SENGI	GSNSY	NNKDK	WNVTS	INKVT	CQRCG	YNGKT
ATAGC	NPTGA	TPDGR	NFGYG	INAGK	LSSGD	QKKGL	REGES	NKVTR	DVGNV	EGADA
AGCHD	AGCPP	CEVCG	FGYGS	NAGKE	FNENN	KKGLY	EGESL	SINKR	VGNVK	IVDHP
KSAKG	LDSLQ	VCCNQ	DPEMC	VLPQA	NENNQ	ISFKQ	VANKP	INKRK	CADCE	VKAGG
GCKGS	DSLNR	CNNQD	VEPGV	VSKYG	ASGNQ	SFKQK	LDNNW	FTWDD	LRPGT	NAPEV
GSKCH	KFNQT	KIDGG	YTPYG	SKYGD	KGGDA	FDDFQ	DNNWG	RRSGL	KMDGG	VEEQR
SKCHS	FNQTN	IDGGY	VLANG	ITEKA	IGQED	HTNGN	YEGCV	PETRG	NLETG	LPSRA
VERTG	KTGMG	VGAVA	LANGD	TEKAV	ITIDN	TNGNV	YPKGF	FTPQG	FNSGE	DFNGI
TERGI	TGMGA	GAVAH	TWQIF	DRKKG	TIDNA	FYGGG	YTGSI	TPQQG	PEEGE	SNMFA
EIKGR	FKLTD	MEEKH	VAPRD	CFFCY	APEGV	GSLSG	FKENP	NCLGK	EGEEM	LKAGE
IKGRR	HNDAK	EEKHY	APRDM	AHGTG	HGVLK	STANQ	QSQEF	TINFN	DLETY	KGADS
HGNPT	NEEDH	LADDK	NILAP	DARAG	GVLKR	FNPEA	SQEFF	NKQPE	FKEGM	GADSL
WRNIM	DDRFG	CNIHG	QEGIL	ASVGE	GATGK	GGDTS	FSDHG	KNKHN	MYEGQ	LCFVI
DLIGM	NLGTG	AIRAY	GGPHT	DPAVL	MPNWG	BDTSP	QGYNE	NKHNY	YEGQP	CFVIE
GMGDS	RGTRG	IRAYN	WSADY	PAVLQ	LRDAG	LSVNS	SSADA	LQGIE	TLETG	RCPRP
SGPER	GTRGE	RAYNK	LPENW	VTSSG	DGSTY	VRDVE	DKTEG	PPGIV	LETGA	CNAGL
RSQAG	RGEHT	IPGKK	STNIG	TSSGV	LSASG	LRGNC	SSRSN	YEQLP	DTRTG	CSIYG
VLQDN	SEGGV	FTPDH	FAKGT	YTKST	SASGR	TAKKN	DEGRL	LFEMS	STDKV	SIYGY
PIAGT	AGQDG	DETKH	LMADG	DLEKG	GRDGK	IEDYC	PDEES	FEMSL	TDKVR	CGAGN
GALTT	GQDGS	ETKHP	MADGS	LEKGI	KMEGW	EDYCT	DEESE	KDSSG	IGLKD	GAGNC
GAHFI	RFDGQ	KEENF	MKGDK	AIDGT	AYWPP	IKENG	TFFFQ	DSSGR	GLKDA	CRCQC
ISNGE	INETD	KPDDT	GKDRG	FDWNG	DGETL	LYPRV	FFFQC	PTSDN	VEPGG	KARGK
VNERG	TPAQD	TAADG	CNATH	DWNGD	TYDEQ	YPRVL	YEAVS	TSDNK	LKEQG	PENSM
NERGE	TPAQL	AADGT	TIKGV	LSKEA	SHYRP	CDENG	KDGNK	EHDER	KEQGE	FNEDG
TSSGG	PAQLE	ETAAG	KAPDG	SKEAM	VKETG	DENGN	RSPAD	YEDDG	ETENG	NEDGS
GGYID	AQLEM	TAAGY	APDGR	KEAMH	DLNLL	YGSIG	KTIAE	SWVGV	TENGT	IGEDY
GYIDD	MEDED	TNNYY	LLANQ	EAMHN	LDGSH	VFPNG	IAEGR	IVMGI	ESDDT	LSAGQ

YIDDP	HSNGN	LGYDS	LANQV	MHNKA	DGSHR	FPNGT	PISKA	VMGIP	SDDTL	DSWRA
ILSDN	QRPQ	EKDQK	YFGEF	LPPGS	DTKEG	LSSSG	KQEDG	TDDKN	IEDDE	FDGNF
PNIYK	IYRMS	KDGKP	FGEFG	HDNGK	HPTFG	SSSGP	QEDGS	DDKNQ	QLANG	DGNFN
NGSDV	YRMSN	SAFHD	LLHGG	IKAGD	HMGDD	MGQNG	KTIVA	IGKMR	LANG	SSSNY
TWGNQ	GSQTA	AFHDI	LHGG	TDSGE	DPEGH	GQNGA	TIVAK	DFKQK	VGEHR	TKDRC
WGNQI	SGTAF	DKENN	HSGSA	VYQDK	PEGHP	NQSLG	ITKNI	FKGKV	VFGQG	ACKGQ
RNNDP	LTSGG	KENNI	SYETA	LSPGG	HPDNA	AYGNG	TKNIQ	MDPEG	PDMGD	CKGQT
SAATG	KIDGS	TKKGK	YETAH	SPGGE	THPNS	YGNGL	IQNGN	DPEGE	DFDPG	SKYPN
AATGD	DSKDS	NCFPH	GPHPY	VLNDK	FNKDG	PTDSG	QNGNA	TNKYG	FDPGH	KYPNC
LMPGA	NPFIG	HPETK	GGHGI	LNDKI	NGKDQ	TDSGA	RQGTK	NKYGT	VKDNQ	EGNPY
KSVDD	PRNAA	LDEGE	IYFGM	FDPNG	DDKTL	SVSQG	FGEDG	KQDGH	FVANL	ISPSG
VPAGN	KAGGA	NEAEG	QTADG	DPNGY	KDERL	TEPSR	GEDGL	NTNSG	NFVGC	PSGCV
PDKGA	DFENS	VPDDE	TADGQ	VSKDK	VAEDS	EPSRD	VKTDG	TNSGK	FVGC	TQSGR
KGTTN	MTKWK	DPQVA	KPVSR	FHPNG	FPIQN	HRKTQ	KTDGQ	NESTG	VLGNK	YLGPK
SPAQA	TKWKA	YGGIG	PVSR	HPNGY	STQSN	LEPGD	VEEDT	GKTQL	FIDQK	LGPKG
IATGK	AVGRY	LEDDE	VHGQQ	RTPSK	TQSNP	FNKDG	ARDNK	NVQNG	NEKFI	GPKGF
IAKYG	LGPLR	VQSGK	TPSKI	HGQQF	AIGDQ	RKASI	VHMDT	DSRFP	EKFIH	VTNPS
SYDD	QAWWY	THSNA	NIGTG	VSNQD	IGDQI	LEEGI	VDEKG	PVGRV	WSTSG	TNPSR
VNNA	LPADI	GQMTA	KKDGL	FSSVG	LSVIK	VKKGT	DEKGE	LPVHL	STSG	CTRS
VTEDL	ISGTQ	TAGSW	NTHSG	SSVGT	TGPAL	IDEDL	NKEEV	PVHLK	CGSAC	TRSGN
GTDTV	SGTQF	LGGMG	LGARA	VQGGK	GPALS	RGEDG	KEEVP	EGPGK	REEKV	GTTCG
RPATA	NIDGK	GGMGG	GARAD	IPKWN	LSKHQ	GEDGT	RSIPP	GPGKN	LDEDS	TTCGS
VINDR	IDGKV	DPLNG	SEPSK	CCEPY	LLPNW	HVHEE	PSMGD	FGSRV	DEDSI	PAVP
SARYI	PSPGQ	PLNGY	LAHGR	SDYYG	NWLHL	FFSFG	RSNPP	GSRVK	PLYST	PAVPY
ANEEG	SATGS	FCRGV	QMETG	LEHFD	VVSGT	KTAHS	CAPTC	SRVKG	STERT	NDGKC
IIGNR	TGADG	FQGLP	METGL	FDLQS	NRFG	HSQGI	SRSRP	ERLNG	EEQEE	NTNWF
GYQDD	GADGL	VGLGL	VPSGG	TNNLG	YVPLG	WARYY	ACNSF	PKLEE	FDRFG	TNWFP
GMGAG	ADGLQ	SPNAE	DPQKP	NNLGS	KGEGM	ARYYP	CNSFT	EDTSG	DRFGV	FGNGR
MGAGS	SDYGG	PNAET	SLDAY	VNSRG	SVNGC	VDGKT	SGDGY	DTSGK	SLEGQ	KWSGE
ALTRT	GNATT	NAETE	FNTEA	NSRGE	SWKGT	YGDEI	LLDNE	PDENY	KPHDC	DNHDN
LTRTS	AQQNP	AMRDG	NTEAH	VADNP	WKGTK	DDKSA	ERDAF	DENYT	DCGNN	FVNGE
TRRDD	FANGA	MRDGS	CGSCK	IDRNG	VGQGG	KTFAE	TSFSG	TIKDG	CGNNR	VNGED
RRDDK	SDPYT	GGGVG	CQKSC	DRNGK	LLDGD	TFAES	SFSGD	DGFNL	RGDKS	NNNGV
QSHGA	EDTNG	VGMGF	CPTGC	GGESS	GDGYR	AQCHV	EDETK	LKANL	EPAEV	NNGVI
DDNGT	DTNGK	DLDDV	PGNGM	YKGGK	RRGDG	KDDKG	LDSDM	KANLS	PAEVM	INADT
DNGTI	INPEG	LDGVI	SSEGN	KGGKI	RGDGE	DDKGV	ASNSH	STNFN	EVMQT	NADTT
DRATG	NPEKG	DGVIT	SEGNR	DPQNT	FHESK	WSKGI	DKVGT	NTEIN	VMQTP	CNDNW
NAPGA	VKNGR	GVITD	TSKWK	ARYGK	HESKN	HGISK	SLTLN	TEINS	NNPTG	NGSNQ
IFTPL	YEANG	NEQLK	GPGST	PLYGL	DADSG	QEGAV	SERGL	EHGKK	LKDNP	RGNRG
FTPLN	EANGQ	ASKPA	TNGSQ	MENGK	LVKDP	EGAVK	FNNGT	NPETW	LTKFY	DVISG
TPLNL	PHNWY	KQDCN	AGNGK	ENGKV	GAEDE	CMNCH	ELSTL	CMEIC	TKFYA	VISGD
VSWAQ	HNWYP	QDCNT	LTDDE	KSEGE	EVLGK	MNCHR	DSNSF	AQYKA	GRANY	KVGNS
VNSTQ	GVRWS	CTPTG	TDDET	SEGEV	VLGKR	KSSYY	SNSFG	QNHSG	LDPEG	VGNSC
YGLGL	GYGEQ	TPTGV	IRNPF	AAQKG	MDKAN	SSYYD	ETEF	SSRQ	PEGSD	VSSDG
GLGLR	EEDYV	SKSGS	KDPFT	LGLLE	DKANL	VLKED	SVPGE	LQQGD	STPDN	SSDGT
LSCGI	APNWG	SSGST	YIDGV	GSESQ	KANLE	QTKNG	VPGEF	DPKKG	HPTMG	FLPYG
TVQGY	NWGQD	SGSTT	NHLGG	VPTAG	ANLEM	TKNGV	HSSWV	DYSGK	YACSC	VISES
ASKDG	DWTNT	GLKGA	LGGTG	DVGGL	NLEMQ	GDETG	FNDSG	YSGKR	PDGRA	ISESH
SKDGK	HSDGN	DIDDT	QTDWR	MQNGK	GRQLD	AFKGQ	GWWDG	HSGDP	CKSCG	VKPGA
MPNMD	NGGGV	IDDTV	TDWRP	VGYSN	WSEKD	AGSKT	DVKTG	DKRFR	CLDCK	QRPQG
RAAMS	GGGVE	DDTVL	DDSKN	LQDGK	DEKYS	EEGYI	VDEHG	FRGRA	SQPLR	YPGSS
ANPPN	YGPNG	DTVLF	ISPDR	QDGKI	DKDKC	THNGR	DEHGD	EISSN	YCVHR	FKNKA
GSYAS	GGTYA	SPESE	SPDRF	ITENS	KDKCK	HNGRT	LKKGW	ISSNR	HNGTI	DTSSS
GHSRW	SAPFD	PATNM	PDRFR	HLDTT	TCIMS	KTDET	SGMGA	FKNGK	NGTIW	KLWFW
DAPLN	VIGGV	GAFGE	SDNVN	GQPNW	LTYAG	DAVFG	GMGAD	PMFSN	VGPQL	LGWFP
NWCNP	IGGVT	FVEND	NVNLP	VAPWI	WTESS	VYGKG	CLDRS	FSNIL	NFNSQ	LQSDL
TCGRG	SDDGT	DDDWW	YTIDG	APWID	LYGDG	AKAGE	RIPAC	DTEAR	SSSSS	QSDLY
CGRGE	RDPFG	LEKDG	TIDGL	PQEGI	DPTGN	SKLGL	CIAGE	FDYDS	SSSSC	VTSST
PQAGR	FKDGG	GDNRG	ADDRG	GILSY	TDARN	SWKKI	IYQGR	PLGDT	VGGGL	TPWSQ
TVDTL	GGFTA	DNRGW	DDRGL	DTYPK	DARNR	FGNDV	VKLGG	RIGKY	GGGLT	NDFDT
HAGW	NEPRG	LPLGF	SKRGV	FDPWY	TFGGK	DVSQA	KLGG	IGKYL	SDGNT	VTRET
HAGWL	QMAGL	EGETF	VPWYP	DPWYP	YNGNG	TLNIG	LKDYD	VRPLE	DGNTV	EAVAG
AGWLG	LRFGA	IDASK	DQQDP	VRGGK	GGPQG	LNIGE	FSQPR	EDERG	DTKCV	VTGTD
GWLGW	GAGDL	VPRGV	GTPHR	RGKGV	IPPGG	DQIGY	PNAVI	DERGY	TKCVK	QPNKQ
GLEDA	AFEDF	NLEEA	IPGRG	YLEQP	QHGTK	QIGYA	NAVIG	ELEDR	DMCKE	MQGTG
PEAGQ	SPGPH	AEVND	EIIQK	CMICS	QWGID	YADNF	AVIGK	CNTSI	YVDGS	NEKQC
GLAGF	PGPHG	STDGT	PSTGQ	FLLLN	WGIDD	LRNGK	TMLSD	RCNES	VDGSA	LPLWQ
AYPLT	PPPWW	NFGAD	PDNFG	SLLNR	GIDDV	RNGKF	RYPLY	CNEST	LPDTE	PGDDA
VGPN	PEPWF	SIDGS	PDNFG	CRSCG	FSDAG	DEDNQ	YPLYT	LDDSL	ITEET	CMTCH
CVHLG	NTHGS	RLVGP	STEDT	GGVWK	SADGQ	EDNQS	KDVVN	DDSLV	TDAEF	MTCHR
YAKGA	SESTA	TFEDG	NIASQ	WKQGW	LTNGA	NTVRG	LTNDV	VAHLV	DAEFV	NLMVG
CPCHG	DQNOG	FEDGT	HPQYG	YNAHH	TNGAI	TVRGP	DSEFN	HPDLM	DVVNG	DMHYE
DSSTG	LDNGG	RSGHS	NGLNW	NAHHK	TSDNR	GIEDT	LMDRH	TVGDS	SQDRK	NVTNG

SAGIP	LPGGG	LSNLH	YTKEG	GWIQT	ASDGG	IEDTG	MDRHE	PPTAS	LGTGV	ASVGD
PNNPS	IENGY	LRNGE	TKEGK	DEANS	SDGGL	TTGKA	VDDYM	DEVTK	GQMCCE	FEGDN
EVKGK	FGDGA	LKEND	HWKNI	QKSGF	VLMGE	AIGLE	DDYMN	ANGGQ	QASEE	EGDNE
LDEDG	RLGSP	DHEAS	GYKDG	GSFGL	AIAPF	VHSDG	CKGEE	GIGGE	ISNDG	SAEAV
DEDDG	GSPSG	AANEV	YKDGS	CPWKV	IAPFD	HSDGT	KGEEK	IGGEP	SNDGK	CKSSS
DTRFS	MAPRS	ANEVN	TWNGK	ISDQN	FDKPH	SHHDM	NEMFG	EPASK	GEKNG	KNEHQ
TRFSP	DTASS	SLLFK	WNGKE	SDQNV	KINGQ	HHDMY	GKYVK	SLDKN	VKDDW	GGIDK
GDSTM	FMKRI	LLFKS	RLVNC	GDDFR	INGQA	MYDYL	GKGVV	WDENY	NRGGT	GIDKF
DSTMA	MINDK	PRNGG	YIIME	QHHDG	SENGK	YDYLH	WCGHA	YEDDD	SAGNV	AAPEY
GGSGT	LWQRP	FTPVN	IIMEG	HDGIT	ENGKP	HPDRF	FELSG	VNYMN	TVNGT	APEYL
VTAGD	KIGGQ	TPVNE	IMEGI	DGITG	VEGNV	NGKNY	SSAKM	NYMNE	VNGTP	GTESN
GTGAE	GGIGG	ETQMG	MEGIF	KPSIY	GSFSN	GKNYY	ICLCD	FGTGG	KNDGT	TESNP
VYDGV	EICGH	TQMG	GILGL	SRWPG	SFSNG	SHEDA	EPGVL	LIEGG	NDGTT	EKETE
WETGT	ICGHI	RQNGS	LEHIS	PGSGV	GMPAG	HEDAM	ECRTV	IEGGY	GGNSI	KETEV
FPIDH	VAPDH	HNGPR	SOQTT	GSQVE	FNGGH	TAEFA	NFPPF	PTPNT	YNSSI	NHDGY
NNKDG	VVGEH	GAGRR	QGTTS	GEDIL	VSRDG	QEPFV	YTVAG	ANEKG	NSSIK	HIDGYD
NVNFK	VEGHV	AGRWR	TPPGS	EDILP	SRDGK	EPFVY	TVAGE	NEKGQ	DVPGP	NHGGT
DERNG	GEHVQ	GRAEQ	GLDVY	TDLAN	VSTWL	TMSDG	APRAG	NSWRD	GPSDP	PNGNA
NVQLD	DLPGS	RAEQL	EQNNL	DLANN	AGTDR	MSDGT	PRAGF	SWRDP	NLRGE	TVDPL
VQLDP	GKRKV	CLICQ	NTATN	DTLTK	HRAHM	FTVNG	CGYNG	SRPVQ	LDRVK	VDPLV
VSDSG	DGSGR	NGPKA	ERSGM	VPPMG	CPADS	TVNGD	NLEKD	FPRNS	YNPGD	WGNWR
DSDGA	DDQSG	IHPDY	LSETA	PPMGL	VEPTP	GNPHT	TPNCA	TRRVS	PRVGQ	TVDGG
LTNEA	NVGGR	FSEEA	RVGRI	FSEQG	FKGVN	PNHTV	LKNNN	FVGGL	RVGQN	PSIKG
TNGKD	VGGRI	ERGPW	VGRIS	SEQGL	HTTGL	RVNNS	STNFK	VNGAG	FFGNT	SIKGI
LTYYL	GVIGT	RLVGM	KINNT	LTQDS	GNQKI	AQYIE	PVNQV	NGAGK	NPPFV	RINGN
MQKHS	VSQNM	IVDGK	INNTL	SGAYL	NQKIG	VKKGT	STKSG	TVFDP	PPFVF	INGNP
WPFHG	SQNMG	VDGKI	GGQWG	GKLES	TYGSD	TGIND	IVKDV	KLRGV	FYGAF	AIGPY
TGING	GKNGD	PDDEG	NNPNG	GLPSV	YGSDY	MEKHN	GGPNV	VKGGY	IPGTA	DLGNM
GINGT	KNGDL	EIAPQ	PNPGA	LPSVV	GSDYD	DPANR	LLVTG	LRELV	TRQNP	LGNMI
LPYGY	PPQGA	IAPQM	MKEIE	LNLQY	VNDRC	TQGGK	LVTGQ	EGKKG	LKADK	NPKTG
HGGGE	QPELA	QMEAL	VAKDG	EDANT	NDRCE	DLKNV	RVEER	RTKAR	KADKK	QNEYF
ENENT	LANKV	TWQAE	AKDGE	PSKLH	DDGNV	VDGQV	SADPP	TINRN	LGASA	EFERV
NTIFS	DLEKY	FGSPD	TDTGG	TKSSA	QVNGA	CRHCH	ADPPL	INRND	INYES	KQPIS
FSNDV	LEKYK	LNPGW	IDAGD	TLTTF	WDGTA	CPVCG	SGREV	MVSGF	NYEGK	QPISA
SNDVK	EEKGI	NPGWV	EEAGG	TLTFL	GATMF	GEDSD	GREVD	ERSNV	KPSVQ	AANLI
NGGNC	SKGDA	TFGGK	EAGGA	VCPME	EQNSG	CDPDE	LGHTG	VSNNH	PSVQP	ANLIA
CTAQN	KGDA	FGGKE	GTPDQ	REGKA	YMDQP	DPDEC	GHTGV	SNNHV	ELNGT	QKPDG
TAQNF	ALDAG	LSPED	TPDQI	EGKAR	NSPGW	TTIRG	TFGDH	SAPCS	QQGTK	KPDGV
CLDYV	LNSGE	YSGDK	PDQIY	EMKRG	WTATS	TVYNS	FGDHD	CPGIC	NKWGK	CEGQV
LDYVA	FDDSG	YDPLK	KSVEE	MKRGV	VRHEI	HDGKT	LDEKG	EGSCG	SNGPG	EGQVN
LSKRE	DDSGS	LKGRV	SVEET	GTAAT	RHEIP	DGKTR	DEKGR	GSCGM	NPKDD	LEEPY
DFSKG	CKTGD	KKAPG	SQRTK	QSEEG	SNHAE	GNPNN	YGKGL	QQNNI	PKDDW	KDRNR
FSKGN	NQYVK	KAPGV	QRTKT	SEEGV	NHAEL	PNNNA	NPEKM	FDLDK	LRDGR	GGYGS
GVGWI	QYKGD	LGGNG	RTKTP	VTFML	VDTNA	WYNRR	QSERM	QKGKV	RDGRP	SPQGE
VGWIN	NIKGF	TIGHI	LTGKG	VERGI	RAGNS	YNRRP	LLPGQ	YGKEK	HNHWA	QANND
SGVGQ	APGGG	IGHIL	LKIGV	FTWDG	AGNSA	CHNGV	RVGEE	CVKCK	NHWAQ	ANNLD
SLGFN	CTTGK	KLANG	NLEDL	TWDGP	SNQGA	SATGP	VGEEE	VKNKH	MEGDS	AAPWW
LYGTT	SYVLD	LANGD	ARREQ	GSSGK	QRRNG	FKEGK	LAPGM	KNKHL	EGDSV	ANWRH
RRSYG	VWTDG	AIINE	SNVTP	TAPWF	RRNGS	GERAE	APAGA	LDNKG	EVDGE	NWRHP
LTEDG	SKARG	TKAGA	ARGAH	APWFQ	LIPHI	DNWQG	QQSGT	DNKGQ	VDGEE	HPEGP
TEDGK	NSNGV	GGFEI	GSGIG	VNAKC	RGSGV	DPVAM	QSGTS	RLHEA	ALGGL	EGPDS
ARFVR	SNGVP	TYKKG	TTHSG	AAVNG	VRPGI	DGVNT	NVLRA	LHEAD	IHMNS	ILHRP
VRPGA	LTGLV	YKGGP	SGGTN	TTSGS	ARQGV	NALTD	SESTF	ASGPA	SVNGY	LFPWG
KNTDG	VTNNA	DPVDG	QSLYQ	MTDGG	DKQRH	VLNTD	ESTFN	NIHGH	NPYMG	FPWGN
NTDGG	SFVED	PGFLA	KNDEN	TDGGE	KQRHH	GRPKE	DPQTK	QREGR	VVEGG	EFVPT
TSASL	FVEDL	LAYSS	NDENI	DGGEE	PSPLS	RPKED	FAQDG	REGRD	HTKGI	GEDGF
VDSSG	VEDLG	DGKNI	PYHDF	PEVKP	SPLSA	TFANA	CLSIP	RRPAV	SPFEG	FQGTA
DSSGK	FDGTI	GKNIT	YHDFI	HDGDD	GFFGC	FANAK	LDRDG	LSKVT	YEDGG	APVDA
LDGDG	LDNAG	ITPQF	CGSDN	DGDDD	CPQDW	NASGV	DRDGK	SKVTT	LEDGC	PNGYG
DGDGN	DNAGD	LPIMG	GSDNK	LEGTS	WHGEN	DLELG	HEFRR	LVLYQ	EDGCL	NGYGL
NFFKD	YGNVY	LGSGS	SNGTL	EGTSL	HGENC	LELGS	LDETY	VLYQE	GAVMQ	NIVGN
FFKDV	PVGDD	INALG	LSFET	TKGDD	RNPSY	VFTFF	LEKWS	NPDGS	AVMQK	HRSYC
FKDVA	ESPYQ	NALGL	DPNTK	VSGGK	LWEDG	DPEAE	LFPNG	PSSLD	VMQKK	RSYCY
KDVAP	FPTDY	AGSDG	KVDGR	YYNGV	WEDGS	LKPEI	SVGEK	SSLDP	PADGG	NTPDS
HGGGQ	EPTSG	IKENN	GKNGA	IDQQG	APRGH	VKDGA	GNDEN	LYRQR	KDGGK	VKPGG
FPGKT	NDAFG	DGNSS	KNGAM	DQQGY	QLRGV	KDGAV	NDENY	FEDGT	DGDEV	ATPQG
DSRTA	DPSTG	VENNI	NRSGG	DLTKR	KELGI	VSEQH	KNQVA	WAGES	SFQPP	YGAEN
FPAGK	MDGNG	YDIST	SGLCA	NLKNQ	GGLQG	WRGTT	SGRGK	EANGS	LAHDQ	ENFLE
CATSP	DGNNG	KTLTG	VSDTE	KGPGD	GLQGE	HNKLG	FTNPP	ANGSN	REGDR	NFLED
DEKTG	GGNDA	TLTGK	THKDV	GKEFT	NTDEV	REGNE	ITVDG	QVNGI	EGDRL	NFEHP
DIDGK	TMSDG	VEPSD	NIGLY	HGYRA	VVREP	EGNEL	AKGGH	IQDDT	RLNGH	ERLGI
IDGKP	MSDGR	IFAGK	IGLYK	ASSTN	NFQQP	RDGDV	KGGHR	GTKSI	LNGHP	ISNDT
VEGKG	SPSSK	IQKES	LMFGL	NPLQP	SASDG	DGDVL	THPDG	QRITG	SPTFG	VNPDG

RDEYT	TSGSG	INGEI	KKASG	LHENT	ASDGS	PLPHE	HPDGR	AQDGT	PGGDH	NPDGT
SWHKG	QSNRG	EGTEG	KASGA	AHSLG	VVVDP	VAGKG	PPEAY	LNDGT	GGDHS	KYLLG
TRPYN	DAVKG	VESAG	NDKGI	LPTLQ	TDVNG	AGKGL	ETRDY	NDGTE	WWKGE	LHSAG
IVRNG	AVKKG	YGQLD	TTSGG	DQIVP	DVNGN	PLAEP	TRDYR	EQPLT	WKGEI	HSAGT
VRNGD	DYQDS	HEQYF	STSGY	ITDGQ	LDGSG	LAEP	SYGDV	YEQGY	TTGTV	PWDDV
NKIGT	VLPDG	YIRAD	YTGNE	FEDGT	DGSGT	FDREG	ETEYG	DLSGI	GNGPY	QSGNE
NPENG	LPDGS	RLKNA	TGNEW	AWGDS	REDRW	DREGY	TEYGP	ILDGK	KTEEG	TEANG
LNESG	RVYHS	FQSAK	DTSLC	QRPGN	FRGGS	ATEAG	DLPNG	LDGKV	TEEGW	EANGQ
NESGE	LLPDG	SWLHS	TSLCP	RPGNK	KRTKL	TEAGV	VSNGK	GGNDV	VDEEN	PNVAP
ITEEG	LPDGR	SWG DG	STGTA	INDGW	RTKLD	VNAGK	WRKNW	TKFGR	DEENR	NVAPW
TEEGV	YNSNG	HTFFH	VTGSN	NDGWK	FLGHN	FEIGE	GKNGV	LGGNG	LPGGK	FTPTS
KNSSG	NSNGN	NPRVN	ADDTH	ITANA	SWLER	IYKTG	TTFLQ	EPGKD	RCNQF	FNDYN
NSSGE	VKVGG	PLPTG	LLNQE	KINGK	WLERS	YKTGK	TFLQR	TLDNW	YYLGK	TQRGD
ISRGL	ATHTV	LPTGY	LPCGL	INGKD	AGESD	SRPGS	YSPES	LDNWQ	QAHLE	HKESG
INTQY	NGGNS	GFPGI	DADGG	DNAGG	KGKDN	RPGSY	SHETA	NNPTG	ITSGV	KDNSN
NTQYA	DSGVA	GYPGI	GMSKY	KELAG	VYPNV	LAFRE	RENGI	TRGKA	TSGVY	QGKRW
KIGNQ	SGVAL	MPHLD	FINGE	LVNGK	ISHSD	NIGKD	VGAET	LSKAF	YQNGS	RYPNE
ASQEC	MNSAG	KDVQC	INGEA	VIDEN	YPTGL	KGPSG	RPSTG	SKAFA	IDDGI	FPPEF
FFDTG	NSAGV	KTDKQ	TGSNT	IDENF	PTGLV	GPSGI	LDKGR	YIDGK	ESDHT	FPEKI
TISQL	SPHSQ	TDKQE	ANNDAA	GGRAG	DVEGF	ERNRE	RSEEE	IDGKW	ADADN	LPFSA
ISQLT	LSSRF	VLSES	NNDAA	SSDDR	VEGFT	RNREK	SEEEI	LPNGK	ESRSV	LPDGT
AAPGC	SSRFE	VSKRR	ARNTG	PAEGG	DRGVV	AIAGD	RVGER	SVSGA	IGTVT	DHAAN
NALKG	SFDPG	SKRRF	NTGLC	AEGGD	RGVVE	SDHAA	VGERW	NWENK	VNQSS	TGSFG
FQDGE	GWEVD	QGYPH	NSFRM	KAGLA	PTEAV	DHAAF	VT DAG	AQSGN	MFNDY	SLGRF
KIGDT	VDAFG	GYPHR	FRMGD	AGLAF	TEAVF	PGRLI	TDAGK	FTKGY	KRSGI	RQGKR
KTTR	DAFGA	NAIFP	LGKGM	TRNNV	SETAV	ELGGR	VLEGE	GYGSY	TLPNG	PLPFQ
TTTRR	PAQVA	RMNSD	GMTVD	TPALA	NLSGL	LGGR	LEGET	NSVLR	LNSVL	AFSLG
VINGR	DTLNT	MNSDC	LTNDN	YPQGV	FGAAF	NQGDH	VVGGE	KVGIL	AKRSG	LNTYP
QNGNL	TLNTY	FNPCG	TNDNT	SDRGV	DALTG	QGDHE	VGGEK	IQNGK	KSDGT	VDHYY

附表 3 1931 个 π 转角.

LKDIGV	PTIYDA	GKETDL	AVTIGL	LAAAGF	ATKAGI	AIGTGA	ILNIGL	AVSNGI
ERRTTY	TSANGL	ALSRGW	ILTSSV	LLRSKG	ALHTGY	AMAQDK	NLKLGN	AEKHGY
ACKQGF	VGSAGG	DATKKE	RAGLGL	DARAGH	DLHNRF	AKKIGA	MIEHGM	SGNTTN
QREANQ	AVSDNV	TQRSVS	VSKYNL	CSSLNN	CIAEGA	DPVAMT	GAASNN	DFVEGK
VSENIG	ANADGT	GLVAGE	WARYNV	DLEKGI	NHGGRQ	NQKENA	MVTYDG	WIYRGR
TFNAEG	AAAQGG	DPNTKS	RLRDKT	YRTAAA	ALALGA	DPEAES	AQAMGF	YIRKYL
VVRELF	QSANSN	ADDSDAS	NEGKRR	KEAMHN	LAQIGC	HLLCGA	HLVHAF	LNANKF
NITNGA	AAEIDA	LSENN	RNNGKV	TLETQL	YTKYSS	MNQKGY	DTVGQV	EIATLA
ADREGV	CEKYHY	YKSEK	ASSHSI	YVDRVF	CRPLNI	LLNAGI	LSAYGL	FVMEGG
AARNGL	CEQLGL	LMDEYL	VSDTFL	LAVFGG	RERVLL	FEMRGW	VEARGA	IMKFGT
AIDVG	AFAAGY	WHNAGY	EEAVDL	GVLNAS	GHNLMG	QEPLHQ	SRLMRL	LRKDDI
AHVYQN	FARTVG	LKEQGT	FVDTCT	YVDVIS	FLTNDN	TQQAGE	IAKFEL	NEYLKK
KLREQV	MRELHV	AIAYGA	IIGFGS	WHQVGG	QLLAGA	STPSGI	SAKTKS	SVLCDC
LSDLKL	VKKTGA	ALMAGN	NLQAQM	MSVNGK	ETNVQG	AKEGIF	ALKHGI	SLQGAQ
LVDEGL	IREEGG	CAAANV	LWQVGL	YKRFQL	AVDAGV	LEEKGL	LLITGL	NSLNQQ
CQSKGI	GGQEG	SIKAGA	SYATRG	LLYTEV	NLLDGG	HQRAGS	WYSDGH	DKSFNR
AAKHNK	EAVTGF	IRDMGV	IRNSGT	PKTFEG	LDSLGA	TVRSGG	TICNAD	LSSEGS
PMQRNL	TKYGDG	LKALGH	IADMG	YRKFDL	NCVMER	MEEGGI	RAANGK	AKKAGA
LSQYGL	LKELGA	CASKGS	YEQLGL	TGHALA	AIENG	AINDGN	RVSFDM	ALAKGE
EDQLGA	DYLEGK	SLEKQL	SVAAGE	SAIYGG	HLIKNE	LHCKGE	LMKHGH	EVVPKF
RVDAGQ	ADDNSL	FEEYGA	NFVHGF	QNQVNR	QVAMGL	ARQHDV	LIESGV	LNEMEI
LTTIGG	DYGGK	ARQNDL	SCLEDK	SYAHNV	ILKLML	LFAQGF	FLKYAY	MLRQGN
LHNMGD	DKAIGR	CAQRGS	LVAAGA	VPTAGK	QWGIDD	INEQHL	LDGKRI	KHKTVF
AGPLLR	MLQQR	VYPDGV	VTEAGG	QIANGI	HEDTGM	LWAWAR	RTLGN	VSTIDG
SIKGD	RELLQI	EKHLKG	DLMSRR	ALRLGA	SNLGMG	SLARGD	AVEQDT	LERTGT
FAQIES	TKANSY	FIREQQ	RSTQGT	AQKYDR	INSVVS	WQMTGD	QEFLKL	LEAQGY
QLYRVG	NTIYGT	FRMMHG	FNTFGF	AHHEGM	TEQNSG	QILLGE	AREMGL	IREGGC
LVREVF	AQKNLG	AKINGV	VGTMAN	LKMSGI	ANRYYW	ARSLRL	TEQYEG	LVDNSF
EVKRHE	HIKSDS	IMKTRL	DQTTQT	MLESGI	AQNRNY	YWQAGR	DLEKGC	DTRTGE
SNGAGG	IKDLGG	MQCLGA	LKRTVV	LHVCQL	FSTVGV	LIQLNT	IKELNS	IGNRHT
DASTNY	IDESNG	IVQKNL	MYENFG	NLITHH	EQLAGN	AKSLGY	LALKGL	IDEVGV
AVCFNE	AKEQGF	NVMAYS	FRALLG	ARTLNL	YYSTGG	YHDHGL	NLLKGD	VEGHRA
TSHDGG	AAAYADL	SQKLVN	CNEHKI	ALRRQV	RIRYNR	LEGVLV	VLSGIQ	WRARGA
ADKLWG	NAQTDI	FINNKL	NFGYGS	LPDLGI	ERQSGV	AEKTGI	SKDTGS	CTNVKH
KKYNNG	DDTSKE	IVNLHA	DPEMCY	YQHDTK	WARQGV	LDEHGL	AGQDGE	FVQEV
LYITGN	NDAFQV	SYLKDL	IQENNL	IVKNGQ	AHRGFF	MRQLGF	LTQSGI	LNMYGW
AIALKY	PAEQGY	FLRKGY	NTMDRG	LQKSGF	LEQHGE	FKSLYY	IGLMGY	VREQGY
VSAATL	LRYYNQ	AVKLK	LRMSNT	LAQQRQ	CLSLDA	MNENHL	IVRAGH	SAQMGY
LGEAGV	WEAARV	WAIFRF	AGSAHL	AERAGQ	YSSAGA	IIKRFI	FEAGGQ	AREHRH
MYDRYF	LEGECV	AIKLDG	FKKLK	SRWPGS	YDEFGL	LESENG	LRHHHF	LEACSV
NSMLRV	LEALGH	LNAAGG	QLMSGV	DTLTKT	LAKLTN	ESVLVR	LMAERV	LRKHEV
AGKAGL	LRENLY	LPALGV	LHKYGL	VRATGA	YLINNQ	LRRKGL	SLDTAG	WVSAS
REAAAGE	TKEGYG	DAVRGS	FEKEGY	LMLRPG	AAELGL	LDKYSL	MENRGF	ATVLGI
SALATE	SIEWGV	WKALGI	FRASGQ	IAKLGG	YALGDG	AAEAHV	LRAQGF	ARHHQV
LDKTYL	LRSVLL	MRRAGI	LRRRGI	HSFMGW	LVALGY	KEKHL	LLKLHT	LAQSGC
ALGTGK	AVQAGY	QENRKG	STNIGV	VTFMLS	YVTSKR	ASENNR	LQGIGH	READGW
ARDTGT	MKAHGV	LLAHEI	AWELGF	QHLLGS	LGRVFL	FISQFY	LEFMGI	CKSLNI
DAATDR	ALKTAK	VEALNG	SINHIY	AVERGI	QLVRDR	AREQGF	RFQKSV	TKFYAI
NKANGT	LGGGKR	KAPLVL	LKNYAG	SGRNGQ	GDNIRF	QLVSDK	EDGKQY	LLTQRI
IIKQDV	INEFDV	LMDADV	AKRMGK	LIRAGE	IRFGLN	LCAAGH	FEEVLH	KKEMTL
VTLDN	KAAYLG	ALGKQV	SALLGL	SISEGR	FADSNS	SYLQKK	AMALGV	STKLN

WGTVPS	VAATLK	KEALGG	MRLMGA	TDGGEE	KAREGV	KLSQGV	EGVQKT	AKKHGA
LPSKNE	MFEMGD	LQGS GK	ILDKEG	RCPRGD	LDTKGY	AIATAT	FINAGI	IHKLNW
AIELKC	LAYQGM	YKGKGR	GIETGE	DKKNMG	MAHGKG	SQEQKL	AADVQL	SQPRLC
VKEFAL	ALEDGV	GEKGVV	LNSIGR	LCAAKA	GKGCKG	IQKAGG	SIQKNM	FRATAF
YTLLGV	QGAARA	ARLEAR	KPVSR	LSEQGK	HEEMKK	SRSLGA	CFEVGM	LSLHDI
CTEQVK	VDFGKV	FDEKVG	MWILGL	LAEAGV	WHNHLN	MSKFTG	SINKRK	LKGKGV
QVKPGN	IKEVFS	ARHVTG	WVSKKL	MISDGF	VVQLGG	CNYFRR	CANTGF	ARKHHI
YKAAGS	RDGFEE	AGGLEP	WIQGGK	LLHEGY	SDEAGD	FQNGRI	FLESEK	GIAGGK
VRTELG	NRHFRE	GRILGM	VRTHLL	LMHLGY	FANRGE	GVGFEA	WRQLGY	SIKERK
IRNYGV	CKATYK	LTSCGL	GVYHGL	AKDIGS	ILDENI	HLAGKS	NANTDG	VQLCGA
ARRLGI	AEVIGD	HVVS GT	FSRFTR	APLGTM	SKAFGT	MMDSGQ	NKQPEL	SVALYQ
LYPTGY	SKKEGF	LIGCGF	FLGETL	MMQKHL	DWLAGD	AQEAGA	WNSLHL	YKSLAV
QVAVQA	LSEMGV	AVKVAK	IRNPFT	AGADNG	LNTKFA	LAALNI	WEMTSG	NQSIQN
LEVHGV	VEGTWK	CKAAGA	LTRTLS	AAVFGF	HLASGD	AHQAGI	HNNIFL	LVIGRV
FHRHGL	LLELGC	AKEVGA	FVEAHG	SDIMMR	SEGCGF	LCKAGI	ILEHAG	VIGDVV
RLLAGI	GMQATD	TEMSNG	AQRQGL	VSKCRV	DQMSKG	LVDEIG	QQRHGL	TQENEL
LESIDA	IGLIGD	LLLSGR	INYQQG	YPNGGL	FRVFGT	AALNDS	GCKSGI	IAEEGG
AAAIEV	GAELSK	DFMAKK	NDETNG	LIESGK	AAERGL	MKRKKT	WLHQGG	FERVFG
HIPRTV	RDWVLG	LLRSGE	AIKCGL	LKQLGL	ATEHGY	DLKKKT	AETMNL	LRKSGI
TAASSL	LEEMGL	AQALRI	RQNNGY	LLENGD	FQSDVM	MEESKH	YPELQI	AESQKW
WRARGA	YEDLGM	VGAVAH	GYKDGS	FWTDRL	AEKAGL	YGSADA	MTAKGG	AVAEGE
WFLAGH	FQKMGI	ASRDTG	IVLAIF	LAHDGS	VIAEGG	LILTDA	RRAEGT	ANFYQA
WIVQEN	NNEKGY	RIQAKT	CESLGL	RKAFNY	LQGDLI	WAYRCI	EPSLEA	LLQKKQ
FTHSQN	AFEPYI	ALALGK	YIIMEG	SISSGG	RPEKRN	ALKEKD	VDRMYG	LLYSRV
IITTIY	LILDTL	AHLTNN	MEGIFF	RPNNGG	ASDILQ	WYKSKS	KEYYLL	TERWLG
SYNQGI	AANGYI	SAFHDI	FHRQNK	SMLEGG	EVDVGL	GWAIWS	MLTEIY	LYGGAI
ETPTKK	TCATFG	DKENNI	LERIGL	DANDNG	ALDSGL	SEDNYA	VNFFKV	TELNGT
NWGSSH	LKHLGV	HPETKA	NTATNT	DSNKA	AAMEKK	DVVFGE	LKANLS	LTQFDT
EHENNA	HFDAGE	KIPDGK	QRVAAL	DIGNNS	AKQKGI	HETLDC	RQVNNL	QASNKE
NAKAGL	EARKGW	QLIAGK	TVTAEA	DTVARN	AAKHQV	VLKNNL	MREMGI	NPYMG
ELQQGR	LYELGC	NEAEGT	QESLGG	NEEKAA	VRDAGG	DLFSGK	KKELNL	AVMQKK
LHTRAF	PVDAGH	AEEQGY	EHSLVH	NDRFFQ	LDAVDF	LTMNGF	AVANGN	SDKEMF
HTKHHQ	DDYHGG	QIEAGY	FVEEGA	VDSLGD	LESRGM	LGDLKI	LTKVNA	LDENSC
YFLKFQ	LIDDHF	NPKELV	AVNLDG	KLLEGN	AQRAGY	AMKAGA	DLFLTG	LVQAE
QSSCGG	LQTANA	LDAGKL	CALKDY	FLRAGL	VAAGSL	ANLKQE	LCESGT	VALDFL
DPNQGY	ASKFNL	GQMTAG	SHIVGA	SASMGR	MIKAGA	GINKGY	DWIVGM	NEQTMK
FAKVGL	CERQGL	TAGSWI	MCSRGV	SQSNGQ	ALAVEG	RAFLQM	KAMKEY	QLAKGF
KKELTG	PAQLEM	ATLAGA	TWCAGL	FLTREM	YVEAGA	DSNEGG	AALTEA	AIASFT
WEALDL	QLTSGG	RLTRY	ARETGI	ANSMWG	LRSABV	TKSYGE	SELLQL	FAAGNL
ELVLQD	LVSLGK	YTAEGK	GRAVLY	LVANNT	YESINY	IDAFGV	DYSGKR	GLCEGV
FVEQVL	LITSVG	LVKRGV	GHSGL	YAADGG	ALSVGN	ADKGYT	NMDHKV	LANTGV
LRDDWG	YAKQKI	FQKQGV	VVESNG	QHVNLG	YAKKGD	WVRESR	DTEARR	LVDVGD
AIDLDI	IVAHIQ	AKEEGV	HQQWMG	NDMYLN	LEFLNR	YERLGF	LQRWGG	YRQGLG
WGNQIK	DKKNDI	VPAYIR	YQDWGA	LPVNSS	MSEHGT	CKSVGI	LSDITR	VQEAHL
GTWSQD	ISSSGL	LCFRGV	MYARGM	LLDSHS	DVDKGN	MCRDVL	LSRSRR	AIAANE
ALDQGA	GADGLQ	MARERI	SRAALD	LQLLHG	LEAFSL	QRMGRH	LKALGL	SAGWNI
MDERNL	AEQHNL	MVRSGE	AAASGL	GCSLNG	SEWNDI	AQQLGI	ITRYEC	WNIPIG
LEANGI	PDSWGT	SPNAET	LAPLGV	IKKQKY	RVSQVG	FAGFNI	ANSLDA	CLKDGA
ARQIGM	CLAAGK	NTAGGA	SRERGL	MAITGM	LKARGY	LKENG	FENAGI	GITQWI
AIQHGV	QCLVKN	HADAGY	RVKRGA	LARDLC	PEGVGG	DPEKGM	LRDTGL	WKKRGW
ALEKGV	FKSQGV	AKEQGL	ELKTIF	LKQEGC	LWKGAL	WTRSGA	AANCTK	DDNSGV
CDKKGT	MKSYGV	AAEIGI	EKELYG	YRKYIL	HYIGIG	CDKRGD	MQYTRG	SSLDGY

KQSHGA	LDAYDV	LRSNKI	EPTFKY	CIMKQL	VLKGNE	FHSLFW	ALMMGI	TFTMLN
ALSQGA	IKSHGA	LERMNL	LTGSAA	MEENTY	WRPYFA	LEGSNF	LKKYGM	LKTKGW
LVDEGK	CKQNR	AHAVGV	VQRSIG	YLEYTR	KGMIEG	SKSRGT	AKEANI	DQETKT
QVMASHR	LRAAGF	LVNDEV	LLDIQA	RYIFAS	WAKKHH	FINKRF	RKEKGY	ALEAGL
QNRIFT	PNWGQD	IDDTVL	WLEHVV	LYESEC	ESEEGI	AWESRE	AEKAGV	WRKRGL
FTPLNL	FVNAGL	GKKTFS	RLRVGD	ESWLLH	QFDSGK	EAFLNT	SIERNL	LLALGL
ALMSGQ	AERLKL	KMNNGW	SLMAGT	VDEAGA	MKEKGL	HPDHGK	SAVLDV	SAKARG
ESAFCG	ERIFYG	HVRRGD	MFDNKE	FAKAGA	IRDNER	VKAEGG	YISNGA	GARKGR
LKELGF	LAELGA	ADNFHI	SNYGGG	IRELGK	CLEKGI	DKTEGT	LYATGN	AGLLGV
AAQAGA	LDATGM	LQDKNI	YIRLFG	CDERGL	IEERVK	CEEMGF	SDYVVA	VVEKGL
FEKLGM	AVELGA	ARDVGA	GKALGI	VLEAGA	LAYLVK	RSEFTG	ELDRGR	FARYGL
AQAAGA	VTSQGY	MLPLGF	FVNQGY	WYKDQK	LQYNKG	KNHFNC	LNDKHR	DYKKRQ
LNDVGV	EQMAGL	LATGGV	AMQRGV	LEENNL	IPDTGN	KNELGL	LQKGKV	VRELGL
SGLTNG	ALWAGK	RVNFGA	AENLKR	AHGGRC	CEEHGI	ADKMGM	SIDIGD	RDMCSF
TCGRGE	LESAGY	KNKLGF	YVQRGT	AVQKRD	ALLTGK	ALFNIG	LLYKDL	YELNKD
AHNAGQ	LRASRL	LDYFKQ	ALLKNM	RLLRIG	SFLLKS	AKILKV	LYNYRM	RAVHQI
VHTLAI	RTAFED	YKENNV	NSEQGY	SICDGE	LLKSPI	AKNGFK	ILDTCG	ISISKD
VDTLV	DHLLGA	ISDSL	VDESGV	YEMALK	GQKKDK	TIAEGR	LKLGGL	AYTNKI
ANQAGA	AHNQSV	SLLFKS	LEGDVW	YTQMNA	AKKAGK	CSAVGL	LADEGR	IVRHGG
AIANN	FCSAEW	AEIAGV	SAAKGN	AKENNF	ARQEGC	DVKLGK	LINDGM	SLELRK
HAGWLG	LARWGI	LKALGI	SKTAFS	AAKVKA	QLISNM	MIDNNI	AMRYIN	RKMQIG
YEDAGK	AEGDGF	SPAYGV	KDDYLD	AEHYGV	GHESR	KLESNK	AKKRGV	VKQRCG
LEARGF	LTQIGC	LARHGQ	KMAAGV	MSKIGM	AFAACL	NSLTLN	IANSGI	HTKLGF
QIKSSG	LVRSGV	GVEIGR	ANITGG	SKKHNL	LFTIGC	ELSTLR	AAETKN	NYKNGK
VGPNGT	GWYNAH	YDAQNG	DAKLLD	SVSYGV	ARQLGF	ETEFGE	WRQAGL	LKLLGV
YAKGAD	LARTDI	LKGQGV	DYARGI	FQELNA	FPENGT	VPGEFA	ALMDGE	SIIDGG
ALKDGG	DDQSGT	MLQRGF	DKDRQM	SDIAGT	NNKDKV	DVKTKG	DSMRGD	AVTVDF
YFIKYG	AKEGAE	TLEHGI	VQTAEI	VKENHF	LRMDGR	LQRQQL	VDSFQL	RRQLHS
CKKEVR	GEPHGR	LRQLGD	LDGVGI	LTKRQY	LEDWGL	MDKFGF	LARIGY	LYNNFG
AKDACR	ACTVFQ	IRHLNS	MKARGG	AEIQCI	TWDERR	FLSING	DPFLGR	TSSELLK
CRIAGL	SEYCCT	WDAEIA	LERLEV	VDNAKL	GLMSGD	LAFRGM	DKIVLG	MFRLGI
YTREGR	CINQHF	LNPGWV	HLANRR	AVNAGQ	LDDYGL	LLMRGE	LKALGF	NYRIMS
FTAKGA	AAFNMG	DLKSGD	DLFGHV	DGAKTG	YKKGVL	TGDFLE	IHTEQ	IHSMSL
AEVAGV	SKARGM	LKDKNM	WYTVFV	MTEAGL	AKELGF	HEALGE	TLQGLL	EVLQEN
VVCTGT	WAQKGE	ALNHHE	EYVKTG	LVNHGC	MLLRHT	KKLLGI	VRETKI	VCAAGA
GYKEGG	GEQLGV	SVLMGK	TKADEN	NPDRGM	RTAKKN	ACELNE	KQSTIG	EIRQGR
RFQKGS	SFVEDL	IKAECS	AKEKGI	ATREGF	FHGMGA	ACELNS	AEQVGI	LKKEDR
IIMYGI	EEEFDT	IAGFGG	DEKTNE	AKYFNL	AVESGK	GKYVVK	LKELNV	AKRHDA
LQTRGH	SDDICA	VSSAGC	LTANKL	AETGPN	YGSIGY	ACGLND	ANHARK	IEQYDV
FEDIGE	CAKLEA	LVRDGL	TVSAGA	VKATGK	HRKTQR	KQYAGK	FANSQF	HTLQNE
AWLKGW	FRGCGM	DLAFIH	SEKLG	AIIEGF	LKKKGV	ACRLGS	LEPLDL	CKVKNI
IKATNG	KWARNE	VWQDYL	KWSDVD	MSQAGA	TRERGN	KETTGG	NQAAGG	YNSVFM
VYSMGG	YGKISG	IYNNAF	HQFVEN	RKEQGG	AVKRRY	AELAGE	LQDKNS	GEKLGL
GKRFGV	GFWYTL	LWLKGV	DPVNVK	DHLLRD	IIEQDG	LSEEGI	CQNFFR	LAANNE
AIMNGE	DILRSQ	MDGVLA	QRYQSH	MFSQGL	LSAAGF	INEATL	HYAMGM	IDAAET
FRQNVI	WTQKYA	VEKYFG	FIKCGI	SASVGA	YDEINF	GGKKGL	DVEEHL	AFDNCK
INRSGI	LPGGAG	YASRIG	SQVANE	FCQDKS	HGQKGV	SRQYQV	NKFSKQ	HCVRGQ
AVSLGA	LKELGV	IAAAGV	EVGAHN	GYNQKV	MDKSCM	APRAGF	LVKVVF	LCARGI
MQTNGA	AHRLGL	LHGKGV	LLAAKD	ISQKGG	AMELGA	NLEKDG	IPAYLL	LRKAGA
AQNAGK	DLVTVN	LKSDLG	KYYGYG	YLQAGE	LAKYGA	FFEHEY	LRLAGE	QADRCT
SMVSNY	GQEWAA	VDKVG	ARLTRS	MRLAGG	QKLAKV	NWLMNH	VHQERT	LEEENR
SQYARF	LNQGA	DHFFNW	FFALGL	GTNKGC	KQTLEQ	LHALQL	RPERAL	SILVERN

PEFYGK	PELMGC	RKRNGI	AKELDG	HQALGF	AIAGKR	KHLGNE	LEDTCV	VLGLFS
GVASGN	QEGKYG	LDEIGV	WARSSG	AGTMGF	LSKKNY	SADPPL	MKEVDI	QTPIGV
IGTPAQ	NSEADE	LKSIGM	CVEQGV	KARNSE	DHQLGL	WTKHGT	DATYGK	EALAGH
SSSVGG	QNDRGG	AEIDGA	MRAAGR	AFKNGE	AIKEFG	LRPHAA	NILGHK	DEINNT
IEPGDI	GSARAD	LKALGL	AHVGV	DPSREN	QAAVGH	MYAEAG	DKQKNG	LAKEGL
VHAEDG	ESHYLD	NAIDGT	AYSNDI	TTALDL	GSKLGL	ATQVDI	AERENH	ALDEGD
AREAGF	FERLTL	LKRSGR	AASRCA	CRLAGK	LMELGL	DHLVGK	THSAGG	ITAVLC
LAKRGI	AYLTEA	KDRYGA	AAGSGM	ARRWGL	ISQRGG	YELLFE	LVFLDV	IKARGK
LIGKGL	AQQLNL	FPGSRA	IAENFL	LIKNNI	KSEFGL	CTQAGG	KVDGAK	AQQNGK
RLQKKA	GFLRGE	LRSKKL	RIRFKD	LLQSKQ	ARAAGV	VVAKNE	LIKEGY	FLNVIG
VQQKCI	LSSYGA	RRALRI	AKARGI	NSANRF	TFDIGR	AIMNGL	LQYIVG	WRAAGV
MQSLGV	KNKLNI	AGEHNI	MDKYGI	PILLNL	SRAADV	NAEVYL	ARCLNI	MKSRNL
LLASGI	LLALGL	DDFEDC	AAEYGA	RCALGV	REIQYG	NHQLQK	TMDDMS	EGNPPY
LEERGG	VHEAGG	FYRDLL	VESPAS	NPGTNV	IEDTGI	DTAHQR	VTKAGH	ALLSGD
FLGHWT	IKESGT	LRAHGV	QCKLQL	LHEDGE	AASQRD	LGTFGI	LKKLNL	EDRCLN
LRAAGA	TSSTGF	GHVLGL	HIASAD	VGSNSY	FESEGL	IESLKG	YIRCRH	YSSLGV
RYHNRF	SEVLET	LQDNNW	MRQKGA	ALKGGA	LAARGY	VYRTIG	VVANNA	AFVNNNT
DPILGK	LKENNL	LKAKGE	AMEYGA	CREAGV	LIDQGY	LKVNKL	ATNLGL	LQENNR
AREEGV	KSLFKV	IPSKSL	AIQCGA	ALNLKA	IPLRVI	MHKSRM	DKQTCT	YVEAGV
LRRQGI	EDALGL	DIQAKN	MKEDGV	AEEDGA	LREKGV	FGWLQI	AARTGK	CERYLG
AQASRK	LRSRDI	NLQTRK	MIACGF	VRRQGI	GITVTN	SHMVSV	FAEEGL	LGPKGF
HSAAGT	AMYLQM	LQQRGA	GGRHGL	VIQAGA	LMHQCE	IISVQV	IGGYGG	VTNPSR
AWNSHS	AYQNDL	MVNRGS	LLYQGR	YFERCA	WRELF	KILSGK	DMVSKY	CNNVGV
MIGVEA	FAANKR	LDEINQ	QRWVAS	LRDAGQ	LENGEL	LLVGRL	EFLAGK	NPGNRE
VDAANA	AQKVG	LKLAGV	YAKTGL	AYWPPQ	AEKLGF	QHMNGK	IEKAKI	FPAVPY
AERLKA	ARQLGL	CSNGGH	YKSYLE	VKETGK	GKALGL	VIKYNW	NIIAGK	LIDIGV
AAQYNI	GAQDMK	HAENKW	SHDLLH	DLNNLK	LKEAGL	SNLVAN	EELLGL	TVVRKW
AGVLEA	LKVEGH	AKREGI	LTAGK	ANARNK	LAERGY	ISDADA	LTSKGY	GEGWGF
AKGYGV	DEEVGG	FGETGL	KKELAL	DTKEGK	ALLRGE	SKKVEV	LVDQNN	DNQRGH
IIAEDR	GHQGME	KAVQGK	CLTGWV	AEWAGI	ALNTRV	NPKVQS	AKEQKL	AYESGA
LVNAEV	CKDMNL	AKRLGI	KQLTEN	DDKTLE	LREWGV	LLQSN	KVKENA	WPEYGY
LVLLGE	IRAVGV	LSAHGL	AKAEGC	NTMTDT	DISNNE	SYDSKD	AEKMFG	KKALKA
LAVAGL	SMLLGY	ARAAGA	LLKTGV	NLLSAS	IHEQGL	SKQVLG	RKSKGL	YDEIGI
VEAVLG	ALLVDA	NVVNGN	LLQSKQ	GIMFRG	ARTMNF	LKKEGF	VVEAGG	DTSSST
FAAEGD	GSEGAG	LLKQNV	QYLAGE	LELSWK	ELLSGQ	LFSKVL	EIKKKG	WNSGSL
TSANQE	CSKTHL	LMRHGF	AGGAGV	SWKGTK	AVRDNK	MARHGI	RPLFEK	HPASST
LLAKGS	LKAKGV	GEANGL	GIGIPL	HESKNF	DKTWVR	LYNEWN	FEKKS	KLQEKE
LIASDG	GRAHKA	ANRLGV	MIRGGH	SKHFN	DLKNVK	AKSLNA	LESYID	LLQQGY
AIFQGA	QSGGLG	ENEFSL	TFGLAL	KTAFGD	WLGCGQ	ANLLGF	LRDAGL	QEYRGE
LEAVAG	GQKLGV	DLEHGF	CFTSGC	FAQKGG	WEKIGW	LEERGF	QRLFIG	YEPLGI
FQFSGL	IKQDGE	FQRGAQ	CAARNC	VVKLKQ	LIEQGI	FLVLKK	LAENDR	VLKYLL
KKEKGL	AEKFGD	PSGSPR	AVELGA	LHSLDL	IYENEV	LEEEGI	LAWHLF	GHEKGY
NVVRTH	CTWAGK	CADPCW	LKDVQC	EILSK	CKELGI	EISKGW	CVDAGA	SFQPPL
SGEAGL	YSCRGG	DTLNTY	TRESGI	AIYQRK	ESMIGV	LRERGF	LEAGFC	LVERTG
LTEK GK	IQQNLF	RNMNNI	DDVYGE	LLADGV	RQKHGV	FIQGEI	ILNSVL	LLEKRL
LDAAGI	LQSQ GK	TSTKMI	AETFGK	AQQIDA	ESSRGQ	KHLVNA	CDELHI	LPGGKL
FSAEAV	IAKHGV	DYFIKE	HNRS GG	LEDEGF	SWLERS	KKDYKL	LKVGIL	LIQNQE
GLETGV	TRPYNQ	FKSMDI	AKEHGI	ALDKKE	LKSAGI	LLGKGI	CNALLY	AIALGY
AIQVSA	GSRLTA	TDSMNM	RKMLGG	RSRYGI	LLCGGL	SILSNE	FDSL YR	EKTYKI
LKKFSY	LVYDKI	KSNFFM	IALTKM	KDFAGL	QTLSDV	LARSHN	PPTNGY	YDALGL
SLYLNK	CKQFGI	LLESGL	LKEIGY	INDGWK	TRQFNI	LDEHKV	RTSRGF	LKEHYA
MESEGI	VCILSA	LSDYNI	LRNSGV	IKARGL	YLQERQ	LHKSGL	AGGNDV	KVKEGK

TVDPLV	FVEENL	CRTSRM	ALMFGL	AALLGV	VLNEER	KQKYGL	HESLGF	LRRLGF
WENLGM	NEAIGC	YGQLDL	LNDKGI	KELAGK	LELKQR	ALLGLG	AQYAGV	PTSLGI
VEAAGL	NWENKT	ASCHEQ	QIMAGE	VEATGA	RWPGPV	ALLSNN	AETIGV	SFRMGD
FTEHNA	SLQFLS	RLKNAR	DNINYQY	PAEGGD	CQAYGK	ANLEGI	LWDQGI	VEEQGG
LIFKEG	DSSSDS	IRDTRG	CLEREI	SRRQKI	VRAQFG	PGLTVG	ARRYNL	
LDQTEQ	SPSSKT	YKFAVA	LRAAGY	LLVAEK	LRESCI	FKELKV	WQRDFW	
LALMNK	DAVKGK	FAVAEK	DYSGTY	AQKRRW	FDRLSF	AVASSD	FKYNGH	
LLLLKD	VPEQDT	MRKAGI	GAKYGT	LAFSLG	IENGFG	LVIAEG	WVEEGR	